分类号_____ 密　　级_____

U D C_____ 单位代码___10763_

喀 什 大 学

专业硕士学位论文

基于 ARIMA-LSTM-BP 组合模型的股指预测研究

Research on Stock Forecasting Based on ARIMA-LSTM-BP Combination Model

马　贵　永

指导教师姓名___唐耀宗　　副 教 授（喀什大学　　喀什　844007）___

专 业 领 域_____应用统计_____　　研 究 方 向_金融统计与风险管理_

论文答辩日期__2024 年 5 月 5 日__　　学位授予日期_____年　　月__

答辩委员会主席___姓　名　　职　称_

评　　阅　　人___姓　名　　职　称_

___姓　名　　职　称_

___姓　名　　职　称_

2024 年 5 月 5 日

中国知网　https://www.cnki.net

Research on Stock Forecasting Based on ARIMA-LSTM-BP Combination Model

A Dissertation Submitted for the Degree of Master

Candidate： Ma Guiyong

Supervisor： Vice professor Tang Yaozong

Kashi University

Kashi, 844000, P. R. China

May, 2024

中国知网 https://www.cnki.net

中文摘要

股票指数的预测对投资者和金融市场具有重要意义。中证 100 指数代表了我国 A 股市场中一系列规模较大、流动性较佳的上市公司，其波动直接关系到投资者和金融机构的利益。因此，对其进行准确预测对金融市场决策和市场风险管理具有重要意义。

本研究使用了中证 100 指数的相关数据进行了预测模型的建立和比较。首先，对相关数据进行了筛选和分析，通过相关性分析选取了包括价格指标、成交量指标、技术指标、宏观经济指标、情绪指标和汇率指标在内的 14 个指标作为模型的输入变量。然后分别利用 ARIMA 模型、BP 神经网络模型和 LSTM 神经网络模型进行了预测，并对预测结果进行了评价。在评价指标方面，ARIMA 模型的 MAE、RMSE 和 MAPE 分别为 62.89、77.31 和 1.62%，BP 神经网络模型的评价指标为 28.22、33.40 和 0.73%，LSTM 神经网络模型的评价指标为 111.03 、139.69 和 2.89%。结果表明，BP 神经网络模型的预测效果最好。接着，我们采用了等权重法、加权平均法和变权组合法法对 ARIMA 模型、BP 神经网络模型和 LSTM 神经网络模型的预测结果进行了组合，得出了不同的预测结果。其中，加权平均法组合形成的 ARIMA-BP-LSTM 组合模型的预测效果最好，MAE、RMSE 和 MAPE 分别为 20.41、26.77 和 0.53%，这表明组合模型的预测效果优于单一模型。

本文的创新点是提出并验证了一种组合模型方法，结合不同的单一预测模型提高预测的准确性，此外，还从多角度精心选取相关数据指标，多方面考虑了影响预测模型的因素为股票相关研究者来说具有一定的借鉴意义。

关键词：股票预测； ARIMA 模型； BP 神经网络模型； LSTM 神经网络模型；组合预测模型

中国知网 https://www.cnki.net

Abstract

The prediction of stock indices is of great significance to investors and financial markets. The CSI 100 Index represents a series of large and highly liquid listed companies in China's A-share market, and its volatility directly affects the interests of investors and financial institutions. Therefore, accurate prediction of it is of great significance for financial market decision-making and market risk management.

This study used relevant data from the CSI 100 Index to establish and compare predictive models. Firstly, relevant data was screened and analyzed, and 14 indicators including price indicators, trading volume indicators, technical indicators, macroeconomic indicators, sentiment indicators, and exchange rate indicators were selected as input variables for the model through correlation analysis. Then, the ARIMA model, BP neural network model, and LSTM neural network model were used for prediction, and the prediction results were evaluated. In terms of evaluation indicators, the MAE, RMSE, and MAPE of the ARIMA model are 62.89%, 77.31%, and 1.62%, respectively, the evaluation indicators of the BP neural network model are 28.22%, 33.40%, and 0.73%, and the evaluation indicators of the LSTM neural network model are 111.03%, 139.69%, and 2.89%. The results indicate that the BP neural network model has the best prediction performance. Next, we combined the prediction results of ARIMA model, BP neural network model, and LSTM neural network model using equal weight method, weighted average method, and variable weight combination method, and obtained different prediction results. Among them, ARIMA-BP-LSTM combined model formed by weighted average method has the best prediction effect, MAE, RMSE and MAPE are 20.41, 26.77 and 0.53% respectively, which indicates that the prediction effect of combined model is better than that of single model.

The innovation of this article is to propose and validate a combination model method that combines different single prediction models to improve prediction accuracy. In addition, relevant data indicators are carefully selected from multiple

中国知网 https://www.cnki.net

perspectives, and factors that affect prediction models are considered from multiple aspects, which has certain reference significance for stock related researchers.

The innovation of this article is to propose and validate a combination model method that combines different single prediction models to improve prediction accuracy. In addition, relevant data indicators are carefully selected from multiple perspectives, and factors that affect prediction models are considered from multiple aspects, which has certain reference significance for stock related researchers.

Key words：Stock forecast；ARIMA model；BP neural network model；LSTM neural network model；Combination prediction model

中国知网 https://www.cnki.net

目　录

第一章 绪论.....1
1.1 研究背景和意义.....1
1.1.1 研究背景.....1
1.1.2 研究意义.....2
1.2 研究现状.....3
1.2.1 国外研究现状.....3
1.2.2 国内研究现状.....4
1.3 论文结构.....7
1.4 技术路线图.....8
1.5 创新点.....8
第二章 ARIMA 模型及预测分析.....10
2.1 ARIMA 模型预测原理.....10
2.1.1 ARIMA 模型.....10
2.1.2 构建 ARIMA 模型.....11
2.1.3 ARIMA 模型的优缺点.....13
2.2 模型的评价指标.....13
2.3 ARIMA 模型预测分析.....15
2.3.1 ARIMA 模型的预测过程.....15
2.3.2 ARIMA 模型的预测结果.....18
第三章 BP 神经网络模型及预测分析.....20
3.1 BP 神经网络模型预测原理.....20
3.2 数据来源及指标选取.....22
3.3 BP 神经网络模型模型预测分析.....26
3.3.1 构建 BP 模型.....26
3.3.2 BP 神经网络模型训练与预测.....28
第四章 LSTM 神经网络模型及预测分析.....32
4.1 LSTM 神经网络模型预测原理.....32
4.2 LSTM 神经网络模型模型预测分析.....34
4.2.1 构建神经网络模型.....34
4.2.2 LSTM 神经网络模型训练与预测.....36
4.3 单一模型预测结果汇总分析.....41
第五章 ARIMA-BP-LSTM 组合模型预测.....44
5.1 组合模型预测原理.....44
5.2 ARIMA-BP-LSTM 组合预测模型.....46

中国知网 https://www.cnki.net

5.3 三种模型组合预测对比分析型 50
第六章 总结与展望 53
6.1 总结.....53
6.2 展望.....54
参考文献.....55

中国知网 https://www.cnki.net

第一章 绪论

1.1 研究背景和意义

随着我国证券市场的不断发展和完善，投资者对于股票指数的预测需求日益增加。中证 100 指数作为我国证券市场的重要指数代表之一，对于投资者来说，准确预测股票指数对于制定交易策略和降低风险具有重要意义。对中证 100 指数进行预测的研究，不仅可以为投资者决策提供一定的参考价值，而且对于我国证券市场的稳定发展有一定的促进作用。

1.1.1 研究背景

在股票市场研究中，投资者需要对股票市场的走势进行合理预测，便于之后的做出正确的投资决策，从而获得更好的收益。因而，对股票进行预测一直是金融领域研究的热门话题。在现代金融数据分析中，大数据[1]、人工智能[2]和机器学习[3][4]等新技术手段被广泛应用于股票预测中，股票数据的预测结果的准确率也得到了很大提高。我国股票市场是全球最大的股票市场之一，中证 100 指数涵盖了我国流通性好规模大的上市公司，对它进行预测可以更好地了解到我国股票市场的合理走势。对相关股票市场的未来走势具有很好的参考价值。此外，影响股票价格的因素复杂多变，使得对它的预测具有很大的挑战性。

在传统的时间序列模型中，ARIMA 模型[5]时常用于对股票数据的预测中，它对时间序列数据具有较大的拟合能力。BP 神经网络[6]和长短期记忆[7]（LSTM）神经网络等机器学习模型因为能够处理非线性和长期依赖关系，在股票价格预测方面得到了广泛应用。不同模型在预测的时候都有其特点和适用条件，大多数情况下，单一模型的预测效果有限，通过将不同的预测模型按着一定的方式进行组合，这样在一定程度上可以降低各个单一模型的局限性，从而提高预测的准确性和稳定性。因此，采用合适的组合预测方法将不同的单一预测模型进行进行组合就显得比较重要。在组合预测方面的已有文章中，常用的组合方法主要分为等权法和变权法，定权法有等权重法和加权组合法，变权法有方差倒数法和变权组合法。定权法是按着一定的方法确定每一个预测模型的权重，这个权重是恒定的，而变权组合法是预测的每一期不同单一模型的权重是变动的，在大多数情况下，变权组合法形成的组合模型预测效果更好，也更符合实际情况。

中国知网 https://www.cnki.net

1.1.2 研究意义

随着我国证券市场的不断发展和完善，投资者对于股票指数的预测需求日益增加。中证 100 指数作为我国证券市场的重要指数代表之一，对中证 100 指数进行预测的研究，不仅可以为投资者决策提供一定的参考价值，而且对于我国证券市场的稳定发展有一定的促进作用。

首先，中证 100 指数的预测研究在理论上为金融领域提供了新的预测模型和方法。传统的时间序列预测方法如 ARIMA 模型在预测股票指数时存在一定的局限性，而深度学习方法如 LSTM 模型在处理非线性时间序列数据方面具有较强的优势。因此，结合 ARIMA 模型[8]、BP 神经网络和 LSTM 模型构建 ARIMA-BP-LSTM 组合模型[9]对中证 100 指数的收盘价进行预测，可以为时间序列预测领域提供新的研究思路和方法。

其次，中证 100 指数的预测可以给投资者进行相关投资提供重要的参考价值，中证 100 指数包含 A 股上市公司流通性强，规模大公司，它们的股票价值变动，在一定程度上代表 A 股上市公司的主要趋势，因此，对它的预测结果可以为金融相关机构提供一定的参考价值，帮助它们进行更好的决策，有助于降低他们的投资风险，提高他们的投资收益。

此外，对中证 100 指数的预测也可以给相关政府部门提供重要的参考价值，股票市场是金融市场中的重要组成部分，因此，对它的预测可以更好的了解到金融市场的现状，在政府相关部门制定宏观经济决策的时候给他们一定的参考，做出更加合理的决策，有助于经济的健康稳定发展。

最后，本文通过等权重法、加权组合法和变权组合法构建的 ARIMA-BP-LSTM 模型具有很好的预测效果，ARIMA 模型适合对具有趋势性或稳定性强的数据具有较高的预测效果，对于波动性较大的股票数据，通常预测效果不是很好。BP 神经网络模型在对复杂的非线性数据进行预测时具有更好的效果。LSTM 神经网络模型具有长时依赖性，在处理时间序列数据时具有较强的预测能力，可以很好地捕捉历史信息。将这三种单一模型进行组合，可以整合他们的优势，降低模型误差较大的偏离值，有助于提高模型的预测效果。这种方法对金融时间序列数据进行相关预测具有重要参考意义，对投资者来说具有重要参考价值。

中国知网 https://www.cnki.net

总之，本文不仅丰富了时间序列预测的相关案例，还给金融市场的参与者提供了预测股票市场的方法，可以帮助他们做出更合理的投资决策。

1.2 研究现状

股票预测一直是金融市场研究的热门话题，有很多学者对它从多方面进行研究。传统的股票预测的方法主要基于技术分析[10]和基本面分析[11]，但这些方法预测出来的结果往往差强人意，股票数据具有非线性和复杂性，这些方法难以很好地处理这类数据。而机器学习、深度学习[12]和自然语言处理[13]这些方面就可以很好地处理这类数据，因此在股票预测方面得到了广泛应用，并取得了不错地效果。

1.2.1 国外研究现状

在对股票预测研究方面，国外学者研究积累了大量的研究成果，涵盖了传统的统计预测模型和最新的人工智能技术，尝试了多种提高预测准确率的方法，给研究金融时间预测方面的学者提供了丰富的思路。例如，Huang[14]等人(2005)使用时间序列相关的分析方法，结合宏观经济指标和企业内部财务数据对股票数据进行预测未来的走势，研究发现，宏观经济指标和企业内部财务数据加入模型中可以提高股票预测的准确性。随着时间序列预测技术的发展，有更多的学者开始尝试利用机器学习对股票相关数据进行预测。接着，Young.K.H [15] 等学者于2019 年提出了一种新的混合预测模型，他们将卷积神经网络与循环神经网络合结合起来形成混合模型，把股价时序与它的图像特征输入到模型中，从而构建了LSTM-CNN 混合神经网络，用这个混合模型对标准普尔 500 指数进行预测，结果表明，构建的混合模型的预测效果优于传统的单一模型。此外，Yaqub.M.U [16]等人把 ARIMA 模型与 BP 神经网络、多层感知机及 RNN 循环神经网络相互结合起来建立了一种混合模型。他们用建立的混合模型对道琼斯指数进行了预测，结果显示，包含神经网络模型的预测效果优于没使用神经网络的模型，通过ARIMA 模型与多层感知机相互结合形成的模型，对道琼斯指数进行预测取得了显著的成果。另外，一些学者尝试将多种数据源加入到预测模型中，对股票进行预测，比如，将新闻数据、社交媒体数据和股票数据结合起来。Bollen[17]等人(2011)基于社交媒体情绪的数据对股票市场进行预测，他们将 Twitter 上的情绪数据加入模型中对股票市场进行预测。

中国知网 https://www.cnki.net

综上所述，国外学者在股票预测方面做出了大量研究，传统的统计预测模型和比较热门的人工智能方面都有研究，并根据股票数据特征构建了多种类型的模型，为股票预测研究做出了巨大贡献，他们的研究成果扩展了金融时间序列预测的思路和方法，给股票预测领域的学者者提供了重要参考价值。

1.2.2 国内研究现状

股票预测研究一直是金融领域研究者的热门话题，较高的预测准确率对投资者和相关机构来说具有重要意义，在过去的几十年里，我国学者在这方面做出了大量的理论研究，通过不断尝试和探索提出了各种股票预测方法。

1. 传统统计模型

在过去的理论研究中，国内一些学者尝试利用传统的统计模型对股票进行预测，比较常用的方法是自回归移动平均（ARMA）模型和自回归积分移动平均（ARIMA）模型，这些模型比较适用于历史数据的拟合和趋势预测方面，用它们对股票进行预测，可以较好地捕捉股票数据地的基本特性和变化规律。例如，刘洁[18]（2021）对格力电器的 240 期股票收盘价进行了时间序列预测，研究结果显示，在短期内 ARMA 模型对股票具有较好的预测效果，股价受多种因素的影响而产生较大的波动，在长期中，ARMA 模型便不适合对股票进行预测了。赵康银[19]（2020）对 TCL 集团的股票收盘价通过 ARIMA 模型进行预测，对数据进行检验后拟合历史数据，然后对 TCL 集团股票的收盘价进行预测,并以此为基础探讨了股价变动对集团经济发展的影响。从这些研究中可以看出传统统计模型在股票预测方面依然具有很大的价值，通过分析这些模型的优势和局限性，可以结合前沿的预测方法提高股票预测的准确性，更好地为金融市场服务。郭改文[20]（2023）利用组合模型对茅台股票价格进行预测，首先进行 ADF 检验检查时间序列平稳性，然后分别尝试了 ARIMA、GM(1,1)和 GM-ARIMA 回归模型，最终选择 GM-ARIMA 模型进行预测，结果显示其预测准确性更高。谢玉莹[21]（2023）运用 ARIMA-GARCH 模型预测中国股价波动，选择隆平高科收盘价指数进行分析，发现所选模型对时间序列拟合良好，显示出股票价格整体上升趋势，同时存在一定程度的波动，但总体风险较低。

2. 机器学习方法

近年来，随着机器学习技术的快速发展，有更多的学者将这种技术应用在股

中国知网 https://www.cnki.net

票市场预测中，促进了金融数据预测的进步。机器学习算法如支持向量机[22]（SVM）、随机森林[23]（Random Forest）和人工神经网络[24]（ANN）等，因其在数据处理和时间预测方面有较高的表现，成为学者常用的预测模型。在这一趋势中，丁宇昕[25]（2022）研究表明，经过数据预处理后的支持向量机（SVM）模型预测结果比原始数据建立的 SVM 模型更准确。与传统的 BP 神经网络和 ARIMA 模型相比，SVM 表现出更好的预测效果。林娜娜[26]（2018）的研究对 A 股股票涨跌进行了预测。通过相关性分析筛选指标体系，优化了随机森林模型的参数，并采用重要性估计方法提升了模型精确度。实证结果显示，随机森林模型优于传统的二元 logistic 回归模型，具有更高的预测准确度。杨易[27]分别用 LSTM, 支持向量机与 XGBoost 模型对白酒的股票价格做了预测研究，通过对比分析得出，LSTM 模型在预测白酒的股票价格表现最出色，同时得出 XGBoost 算法也可以对股票价格进行预测。此外，管健[28]（2023）用循环神经网络（RNN）和卷积神经网络（CNN）构建了复合预测模型，并将公众舆论和新闻信息加入到模型中，研究结果表明，他提出的复合模型在预测股票数据时具有较高的稳定性，给学者进行这方面研究提供了一定的参考价值。以上这些研究成果表明，机器学习算法在股票预测方面有巨大的应用价值，不仅丰富了股票市场分析的理论和方法,也为投资者进行股票市场分析提供了新的方法，有助于他们做出更好的投资决策。

3. 混合模型

为了提高对股票走势预测的准确性，一些学者尝试将不同的预测模型进行融合并进行预测。肖田田[29]（2024）提出了一种混合深度学习方法，通过将距离算法修改为动态时间归整（DTW），并结合 K-means-DTW 聚类算法，对价格趋势相似的证券进行聚类。然后，利用聚类数据训练 LSTM 模型，实现对单支股票价格的预测。结果显示，混合模型 K-means-LSTM 预测性能更优，其预测精度和稳定性均优于单一 LSTM 模型。孙娜等[30]（2023）提出 XGBoost 与 LSTM 组合的股票价格预测模型，结果表明多特征 LSTM 模型优于单特征预测，XGBoost-LSTM 预测模型效果优于多特征 LSTM 预测。曹玉贵[31]（2023）构建了 WD-CNN-LSTM 模型，通过小波阈值去噪、卷积神经网络特征提取和长短期人工神经网络模型处理，对股票价格进行预测。实验结果显示该模型在不同时间

中国知网 https://www.cnki.net

周期和不同类型的股票和股指上均具有良好的预测效果。张怡[32]（2022）为 LSTM 引入了注意力机制形成 AT-LSTM 模型，并将 ARIMA 的预测残差引入其中，进一步提高了预测精度。实验结果表明，ARIMA 和 AT-LSTM 组合模型的误差降低 4 倍，预测精度得到了显著提高。刘一舟[33]（2022）分别用 LSTM 模型、XGBoost 模型和 LSTM-XGBoost 组合模型对上证综合指数进行了预测，结果表明，LSTM-XGBoost 组合模型的预测效果比单一模型更好。刘宇婷[34]（2022）将深度双向长短期记忆网络(DBLSTM)与 ARIMA 模型结合起来对股票数据进行预测，研究结果表明，机器学习方法融合 ARIMA 模型后的预测效果比单一使用机器学习更好。李佳徽[35]（2023）分别建立了 ARIMA 模型、LS-SVR 模型以及遗传算法优化后的 LS-SVR 和 Markov 混合模型对股票价格进行预测，研究结果表明，遗传算法优化的 LS-SVR 和 Markov 混合模型的预测效果最好。这些研究表明，将不同类型的预测模型进行有效地结合，可以提高对股票预测的准确性。

4. 基于情感分析的预测

近年来，一些学者将情感分析融入到股票价格预测模型中，认为公众情绪和情感对股票价格的波动具有重要影响作用。因此，他们尝试从社交媒体和新闻报道中提取的情感分析数据,并将情感因子加入股票价格预测模型中，以期提高预测的准确性。宋丽娜[36]（2021）提出基于情感分析和 PCA-LSTM 模型对平安银行的股票数据进行预测研究，研究结果表明，加入情感分析可以提高股票预测的准确性。朱柳燕[37]（2021）提出将 LSTM 与新闻情感相结合对股票数据进行短期趋势预测，研究结果表明，融合的情感词典和改进的情感提取方法可以更准确地提取新闻中的情感，从而提高股票预测的准确性。

综上所述，国内学者在股票预测方面取得了一系列成就，对我们进行相关研究提供了很多思路和方法，通过分析他们进行股票预测研究的方法主要有，基于传统的时间序列方法，机器学习和神经网络技术，以及将这些方法进行融合使用，从他们最新研究的结果表明，通常下，混合模型比单一模型预测效果好，加入重要的变量，如市场情趣等指标可以提高股票预测的准确性。在股票预测方面，在未来，希望探索更好的方法对股票这种波动性很大的复杂非线性数据的处理，从而可以更有效的提高股票预测的准确性。

中国知网 https://www.cnki.net

1.3 论文结构

第一章 绪论：本章主要介绍了股票价格预测的研究背景和意义。通过对比分析国内外对股票价格预测所采用的主要方法和研究结果，基于此提出了本文对股票价格预测要采用的主要模型和，并指出了本文的创新点。

第二章中，首先对 ARIMA 模型基本原理和构建步骤进行了详细介绍。然后对模型进行了实证分析，包括对股票数据的稳定性检验、ARIMA 模型的识别和定阶、ARIMA 模型的诊断性检验，并对股票数据进行了预测。同时使用评价指标 MAE、RMSE 和 MAPE 对预测结果进行评估。

介绍了 BP 神经网络模型的基本理论，通过相关性分析结果选取了合适的输入指标，利用 python 寻找了最优参数并构建了 BP 模型。然后将选取的数据划分为训练集、测试集和验证集，用训练集数据对模型进行训练。将训练好的模型分别对测试集和验证集数据进行预测，同时使用评价指标 MAE、RMSE 和 MAPE 对预测结果进行评估。

第四章 介绍了 LSTM 神经网络模型的基本理论，通过相关性分析结果选取了合适的输入指标，利用 python 寻找了最优参数并构建了 LSTM 模型。然后将选取的数据划分为训练集、测试集和验证集，用训练集数据对模型进行训练。将训练好的模型分别对测试集和验证集数据进行预测，同时使用评价指标 MAE、RMSE 和 MAPE 对预测结果进行评估。最后将 ARIMA、BP 神经网络模型和 LSTM 神经网络模型的预测结果进行了对比分析。

第五章 ARIMA-BP-LSTM 组合模型预测：首先分别介绍了等权重法、加权平均法、等权重法和变权组合法的基本原理、适用情况、优势和局限性。然后用这三个方法对 ARIMA、BP 神经网络和 LSTM 神经网络模型进行了组合预测。最后使用评价指标 MAE、RMSE 和 MAPE 对三个组合模型的预测结果进行对比分析。

第六章 总结与展望：这里将本文预测研究的结果进行总结，并精简的对几个单一预测模型和组合预测模型的评价指标进行阐述，并将结果进行简要对比。根据本文的研究结果，对未来股票研究趋势进行简要说明。

中国知网 https://www.cnki.net

1.4 技术路线图

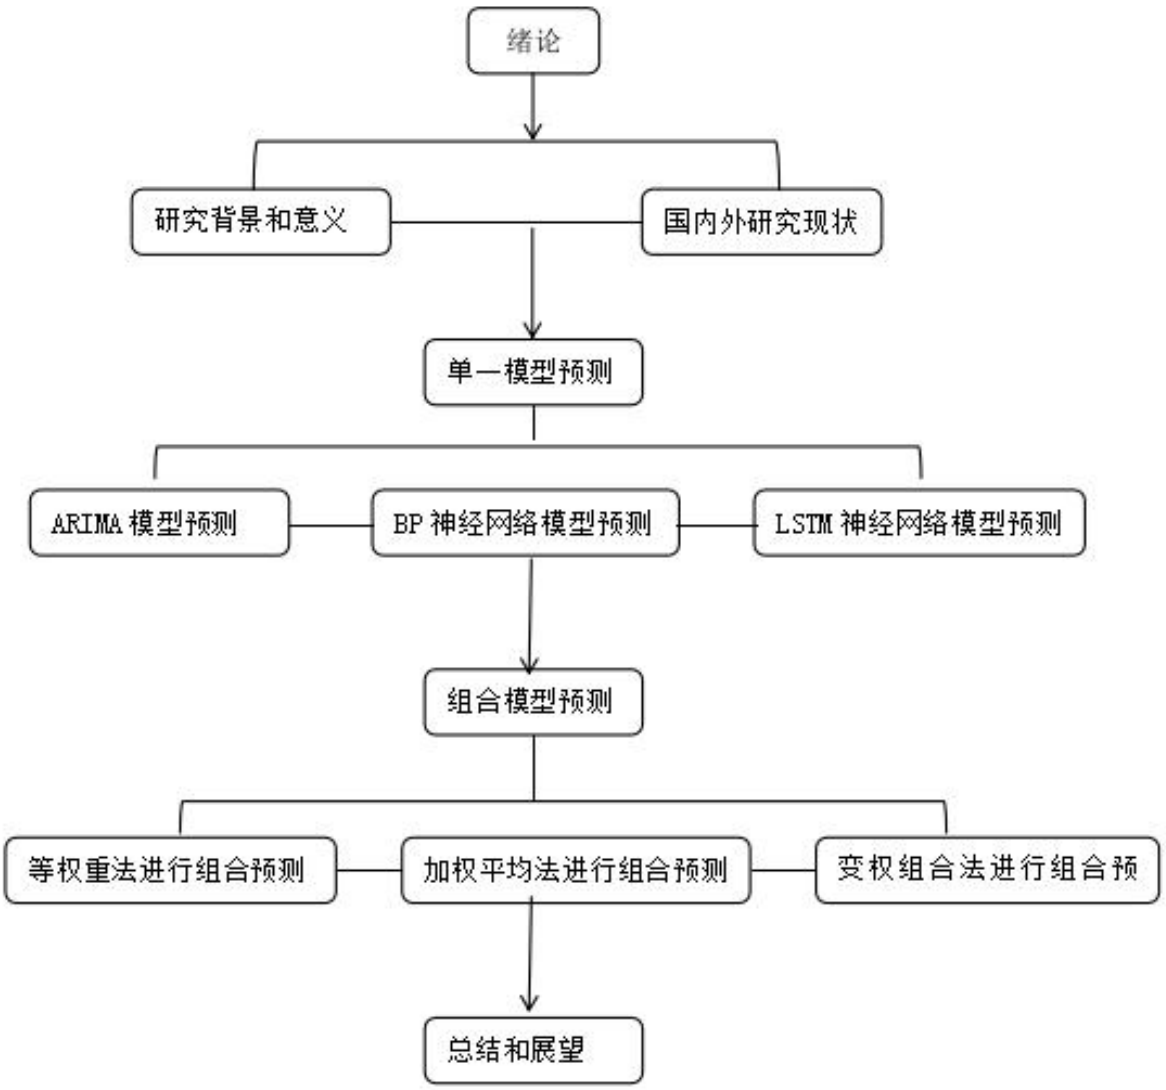

图 1-1 论文技术路线图

1.5 创新点

本文提出并且验证了一种结合 ARIMA、BP 神经网络和 LSTM 的组合预测模型，这种组合模型可以更为准确地预测中证 100 指数的收盘价，得出组合预测模型预测结果比单一模型效果更好，同时组合预测模型具有更强的稳定性。

本文选取的指标也是一个创新点。选取了收盘价、成交量、RSI、MOM、MAE、MACD、BIAS、ROC、GDP、CPI、收盘价的恐慌指数 VIX、AR、BR

中国知网 https://www.cnki.net

以及汇率共 14 个指标作为 BP 和 LSTM 神经网络模型的输入变量，为模型提供了更加可靠的数据支持。

中国知网 https://www.cnki.net

第二章 ARIMA 模型及预测分析

2.1 ARIMA 模型预测原理

2.1.1 ARIMA 模型

ARIMA 模型是一种用来预测时间序列数据的方法，通过结合自回归项、差分项和移动平均项来表示时间序列的观测值。它用用 ARIMA(p, d, q)的形式来表示，其中 p 代表自回归项的阶数，d 代表差分次数，而 q 代表移动平均项的阶数。

1. 自回归项（AR）：自回归项表示时间序列当前观测值与前 p 个滞后观测值之间的关系，可以用来捕捉时间序列的依赖性和趋势性。具有如下结构的模型称为 p 自回归模型，简称 AR（p）。

$$\begin{cases} x_t = \phi_0 + \phi_1 x_{t-1} + \phi_2 x_{t-2} + \cdots + \phi_p x_{t-p} + \varepsilon_t \\ \phi_p \neq 0 \\ E(x_t) = 0, Var(\varepsilon_t) = \delta_\varepsilon^2, E(\varepsilon_t \varepsilon_s) = 0, s \neq t \\ E(x_s \varepsilon_t) = 0, \forall s < t \end{cases} \tag{2.1}$$

其中，x_t 表示时间序列的当前观测值，$\phi_0, \phi_1, \phi_2, \cdots \phi_p$ 表示自回归系数，ε_t 表示误差项。

2. 差分项（I）：差分的主要目的时确保时间序列数据的稳定性。当时间序列中的数据表现出趋势性和季节性时，通过对时间序列数据进行一阶或多阶差分处理，可以消除它的趋势性和季节性的影响，让时间序列数据趋于平稳。用 I(d)表示，它的公式为：

$$I(d) = \Delta x_t = x_t - x_{t-d} \tag{2.2}$$

其中，Δx_t 表示时间序列的一阶差分，d 表示差分的阶数。

3. 移动平均项（MA）：这部分是用来捕捉时间序列数据的随机误差，在 ARIMA 模型中，通过将误差项的当前观测值与过去的观测值来实现的，可以帮助模型调整因自回归部分未能捕捉到的随机波动。模型假定误差项是独立同分布，并且误差项没有自相关性，用 MA(q)表示移动平均项,简记为 MA（q）:

中国知网 https://www.cnki.net

$$\begin{cases} x_t = \mu + \varepsilon_t - \theta_1\varepsilon_{t-1} - \theta_2\varepsilon_{t-2} - \cdots - \theta_q\varepsilon_{t-q} \\ \theta_q \neq 0 \\ E(\varepsilon_t) = 0, Var(\varepsilon_t) = \delta_\varepsilon^2, E(\varepsilon_t\varepsilon_s) = 0, s \neq t \end{cases} \tag{2.3}$$

其中，ε_t 表示误差项，$\theta_1, \theta_2, \cdots \theta_q$ 表示移动平均系数。

ARIMA 模型通过对上述三种项的组合得到，即:

$$ARIMA(p, d, q) = AR(p) + I(d) + MA(q) \tag{2.4}$$

ARIMA 模型对时间序列数据进行预测分析，可以让我们对这类数据有更充分的认识，了解到它的趋势以及周期规律变化等，根据时间序列数据的特点，对它的自回归项、差分和移动平均项选择合适的阶数。在实际预测中，ARIMA 模型阶数的确定是通过对自相关函数（ACF）和偏自相关函数（PACF）图表分析得出，有时也会借鉴信息准则（如 AIC、BIC）帮助我们选择最合适的阶数。在阶数确定后，使用专门的统计软件进行 ARIMA 模型的预测分析，比如，使用 Python 中的 statsmodels 库，这些工具可以有效地帮助我们对时间序列数据进行处理，并从中得到有价值的信息。

2.1.2 构建 ARIMA 模型

构建 ARIMA 模型首先需要对时间序列数据进行收集、清洗和预处理，确保相关数据的完整性和一致性。接下来对数据进行基本分析，通过时间序列数据进行可视化和描述性统计分析，识别出数据的趋势性、季节性和周期性等特征。当数据显示出趋势性或季节性的时候，需要通过差分处理使其变的平稳。ARIMA 模型的阶数（p, d, q）是用自相关图（ACF）和偏自相关图（PACF）的特征进行确定的。ARIMA 模型阶数确定后，使用最大似然估计法模型参数进行估计。接着对模型进行相关诊断，包括残差分析，确保模型可以更好地对时间序列数据进行预测。最后，使用构建好的 ARIMA 模型对时间序列数据进行预测。整个过程可以借助 Python 中的 statsmodels 库来实现。

（一） 平稳性检验

平稳性检验是 ARIMA 模型建立过程中的一个重要步骤，它主要是为了满足时间序列数据是平稳性的这一基本假设，即需要预测的时间序列数据的均值和方差保持不变，不随时间的变动而表现出一定的波动和趋势性。常见的平稳性检验方法包括可视化检验、原假设检验以及统计量检验。可视化检验主要通过时间序

中国知网 https://www.cnki.net

列的图表来观察它的趋势和周期性，所用的图主要有折线图、自相关图（ACF）和偏自相关图（PACF），原假设检验方法，如 ADF 检验和 KPSS 检验，ADF 检验是通过确定时间序列数据是否存在单位根，即序列数据是否具有非平稳的趋势。而 KPSS 检验是确定数据是否平稳，如果拒绝原假设，表明数据是平稳的。而统计量检验，如 DF（Dickey-Fuller）检验，它的原假设是时间序列数据存在单位根，即数据是非平稳的，当 DF 检验的统计量小于临界值时，就拒绝原假设，此时数据是平稳的。平稳性检验的这些方法是确定是否要通过差分处理让数据变得平稳，满足 ARIMA 模型的平稳性要求，如果数据是非平稳的，就需要进行差分处理满足平稳性要求后在用 ARIMA 模型对数据进行拟合和预测。

（二）ARIMA 的识别与定阶

ARIMA 模型的识别和定阶是时间序列分析中很重要的一个环节，它主要包括判断时间序列是否符合 ARIMA 模型的要求、选择合适的模型参数（p 和 q）以及是否加入季节效应到 ARIMA 模型中。首先，通过观察时间序列的自相关函数（ACF）和偏自相关函数（PACF），就可以得出时间序列是否平稳，确定它是否适用 ARIMA 模型进行预测。接着，根据 ACF 和 PACF 图表选择自回归项（AR）的阶数 p 和移动平均项（MA）的阶数 q，通过比较模型不同阶数的赤池信息准则（AIC）或贝叶斯信息准则（BIC）来确定模型最佳的阶数 p 和 q。如果时间序列呈现出明显的季节性特征，需要进一步确定时间序列的季节效应。在确定 ARIMA 模型的阶数后，需要用最小二乘法来估计模型相关参数，最后需要用残差分析和白噪声检验来确定模型的有效性，确保模型可以有效地反应数据特征。

（三） ARIMA 预测

ARIMA 模型的预测主要是用已经拟合好后的模型对未来一定时间的数据进行预测。在预测前需要对数据进行一定的处理，包括对时间序列数据收集和预处理。然后，使用时间序列的历史数据对 ARIMA 模型模型进行拟合，并利用 Python 中的 statsmodels 库对模型的参数进行估计。对于拟合好的模型，需要检验模型预测的稳定性和准确性，选取一部分历史数据对模型的效果进行验证，通过对预测结果的误差来评价模型的准确性。之后需要对模型进行预测，在确定需要预测出的观测值个数后，从最后一个观测值开始，进行逐步预测，同时要考虑残差和

中国知网 https://www.cnki.net

误差的影响。最后，通过预测结果与实际观测值计算出评价指标，如均方根误差（RMSE）、平均绝对误差（MAE）等，来评估模型预测的准确。

ARIMA 模型的预测结果是根据已有的历史数据和模型估计得出的，对于未来发生的外部因素的影响无法得到预测，因此，在进行预测时需要考虑其他影响时间序列数据未来走势下因素。

2.1.3 ARIMA 模型的优缺点

ARIMA 模型的优势是它能够有效地捕捉时间序列数据中的趋势性，对规律性较强的数据进行预测，具有较好的效果，此外，ARIMA 模型是通过对历史数据进行建模，预测出的结果具有很好的解释性，从而更好的发现时间序列数据的变化规律。然而，ARIMA 模型也存在局限性。首先，它对数据的异常值比较敏感，容易被噪声感染；要求需要预测的时间序列数据必须是平稳的，在实际预测中，遇到的时间序列数据通常是非平稳的，如金融类的时间序列数据，这就需要对他进行差分处理；ARIMA 模型在处理非线性关系的数据时表现差强人意。因此，在预测非线性时间序列时，ARIMA 模型可以结合其他模型进行预测可以提供对时间序列数据预测的准确性。

2.2 模型的评价指标

在对中证 100 指数预测结果的分析中，通过评价指标可以更好地对比分析出不同模型预测效果的优劣，本文主要用到的评价指标有：平均绝对误差（MAE）、均方根误差（RMSE）和平均绝对百分比误差（MAPE）。下面是对这的详细介绍。

（一） MAE（Mean Absolute Error）

MAE（平均绝对误差）是评价预测值与实际值准确率的指标，通过平均绝对误差可以直观地了解预测准确性。它的计算公式为：

$$MAE = \frac{1}{\mathrm{n}}\sum_{i=1}^{n}\left|(y_i - \hat{y}_i)\right| \tag{2.5}$$

其中，n 表示样本数量，y_i 是真实值，$\hat{y}_i$ 是对应的预测值。

MAE 的特点是它把所有的误差通过绝对值形式相加，避免了误差相互抵消的问题。但它也存在一定的局限性。对误差大的预测结果不太敏感，平均绝对误

中国知网 https://www.cnki.net

差不涉及平方处理，无法反应极端值对总体预测准确性的影响。

（二） RMSE（Root Mean Square Error）

RMSE（Root Mean Square Error，均方根误差）是一种常用的评价指标，用来对模型预测结果的准确性进行评价。它是对每个样本的预测误差进行平方，然后求平均后开平方根。对于样本量为 n 的数据集，RMSE 的计算公式如下：

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{2.6}$$

其中，y_i 是真实值，$\hat{y}_i$ 是对应的预测值。

RMSE 对于预测误差大的值给予较高的权重，用它对预测模型评价时对于大的误差更加敏感，因此，对于比较关注大的误差的预测模型来说，这个评价指标就很适用，它可以较好地描述预测结果的波动性。然而，由于它对数据中的离群值比较敏感，这也会导致评价指标出现一定的偏差。相比平均绝对误差（MAE），因为涉及平方处理，使得它比较难解释。在实际预测中，当大的误差对于决策比较重要时，RMSE 可以提供重要的参考价值。当数据中有大量的异常值或离群值时，仅参考 RMSE 效果不佳，这时需要结合其他评价指标进行综合判断，从而确保得出正确的结论。

（三）MAPE（Mean Absolute Percentage Error）

平均绝对百分比误差（MAPE）是预测结果准确性的重要值，它将预测值与实际值之间的误差转化为相对误差的百分比来衡量。计算公式如下：

$$MAPE = \frac{1}{\mathrm{n}}\sum_{i=1}^{n}\left|\left(\frac{y_i - \hat{y}_i}{y_i}\right)\right| \tag{2.7}$$

这个评价指标的主要优点它对预测误差的表现更加直接，解释下更强，即预测误差占实际值的比重大小。然而，MAPE 指标也存在它的局限性，当实际值接近或等于零时，MAPE 指标的参考价值可能不是很大，此外，当预测误差本身很小的时候，MAPE 指标可能无法很好地反应预测误差。尽管 MAPE 指标存在一定地局限性，但它可以很好地反应误差占实际值地百分比，结合其他评价指标可以多方面的对模型的预测误差进行评估。

中国知网 https://www.cnki.net

2.3 ARIMA 模型预测分析

本章使用 ARIMA 模型对中证 100 指数的收盘价进行预测。选取了 2015 年 1 月 1 日至 2023 年 5 月 30 日的收盘价作为模型的拟合数据，通过拟合数据训练好的 ARIMA 模型预测 2023 年 6 月共 20 天的收盘价。并用评价指标 MAE、RMSE 和 MAPE 衡量模型的预测准确性。

2.3.1ARIMA 模型的预测过程

（一） 平稳性检验

对中证 100 指数做单位根（ADF）检验，ADF 检验如表 2-1 所示.

表 2-1 中证 100 指数原始数据的 ADF 检验

Augmented Dickey-Fuller Test	
Test Statistic	0.2645
p-value	0.2645

由表 2-1 可知，ADF 检验的 P-Value=0.2645> 0.05，存在单位根，认为中证 100 指数原始序列数据是非平稳的序列。需要做平稳化处理，对原始数据进行一阶差分，得到序列 diff1，并检验 diff1 的平稳性，diff1 的时序图以及 ADF 检验的结果如图 2-1 和表 2-2 所示：

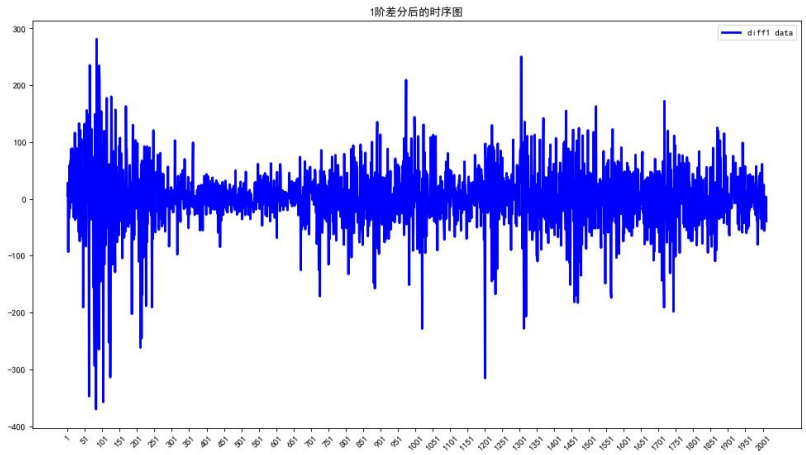

图 2-1 一阶差分时序图

表 2-2 中证 100 指数一阶差分的 ADF 检验

Augmented Dickey-Fuller Test	
Test Statistic	7.594e-15
p-value	7.594e-15

中国知网 https://www.cnki.net

由图 2-1 可知一阶差分数据序列基本平稳， ADF 检验得到的 P-Valu< 0.05 ，可知，一阶差分后的序列 diff1 已经平稳，故取 d=1。

（二） 模型定阶

对经过一阶差分后的序列 diff1，画出其自相关图（ACF）及偏自相关图（PACF）如图 2-2 和图 2-3 所示：

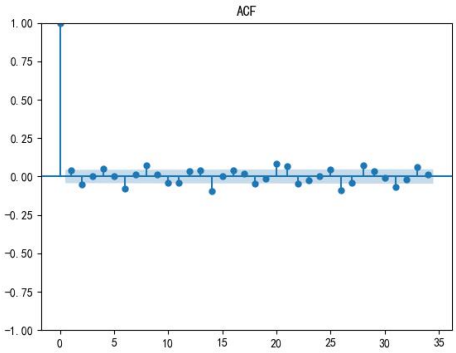

图 2-2 一阶差分序列的自相关图

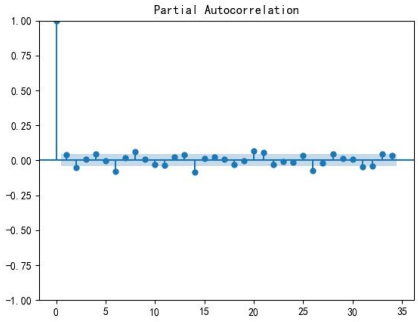

图 2-3 一阶差分序列的偏自相关图

由图 2-2 和图 2-3 可知，p 和 q 可能的取值分别为 p=0,2,4,6，q=0,2,4,6，同时根据模型的参数显著性检验，将这些 p、d 和 q 待人模型 ARIMA,并算出 AIC,结果如表 2-3 所示。

表2-3 各 ARIMA 模型的AIC值

ARIMA 模型	AIC 值	ARIMA 模型	AIC 值
ARIMA(0, 1, 0)	21985.65497	ARIMA(2, 1, 0)	21980.90893
ARIMA(0, 1, 1)	21983.81747	ARIMA(2, 1, 1)	21982.89368
ARIMA(0, 1, 2)	21981.33629	ARIMA(2, 1, 2)	21940.19223
ARIMA(0, 1, 3)	21983.3132	ARIMA(2, 1, 3)	21934.02798
ARIMA(1, 1, 0)	21984.20425	ARIMA(3, 1, 0)	21982.86584

中国知网 https://www.cnki.net

ARIMA(1, 1, 1)	21983.43636	ARIMA(3, 1, 1)	21984.24196
ARIMA(1, 1, 2)	21984.91118	ARIMA(3, 1, 2)	21933.59215
ARIMA(1, 1, 3)	21985.65497	ARIMA(3, 1, 3)	21935.77894

通过 AIC 最小准则,以及系数的显著性来确定阶数。从表中可以看出，在所选择的模型中，ARIMA(3,1,2)模型的 AIC 为 21933.59，是所有模型中最小的，根据 AIC 最小准则，选择 ARIMA(3,1,2)模型预测中证 100 指数收盘价。接着，利用极大似然估计对模型参数进行估计，ARIMA(3,1,2)模型系数的估计值和置信区间以及检验的 P 值如表 2-4 所示：

表2-4 ARIMA(3,1,2)各参数估计值和显著性检验

	coef	std err	t 值	P-value	95%置信下限	95%置信上限
ar.L1	0.1831	0.022	8.268	0.000	0.140	0.226
ar.L2	-0.9665	0.011	-91.492	0.000	-0.987	-0.946
ar.L3	0.0706	0.016	4.333	0.000	0.039	0.103
ma.L1	-0.1399	0.016	-8.651	0.000	-0.172	-0.108
ma.L2	0.9209	0.016	59.285	0.000	0.890	0.951

由表 2-4 可知，ARIMA(3,1,2)模型各参数对应的 P-value 都小于 0.05，说明各参数均显著，确定模型为 ARIMA(3,1,2)，这个模型显示了非常令人满意的检验结果，所有的系数都非常显著地不同于零（即 p 值都为 0）。这表明了模型的有用性和指示了模型对数据的很好拟合。将估计的参数代入到模型表达式中得到：

$$(1\text{-}B)X_t = \frac{(1+0.1399B-0.920*B^2)\varepsilon_t}{1-0.1831B+0.9665B^2-0.0706B^2} \qquad (2.8)$$

通过ARIMA模型拟合得到的系数表明，当前的观测值与过去三期的观测值，以及过去两期的预测误差相关。这表明了模型捕捉到了数据的滞后性和趋势，从而能够进行较为准确的预测。同时，非常低的 p 值也表明了模型的高显著性和可靠性。总体来说，这个模型表现出了非常好的拟合效果和预测能力，这为您对证券市场的指数进行预测提供了一个可靠和有效的工具。

（三） ARIMA 模型的诊断检验

上文中，建立的 ARIMA(3,1,2)模型，还需对模型的有效性进行检验，通过分析残差的序列图和 QQ 图来检验，只有检验通过，才能利用该模型进行预测。

中国知网 https://www.cnki.net

画出残差的时序图和 QQ 图，如图 2-4 和图 2-5 所示：

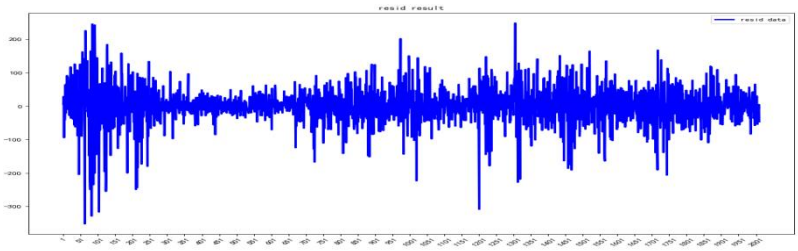

图 2-4 ARIMA(3,1,2)模型残差时序图

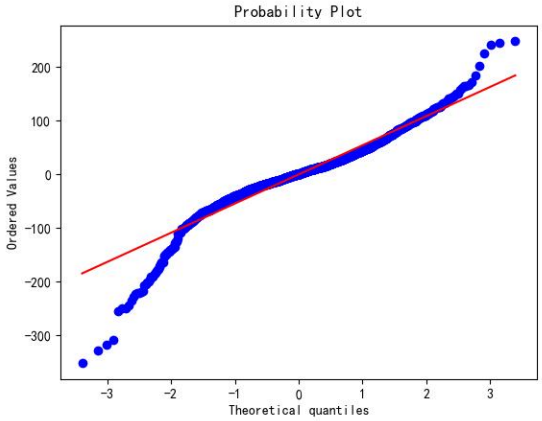

图 2-5 ARIMA(3,1,2)模型残差 QQ 图

图中证 100 指数 ARIMA(3,1,2)模型残差时序图和 QQ 检验图可知，残差序列是白噪声序列。综上所述，建立的 ARIMA(3,1,2)模型是可行的，可以用于预测中证 100 指数的收盘价。

2.3.2ARIMA 模型的预测结果

通过建立的 ARIMA(3,1,2)模型对中证指数 2023 年 6 月份的数据进行预测，并与实际值进行对比，预测结果的评价指标 MAE、RMSE 和 MAPE 分别是 62.88、77.31 和 1.61。如表 3-5 所示，是预测的的真实值和预测值。

表 2-5 预测结果的预测值和相对误差

时间	真实值	预测值	相对误差	时间	真实值	预测值	相对误差
2023/6/1	3806.87	3797.46	0.25%	2023/6/15	3925.5	3790.13	3.45%
2023/6/2	3861.83	3792.23	1.80%	2023/6/16	3963.35	3792.50	4.31%
2023/6/5	3844.25	3789.55	1.42%	2023/6/19	3930.91	3796.36	3.42%

中国知网 https://www.cnki.net

2023/6/6	3808.16	3794.03	0.37%	2023/6/20	3924.24	3794.51	3.31%
2023/6/7	3789.34	3797.08	0.20%	2023/6/21	3864.03	3790.61	1.90%
2023/6/8	3820.19	3793.11	0.71%	2023/6/26	3809.7	3791.95	0.47%
2023/6/9	3836.7	3789.76	1.22%	2023/6/27	3845.43	3795.84	1.29%
2023/6/12	3844.43	3793.20	1.33%	2023/6/28	3840.8	3794.97	1.19%
2023/6/13	3864.91	3796.79	1.76%	2023/6/29	3821.84	3791.16	0.80%
2023/6/14	3864.02	3793.89	1.82%	2023/6/30	3842.45	3791.56	1.32%

如表 2-5 所示，ARIMA 模型对中证 100 指数的预测表现挺出色，大多数预测值与真实值之间的相对误差在 2%以内，也有很多预测数据在 1%左右。此外，它的评价指标 MAE、RMSE 和 MAPE 分别是 62.89、77.31 和 1.62。从这些指标可以看出 ARIMA 模型对股票的短期预测具有较高的准确性，其中预测结果的 MAE 和 RMSE 可以看出预测误差比较低，而 MAPE 的值表明了模型对股票数据的相对误差控制在较小的范围内。通过 ARIMA 模型对中证 100 指数的预测，结果显著，可以为股票投资者提供一定的参考价值，帮助他们做出合理的决策。

中国知网 https://www.cnki.net

第三章 BP 神经网络模型及预测分析

3.1 BP 神经网络模型预测原理

（一） BP 神经网络模型原理

BP 神经网络(反向传播神经网络)，是深度学习中一种常用的方法，在数据预测方面被广发进行使用，用于训练前向反馈神经网络。这个网络是由一个输入层，至少一个隐藏层和一个输出层组成，而每一层是由多个神经元组成，这些神经元是通过加权链接互相地信息。在前向传播中，输入数据在网络中向前进行流动，每个神经元接受到上一个神经元的输出作为输入，计算出它的加权和为 $\sum(w_i x_i)+b$，并通过激活函数如 ReLU 或 Sigmoid 产生输入到下一层。选择激活函数主要是为了让网络能够学习数据间的关系。网络生成的最终结果要通过损失函数与真实值进行比较，计算出预测误差。

误差反向传播是 BP 神经网络的核心思想，目的是通过误差最小化调整网络权重 w 和偏置 b。具体而言，它是利用链式法则计算损失函数关于每个权重的梯度 $\frac{\partial L}{\partial \mathrm{w}}$ 和关于每个偏置的梯度 ，$\frac{\partial L}{\partial \mathrm{b}}$ 然后根据这些 梯度和给定的学习率 η，然后按着 $w=w-\eta\frac{\partial L}{\partial w}$ 和 $b=b-\eta\frac{\partial L}{\partial b}$ 更新网络的权重和偏置，这个过程可以让网络进行逐步调整，降低输出值跟真实值之间的误差。

在迭代训练中，BP 神经网络通过不断进行前向传播和反向传播，利用不断优化的权重和偏置降低损失函数值，从而提高 BP 神经网络在训练数据上的拟合效果。当模型训练达到了给定的迭代次数或设定的误差阈值，网络训练过程结束。这种方法可以更好地让学习到输入数据和输出数据简的关系，可以处理各种复杂的数据类型。

（二） BP 神经网络的训练步骤

BP 神经网络模型的训练步骤遵循严格的序列，确保在迭代过程中让模型得到不断优化。模型的训练主要分为训练准备阶段、训练与反向传播阶段和迭代优化与模型评估阶段。

（1）在训练准备阶段中，将收集好的相关数据进行预处理，然后把数据分

中国知网 https://www.cnki.net

为特征向量和真实值，特征向量是模型训练的输入值，之后需要对模型的权重W和偏置进行初始化，权重和偏置一般会从正太分布中随机选取。

（2）在训练与反向传播阶段中的前向传播，输入数据需要经过多层计算得出输出，在每一层中，神经元的输出O由输入x、权重W、偏置b和激活函数f计算得到：

$$O = f(W \bullet x + b) \tag{3.1}$$

接着，用损失函数L计算输出与真实值之间的误差。若用均方误差，损失函数的计算公式为：

$$L = \frac{1}{2}\sum(y_{pre} - y_{ture})^2 \tag{3.2}$$

其中y_{pre}是模型预测的标签，y_{ture}是真实的标签。

在反向传播中，损失函数关于权重的梯度通过链式法则计算，用于更新权重：$\frac{\partial L}{\partial \mathrm{w}}$

更新权重W和偏置b的规则由学习率η和计算得到的梯度决定：

$$W_{new} = W_{old} - \eta\frac{\partial L}{\partial w} \tag{3.3}$$

$$b_{new} = b_{old} - \eta\frac{\partial L}{\partial b} \tag{3.4}$$

（3）在迭代优化与模型评估阶段中，重复进行前面的这个过程，每次迭代都会更新网络的权重和偏置，减少损失函数的值。通过设置迭代次数和调整学习率等超参数，模型被不断调整至优化。最终，将训练好的模型进行数据预测，并通过预测值和真实值计算出相关的评价指标来评价模型预测的优劣。

（三） BP 神经网络模型的优势与不足

BP 神经网络模型,由于它的反向传播算法的核心思想，成为深度学习中的重要代表，调整网络内部参数可以有效降低输出值的误差，在非线性的复杂数据处理方面具有较强的优势。对输入变量进行自动提取数据特征，减少了人工干预下情况，通过网络自动学习有效的信息，此外，BP 网络可以根据不同的数据处理情况调整它的结构，具有较好的泛化能力。

中国知网 https://www.cnki.net

然而，BP 神经网络在训练的过程中存在着一定的挑战。比如梯度消失或爆炸问题在模型训练的过程中也时常发生，这会降低模型的训练效率，导致训练过程出现不稳定。此外，在数据量比较少或着输入变量的维度较高时，训练的模型很可能存在过拟合的情况，这时就需要用正则化、dropout 等技术来缓解。

尽管 BP 神经网络存在着一定的局限性，在对比较复杂的数据进行处理的时，经常被人们使用。随着深度学习技术的发展，提出的一些方法可以克服这些不足，从而提高了模型的性能和稳定性。

3.2 数据来源及指标选取

（一） 数据来源

本文选取了中证 100 指数 2015 年 01 月 01 日至 2023 年 6 月 30 日（除节假日外）共 2065 天的数据，其中收盘价、开盘价、最高价、最低价、成交量和成交金额使用 python 从聚宽数据平台获取，国内生产总值（GDP）和消费者物价指数(CPI)是从国家统计局获取，汇率是从中经网中下载的，KDJ、相对强弱指数（RSI）、均线（MA5 和 MA10）、MOM、MACD、BIAS、ROC 以及投资者的情绪指标 AR 和 BR 是通过相关公式用 python 算出来的，以下是这些指标的相关说明

（1）国内生产总值（GDP）是衡量一个国家或地区经济规模和增长速度的重要指标。

（2）消费者物价指数（CPI）常用来衡量通货膨胀的水平。

（3）KDJ 指标用于衡量股票价格未来走势的强弱和买卖信号。KDJ 指标包括三条曲线：K 线、D 线和 J 线。它是根据最高价、最低价和收盘价的比率计算得出的。计算公式如下：

计算 K 值：

$$K = \frac{100 \times (close_{new} - \min_{close})}{\max_{close} - \min_{close}} \tag{3.5}$$

其中，n 为设定的参数，代表天数，$close_{new}$ 代表最新收盘价，$\max_{close}$ 代表 n 日内最高价，$\min_{close}$ 代表 n 日内最低价，

计算 D 值：

中国知网 https://www.cnki.net

$$D = M \times K + (N-1) \times D_{昨天} \tag{3.6}$$

其中，M 和 N 分别是平滑因子，一般取 2 和 3。

计算 J 值：

$$J = 3 \times D - 2 \times K \tag{3.7}$$

KDJ 指标常用于表示股票的超买和超卖信号，通过分析 K、D、J 线的走势，可以帮助投资者更好地判断股票的买卖时机。当 K 值大于 80，表示超买；当 K 值小于 20，表示超卖。

（4）相对强弱指数（RSI）用于衡量公司的股票在一定时间内的变动情况。RSI 的计算基于股票的收盘价，通常使用 14 天的周期来计算。计算公式如下：

$$RSI = 100 - \frac{100}{1 + RSI_RS} \tag{3.8}$$

其中，RSI_RS 是相对强弱值，可以通过以下公式计算：

$$RSI_RS = \frac{100}{1 + 平均涨幅 / 平均跌幅} \tag{3.9}$$

RSI 的取值范围在 0 到 100 之间。通常，RSI 值在 70 以上表示市场处于超买状态，价格可能会下跌；RSI 值在 30 以下表示市场处于超卖状态，价格可能会上涨。

(5) 均线（MA）用于衡量股票价格的平均趋势。它是一种平滑指标，通过计算一段时间内的收盘价平均值，来反映股票价格的趋势。均线的计算公式如下：

$$MA = \frac{C_1 + C_2 + \cdots + C_n}{n} \tag{3.10}$$

其中，MA 代表均线，$C_1, C_2, \cdots, C_n$ 是股票收盘价序列，n 是计算均线的时间周期。常见的均线周期有 5 日、10 日、20 日、50 日等。一般来说，短期的均线更能反映股票价格的短期波动，而长期的均线更能反映股票价格的长期趋势。

(6)MOM 用于衡量股票价格变动的速度和幅度。它通过比较当前时间点和一段时间前的价格来观察价格的变化情况。公式如下：

$$MOM = close - close_n \tag{3.11}$$

其中，n 代表选取的时间周期，$close$ 代表当日收盘价，$close_n$ 代表 n 日前收

中国知网 https://www.cnki.net

盘价。

MOM 指标的数值表示价格的增长量或减小量。当 MOM 为正值时表示股票价格上涨的动能正在增强，为负值时表示价格下跌的动能增强。通常将 MOM 值进行移动平均处理来减少噪音，更好地捕捉价格变化的趋势。

（7）指数平滑移动平均线（Moving Average Convergence Divergence，MACD）用于衡量股票价格趋势和价格动能的变化。MACD 由快速线(DIF)和慢速线(DEA)组成。计算 MACD 的步骤如下：

$$DIF = EMA_{12} - EMA_{26} \tag{3.12}$$

其中 EMA 代表指数加权移动平均线。

$$DEA = DEA_{\text{前1天}} \times \frac{8}{10} + DIF_{\text{当日}} \times \frac{2}{10} \tag{3.13}$$

通常 9 日为一个较为常见的采用天数。

$$MACD = (DIF - DEA) \times 2 \tag{3.14}$$

MACD 通常用于捕捉股票价格的快速动能变化和趋势的转折点。作为预测中证 100 指数的输入变量，MACD 可以提供有关价格趋势和动能的信息。通过分析 MACD 指标的走势，投资者可以研判中证 100 指数未来价格的发展趋势和可能的买卖信号。

（8）乖离率（BIAS）用于衡量股票价格与其移动平均线之间的偏离程度。它可以帮助投资者判断股票价格偏离均值的程度。计算 BIAS 的步骤如下：

$$BIAS = \frac{Close - MA(N)}{MA(N)} \times 100\% \tag{3.15}$$

其中，Close 代表股票的收盘价，MA(N)代表选择的移动平均线的数值，通常选取 6 日、12 日和 24 日的移动平均值。

当 BIAS 为正值时，表示股价偏离均值上方；当 BIAS 为负值时，表示股价偏离均值下方。

（9）变动率指标（ROC）用于衡量价格变动的速度和幅度。它帮助投资者判断股票价格变动的幅度，从而预测价格趋势。ROC 的计算公式如下：

$$ROC = \frac{Close - Close_n}{Close_n} \times 100\% \tag{3.16}$$

中国知网 https://www.cnki.net

其中，$Close$ 代表当前周期的收盘价，$Close_n$ 代表 n 个周期前的收盘价。ROC 可以帮助投资者观察价格的变动幅度，从而判断趋势的强度。当 ROC 值为正时，表示股价上涨的速度大于 n 个周期前的速度；当 ROC 值为负时，表示股价下跌

（10）情绪指标(BRAR)也称为人气意愿指标，由人气指标(AR)和意愿指标(BR)两个指标构成。AR 指标和 BR 指标都是以分析历史股价为手段的技术指标。

情绪指标 AR（Asymmetry Ratio）AR 指标是通过比较一段周期内的开盘价在该周期价格中的高低。从而反映市场买卖人气的技术指标。计算公式为:

$$AR_N = \frac{\sum_{i=1}^{N}(H_i - O_i)}{\sum_{i=1}^{N}(O_i - L_i)} \times 100 \qquad (3.17),$$

其中，H 为当日最高价，L 为当日最低价，O 为当日收盘价，N 为设定的时间参数，一般原始参数日设定为 26 日

BR 指标是通过比较一段周期内的收盘价在该周期价格波动中的地位，来反映市场买卖意愿程度的技术指标。其计算公式为：

$$BR_N = \frac{\sum_{i=1}^{N}(H_i - Close_{前一日})}{\sum_{i=1}^{N}(Close_{前一日} - L_i)} \times 100 \qquad （3.18）$$

其中，H 为当日最高价，L 为当日最低价，$Close_{前一日}$ 为前一交易日的收盘价，N 为设定的时间参数，一般原始参数日设定为 26 日

（11）恐慌指数 VIX 是一种衡量市场波动和恐慌情绪程度的指标。VIX 指数的数值越高，意味着市场的波动性和不确定性越大。

（12）对于中证 100 指数进行预测时，汇率可以作为一个重要的输入变量，为投资者提供了对整体经济环境和市场情绪的一种参考。

（二） 指标选取

本文中，ARIMA 模型的输入变量仅为中证 100 指数的收盘价，而对于 BP 神经网络模型和 LSTM 神经网络模型就需要对输入的变量进行相关性分析，选取合适的变量作为模型的输入值，相关性分析结果如图 3-1 所示。

中国知网 https://www.cnki.net

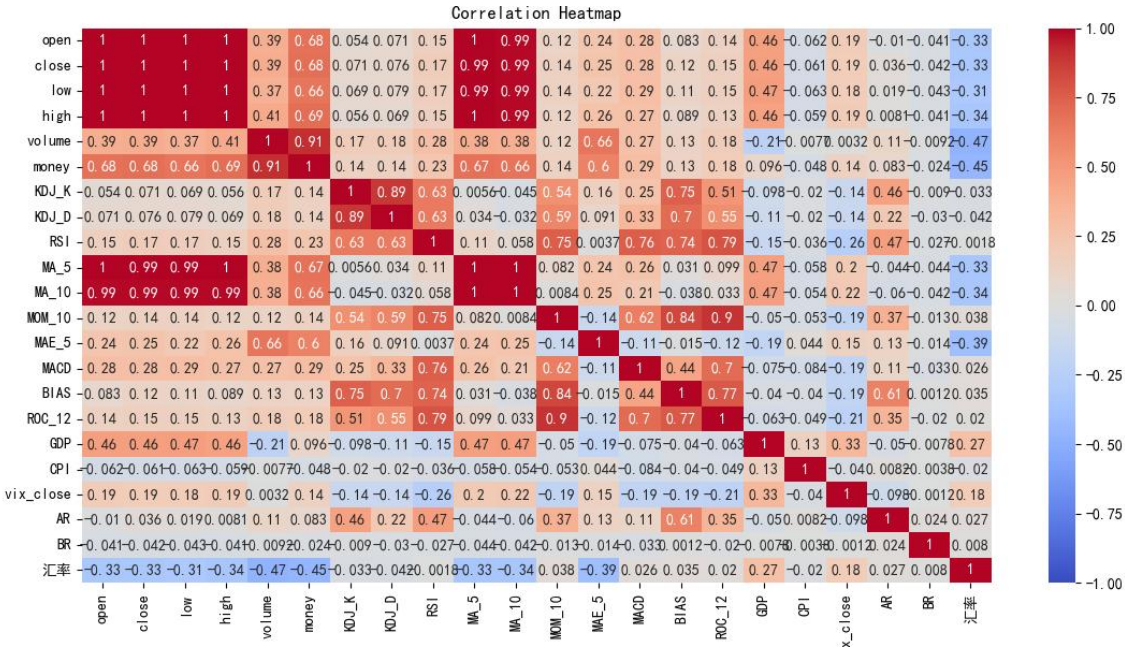

图 3-1 变量指标之间的相关分析图

因此模型输入变量选择为：收盘价（close）、成交量（volume）、RSI、MOM_10、MAE_5、MACD、BIAS、ROC_12、GDP、CPI、收盘价的恐慌指数 VIX,、AR、BR 以及汇率共 14 个指标。

3.3 BP 神经网络模型模型预测分析

3.3.1 构建 BP 模型

确定神经网络的层数和每层的神经元个数。一般来说，对于简单的问题，可以选择较少的层。用 BP 神经网络进行预测时，需要对模型的网络层数、隐藏层的节点数和初始参数进行确定，这些对模型的预测性能具有重要影响作用。

（一） BP 模型层数的确定

本文选用常见的三层 BP 神经网络结构。同时设定 14 个输入层节点，即 14 个神经元。输入参数分别为收盘价（close）、成交量（volume）、RSI、MOM_10、MAE_5、MACD、BIAS、ROC_12、GDP、CPI、收盘价的恐慌指数 VIX,、AR、BR 以及汇率共 14 个指标。

（二） BP 模型隐藏层节点的确定

在对进行确定 BP 神经网络的隐藏层节点数之前，需要理解隐藏层节点数对神经网络性能具有重要影响的影响作用。它直接影响着神经网络的学习能力和泛化能力。当隐藏层节点数较少时，可能无法捕捉到数据中的所有有效特征，

中国知网 https://www.cnki.net

将会导致模型出现欠拟合的情况；当隐藏层节点数较多时，很可能会导致模型出现过拟合情况，即网络不仅学习到了数据的所有特征，还学习到了噪声，这会降低模型的泛化能力。因此，确定一个合适的隐藏层节点数对于构建神经网络十分的重要。为了确定最优的隐藏层节点数，可以借鉴经验公式，

$$N=\sqrt{S+C}+A \tag{3.19}$$

其中，N 为隐藏层节点数目，S 为输入层节点数目，C 为输出层节点数目，A 为[1,10]区间的常数。根据公式可知，隐藏层的节点可以取 4，5，6，7，8，9，10，11，12，13，然后用交叉验证法确定最佳的隐藏层节点数。

交叉验证可以更好地帮助我们确定神经网络隐藏层节点数。它通过对数据进行分割并进行多轮训练和测试，通过交叉验证可以比较不同隐藏节点数的模型预测效果。在这个过程中，使用均方根误差（RMSE）来确定模型的预测效果，通过迭代的这种方式找到最佳的隐藏层节点数。这样既可以避免模型出现欠拟合，也能避免对训练数据出现过度拟合的情况，从而提高模型的预测能力。

使用 pyhon 代码对可能取的隐藏节点数进行交叉验证，结果显示当隐藏节点数为 13 时，该神经网络模型预测的误差最小即建立了一个隐含层神经元数目为 13 的 3 层网络结构的 BP 神经网络对中证 100 指数的收盘价进行预测。

（三） 激活函数的选择

在 BP 神经网络的预测中，选择合适的激活函数的十分重要。ReLU（Rectified Linear Unit）是比较流行的一种激活函数，成为训练神经网络模型的主要选择。ReLU 函数的定义是：$f(x)=\max(0,x)$，对输入的正值，直接输出该数据，而输入的值是负数，则以零为输出。它解决了 BP 神经网络模型在训练数据时容易出翔的梯度消失问题。具体而言，对于正数输入，ReLU 的导数恒为 1（$\frac{df(x)}{dx}=1$），这保证了在网络的深层中梯度可以无阻碍地传播，避免了在使用 sigmoid 或 tanh 激活函数时出现的梯度接近零的情况。

此外，ReLU 因其较高的计算效率被人们广泛使用。相比 sigmoid 和 tanh 函数，ReLU 的计算仅需判断输入值的正负，极大地降低了计算的复杂度。这种高效的计算方法加速了模型的训练过程，便于处理规模较大的数据。同时，由于 ReLU 在负数输入时零输出的特点促进了网络的稀疏激活性因此只有部分神经元

中国知网 https://www.cnki.net

处于激活的状态，有助于减少模型的过拟合风险，提高模型对数据的学习。最后，ReLU 在正数区间内保持恒定的导数为 1，这加快了模型的收敛速度，可以在较短的时间训练好性能较高的模型。

综上所述，在使用 BP 神经网络进行数据分析时，ReLU 激活函数能够有效避免梯度消失问题，提高计算效率，还可以促进网络的稀疏激活并快速实现收敛。因此，在对中证 100 指数进行预测时，本节使用 ReLU 作为 BP 神经网络的激活函数。

（四） 损失函数的确定

在构建 BP（反向传播）神经网络时，选择合适的损失函数模型的训练效果具有重要的影响。均方误差（MSE）作为损失函数在神经网络的训练和预测中得到广泛的使用，它是预测值与实际值之差的平方和的均值，即 $MSE=\frac{1}{n}\sum_{i=1}^{n}(Y_i-\hat{Y}_i)^2$，其中 n 代表样本数量，Y_i 是实际值，而 $\hat{Y}_i$ 是预测值。MSE 的优势体现在其数学特性上：作为一个连续且可微的函数，它为梯度下降及其他优化算法提供了方便，使得在训练过程中可以有效地计算梯度并更新模型参数。

此外，MSE 作为一个凸函数，在优化过程中能够保证找到全局最小值，这一特点简化了优化过程，减少了陷入局部最小值的风险，从而提高了训练的效率和稳定性。

综上所述，通过前面的分析和代码验证，构建出了合适的 BP 神经网络模型：它的输入层神经元数量为 8 个、隐藏层神经元数量为 13 个、输出层神经元数量为 1 个、激活函数选择 ReLU、损失函数选择 MSE。

3.3.2 BP 神经网络模型训练与预测

（一） 数据选取和预处理

模型训练部分选取 2015 年 01 月 01 日至 2023 年 5 月 31 日的数据，其中前 80%的数据作为训练集，后 20%的数据作为测试集，并预测 2023 年 6 月的 20 天数据，并与实际值进行对比分析。在开始训练模型之前，首先需要进行数据预处理。数据预处理的步骤包括数据清洗、归一化处理、数据集划分等。在这个过程中，本文将使用 Python 中的 pandas 和 numpy 库对数据进行处理，并使用 sklearn 库来进行数据集划分。

（二） 神经网络模型训练

中国知网 https://www.cnki.net

通过前面构建的模型对中证 100 指数的训练集数据进行训练，并在测试集数据中验证模型效果，结果显示测试集的 MSE 和 MAPE 分别是 74.21 和 1.4%，模型训练的损失图如图 3-2 所示，测试集模型的拟合效果如图 3-3 所示.

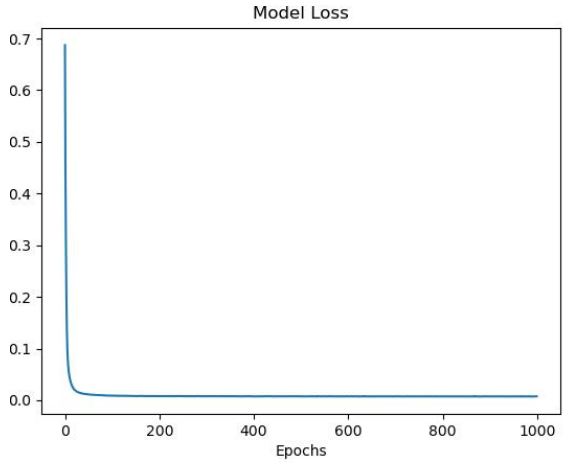

图 3-2 BP 神经网络模型训练集 loss 图

如图 3-2 所示，随着训练次数的增加，损失函数 MSE 的值逐渐减小并逼近为零。这表明神经网络在训练过程中逐渐达到了全局最优解。 损失函数的逐渐下降表明神经网络对训练数据的拟合效果逐渐变好，同时也意味着对未见过的数据进行预测时可能会有更高的准确性。 逼近零的损失函数值可能表明神经网络已经在训练数据上达到了非常高的拟合程度，这可能导致出现过拟合的情况。最终的损失函数值非常接近零可能表明神经网络在当前训练数据上已经达到了很好的训练效果，但不能完全保证在其他数据集上的泛化能力，需要通过验证集来评估模型的整体性能。

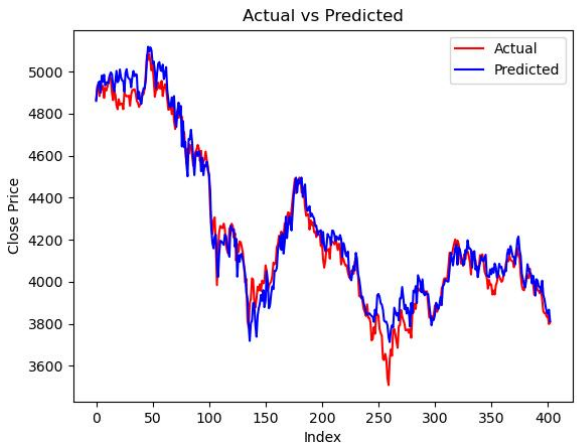

图 3-3BP 神经网络模型测试集拟合效果

中国知网 https://www.cnki.net

如图 3-3 所示，测试集中真实值与拟合值总体上相差不大，结果表明 BP 神经网络在测试集数据上取得了较好的拟合效果，能够较准确地预测真实数据，这表明模型具有一定的泛化能力。这种情况下，模型预测的结果与实际值整体上相差不大，表明模型很可能学到了数据的基本特征，对大多数样本进行了较好的拟合。偶尔出现差异较大的情况可能是因为在某些特定样本上神经网络的预测过程存在一些误差，这可能是由于该样本的特征或分布与其他样本不同，导致预测效果偏离。

（三） 神神经网络模型预测

这里对中证 100 指数 2023 年 6 月的 20 天数据进行预测，模型对训练验证集预测结果如图 3-4 所示，预测结果的评价指标如表 3-1 所示。

图 3-4 BP 神经网络模型测试集验证集预测结果

通过绘制真实值、训练集、测试集和验证集的拟合效果图可以观察到，模型对各个数据集的拟合效果都表现良好，预测值与真实值之间的差异较小。真实值与预测值之间的拟合效果良好，表明神经网络在训练集、测试集和验证集上都取得了较好的预测效果，这表明模型具有较强的泛化能力，能够适应不同的数据集。真实值、训练集、测试集和验证集的图中可以观察到一致的趋势和规律，这表明模型能够较好地捕捉到数据集中的模式和特征。真实值与预测值的拟合效果好可以为模型的应用提供较大的信心，特别是对于要用于实际决策或预测的情况。

表 3-1 验证集预测结果的评价指标

	MAE	RMSE	MAPE
训练集	36.99	51.85	0.94%

中国知网 https://www.cnki.net

测试集	58.43	74.21	1.40%
验证集	28.22	33.40	0.73%

如表 3-1 所示，可以看出 BP 神经网络模型对中证 100 指数预测时，表现出比较好的效果。在训练集，模型表现出了很好的拟合效果，它的评价指标 MAE 为 36.99，RMSE 为 51.85，MAPE 为 0.94%。在测试集和验证集中表现基本一致，虽然相比在训练集中的预测性能有所降低，但总体上它的误差基本维持在较低的水平下，其中，测试集中的评价指标 MAE 为 58.43，RMSE 为 74.21，MAPE 为 1.40%。验证集中的评价指标 MAE 为 28.22，RMSE 为 33.40，MAPE 为 0.73%。可以看出，训练出的模型具有较高的稳定性。模型很好的学习到输入数据复杂的关系，对股票研究者具有一定的参考价值。因此用 BP 神经网络模型对中证 100 指数进行预测准确是很高的,给相关投资来说具有重要参考价值。

中国知网 https://www.cnki.net

第四章 LSTM 神经网络模型及预测分析

4.1 LSTM 神经网络模型预测原理

（一） LSTM 神经网络模型原理

LSTM（长短期记忆）网络是一种特殊类型的循环神经网络（RNN），它可以克服 RNN 在处理时间序列数据时遇到的梯度消失的问题。LSTM 主要特点是它的内部结构，它通过门控制数据信息的输入、保留以及信息的流出，使得网络可以在较长的时间间隔有效地提取信息。在 LSTM 神经网络中，每个单元由遗忘门、输入门、输出门和一个细胞状态构成。这些组成部分共同工作，使得 LSTM 神经网络在处理时间序列的时候在不同阶段记住和遗忘信息。

遗忘门进行决定哪些信息应该保留和哪些信息应该丢弃。它通过 sigmoid 函数用当前输入的值 x_t 和上一步的隐藏状态 h_{t-1}，计算出一个在 0 到 1 之间的值。遗忘门的公式是：$f_t = \sigma(W_f \bullet [h_{t-1}, x_t])$ 其中，W_f 和 b_f 是遗忘门的权重和偏置。当 f_t 值接近 1 时，之前的信息就被保留下来；当 f_t 值接近 0 时，之前的信息就被忘记。

输入门则决定新的信息中有哪些部分将会被更新到细胞状态中。它使用 sigmoid 函数和 tanh 函数来创建一个新的候选值向量，进行更新细胞状态。输入门的公式是 $i_t = \sigma(W_i \bullet [h_{t-1}, x_t] + b_i)$，而候选值向量的公式是 $\widetilde{C}_t = \tanh(W_C \bullet [h_{t-1}, x_t] + b_C)$。细胞状态被更新为 $C_t = f_t \times C_{t-1} + i_t \times \widetilde{C}$，它既考虑了旧的细胞状态，也加入了新的候选值。

输出门决定着从细胞状态到最终输出的信息流。它用 sigmoid 函数来决定细胞状态的哪些信息传递到下一个时间步，然后将细胞状态用 tanh 函数进行处理，并将结果与输出门的输出相乘，得到最终的输出 $h_t = o_t \times \tanh(C_t)$。这样，LSTM 能够在每个时间步骤中调节它的内部状态和输出，让它在序列中有效地传递和保留重要信息。

通过这样比较复杂的机制，LSTM 就能够处理并对时间序列数据进行长期记

中国知网 https://www.cnki.net

忆，通过这样的设计，可以让 LSTM 学习到在何时忘记无关的信息，何时引入新的重要信息，以及何时将信息传递出去，从而可以让它处理数据量比较大的长期数据表现优秀。

（二） LSTM 神经网络的训练步骤

LSTM 神经网络的训练是很重要的一个过程，它主要是对权重和偏置的更新，让模型更准确地对时间序列数据进行预测。LSTM 的训练过程主要包括前向传播、计算损失、以及 C 反向传播和参数更新这三个步骤。

首先，在前向传播过程中，网络接收到序列数据，然后通过各个 LSTM 单元进行处理。每个单元根据当前的输入和先前的隐藏状态计算它的门控制信号和细胞状态，进而产生输出和新的隐藏状态。在这个过程中，每个门（遗忘门、输入门和输出门）都会使用特定的权重和偏置进行处理信息，如遗忘门利用 $f_t = \sigma(W_f \bullet [h_{t-1}, x_t] + b_f)$ 来决定保留哪些旧的信息，而输入门则通过 $i_t = \sigma(W_i \bullet [h_{t-1}, x_t] + b_f)$ 和新的候选值 $\widetilde{C}_t = \tanh(W_C \bullet [h_{t-1}, x_t] + b_C)$ 来更新细胞状态 C_t。

然后，用网络的输出值和实际值计算出损失函数，这一步骤在模型训练的过程中是十分重要的，因为损失函数的值将会影响后续的参数更新。常用的损失函数主要是均方误差（MSE），它能更好地对预测值和实际值之间的差异进行量化. 接下来就是反向传播过程，其中梯度下降（如 Adam 优化器）被用来更新网络的权重和偏置，以减小未来的预测误差。

最后，反向传播是 LSTM 训练中的核心，主要是对损失函数关于各参数的梯度进行计算，并利用这些梯度来更新参数。在 LSTM 中，主要包括对每个门的权重和偏置的更新，以及对细胞状态的更新。这些梯度是通过链式法则计算得出的。随着训练的不断进行，这些参数的更新将使 LSTM 神经网络逐渐学会从输入数据中提取有用的特征，并减小预测误差。

通过重复前面的这些步骤，LSTM 神经网络的性能将会不断得到提升，从而实现较高的预测准确率。训练过程中比较关注的是平衡好记忆和遗忘，调整好模型的复杂度,避免出现过拟合和欠拟合现象。最终，训练好的 LSTM 可以有效地预测长时间的数据。

中国知网 https://www.cnki.net

（三） **LSTM 神经网络的优缺点**

LSTM（长短期记忆）网络，在处理时间序列数据方面具有很强的优势。它的出现主要是为了解决传统 RNN 在处理时间序列数据时出现的梯度消失问题。通过引入遗忘门、输入门和输出门，LSTM 可以很好地控制信息的存储、更新和提取，使得它在很多方面得到了广泛的使用，如自然语言处理、股票价格预测、语音识别等方面。

LSTM 网络的主要优点是它可以捕获时间序列数据的长期依赖关系。而传统的 RNN 网络会随着时间序列的延长，前期的时间数据很难影响后期数据的输出，即梯度消失问题。LSTM 通过细胞状态和三个门的机制就可以很好地解决梯度消失问题，可以让信息在较长的时间间隔进行传递和保留。此外，LSTM 网络更加灵活，可以预测各种类型的时间序列数据。

然而，LSTM 也存在局限性。首先，LSTM 模型比较复杂，包含了很多参数，这使得它的训练过程所花费的时间更长，计算量也比较大，特别是在处理大规模数据的时候。此外，由于它的参数比较多，容易导致出现过拟合的情况，特别是在数据量比较少的情况下,这个时候就需要引入正则化或 dropout 技术避免出现过拟合。其次，虽然 LSTM 网络比传统 RNN 更好，但它并非对所有类型的时间序列数据都具有比较好的预测效果。在某些特定的情况下，简单的 RNN 网络的预测效果可能更好。

总之，LSTM 网络在处理更为复杂的时间序列数据时具有更好的效果，特别是在处理具有长期以来关系的数据时。它改进了 RNN 出现的梯度消失问题，使得它可以在更多领域进行数据处理。然而，由于它的计算量大以及参数调整比较敏感给模型的训练和参数优化带来了一定的挑战。因此，在使用 LSTM 进行数据预测时，需要根据预测数据的特点权衡它的优势和不足，确保选择合适的模型对数据进行处理。

4.2 LSTM 神经网络模型模型预测分析

4.2.1 构建神经网络模型

（一） **输入层和输出层的选择**

本文用前 5 天的交易日数据来预测未来 1 天中证指数的收盘价，输入的特征变量主要分为收盘价（close）、成交量（volume）、RSI、MOM_10、MAE_5、

中国知网 https://www.cnki.net

MACD、BIAS、ROC_12、GDP、CPI、收盘价的恐慌指数 VIX,、AR、BR 以及汇率 14 个变量，输出变量是输入变量下一期的收盘价。

（二） LSTM 模型的层数的确定

LSTM 模型的层数是影响其性能的重要因素，在模型层数较少时，模型可能无法捕捉到时间序列数据中的复杂关系；而层数过多时，模型可能出现过拟合的情况，降低了模型的泛化能力。因此，需要针对中证 100 指数的时间序列数据，分析不同层数对模型性能的影响。为了确定 LSTM 模型的最佳层数，本文采用交叉验证的方法，通过在训练集上训练模型，并在验证集上评估不同层数下模型的性能，根据验证集的指标（如均方误差、准确率等）来比较模型的表现，从而确定最佳的层数。

本文使用 python 代码对不同层数的 LSTM 模型进行交叉验证，并计算均方误差（MSE）。最后，输出了不同层数下的均方误差，并找到最佳的层数。代码运行结果显示，当 LSTM 模型的层数为四层的时候，LSTM 模型的性能最好，这时候的均方误差（MSE）0.0081

（三） 隐藏层节点数的确定方法

在在 LSTM（长短期记忆）模型中，隐藏层节点数的确定是一个重要环节，因为它会影响训练模型的学习能力和泛化能力，因此，在 LSTM 模型训练中，确定最佳的隐藏层节点数是十分必要的。隐藏层节点太少，训练的模型很难对复杂数据进行很好地捕捉。而隐藏层节点太多，则会导致模型出现过拟合的情况，导致模型在预测序列数据的时候表现不佳。

隐藏层节点数的确定没有固定的公式，它需要根据具体是预测任务进行调整。即从较小的节点数开始尝试，然后节点数逐步进行增加，同时要兼顾模型在验证集中的表现情况，当模型的预测效果不在显著提高或者出现过拟合的情况时，所对应的隐藏层节点数便是一个比较合理的数值。这个复杂的过程可以借用交叉验证的方法进行完成，确保它的稳健性，即将数据集分成好几部分，轮流使用其中一部分作为验证集，剩余的数据作为训练集数据，从而可以得到更为稳定的模型性能。

交叉验证是确定隐藏层节点数很有效的方法，如 K 折交叉验证,它是将数据分成 K 个子集，每次训练，其中一个子集作为验证机，剩余 K-1 个子集作为训

中国知网 https://www.cnki.net

练集，这个过程进行 K 此，最终是 K 次验证结果的平均值。这种方法方法可以降低因数据划分而带来的性能的波动性，从而更为可靠的评估不同节点下模型的性能。

另一种方法是网格搜索，它通过遍历所有给定的节点数组合来找到最佳的隐藏层节点数，如我们想要测试隐藏层节点数为 50, 100, 150, 200 的模型性能，网络搜索会遍历给定的隐藏节点数的范围，并评估每个节点下模型的性能。虽然这个方法可以系统的寻找到模型的最佳隐藏节点数，随着隐藏节点数范围的增加，它的计算时间呈指数增加，因此，实际操作中，往往需要权衡搜索的广度和深度，有时借助随机搜索或贝叶斯优化等更高效的方法来辅助。

总之，确定 LSTM 隐藏层节点数需要考虑模型的性能、计算成本和过拟合风险。通过交叉验证和网格搜索等方法，可以更为便捷地找到最佳的隐藏层节点数。虽然这一过程的计算相抵漫长，但对于构建一个性能更好的 LSTM 模型是十分必要的。通过这一步骤，可以确保模型既能学习到数据中的复杂结构，又能确保模型的泛化能力。。

基于此，本文用 python 代码通过网格搜索方法来确定最佳的隐藏层节点数量为 200，其中输入层变量 14 个，步长为 5.

4.2.2 LSTM 神经网络模型训练与预测

（一） 激活函数和损失函数的选择

在用 LSTM 神经网络模型对中证 100 指数进行预测时，选择合适的激活函数和损失函数的模型的性能具有重要作用，激活函数影响着模型中数据的转换和传递，损失函数影响着模型优化的方向。

激活函数可以帮助 LSTM 网络模型更有效地捕捉时间序列数地长期依赖关系。tanh 函数的输入范围是-1 到 1 之间，便于模型处理不同规模的数据，相比 sigmoid 函数，tanh 函数在模型训练中可以缓解梯度消失问题，更好地让模型捕捉数据的长期趋势。因此，在对中证 100 指数进行预测时，选择 tanh 函数作为模型的激活函数是十分合理的。

损失函数决定模型的优化目标，对股票进行预测中，常用均方误差（MSE）作为模型的损失函数，MSE 损失函数对预测偏差较大的数据更为关注,尽管 MSE 函数对异常值比较敏感，在股票预测中，异常值往往包含重要的信息。在股票预

中国知网 https://www.cnki.net

测类的研究中，平均绝对误差（MAE）也会被用来作为模型的损失函数。与 MSE 相比，MAE 对异常值不够敏感，适用于异常值不重要的股票预测中。

综上所述，股票数据的变化跟历史长期数据具有很大的关系，因此本文选择 tanh 函数作为 LSTM 的激活函数，MSE 作为模型的损失函数是比较合理的。

（二） 参数优化

用 LSTM 神经网络对中证 100 指数进行股票预测时，需要在训练的过程中对模型进行参数优化，参数优化对训练后 LSTM 模型的性能具有重要影响作用。参数优化的过程主要是为了确定模型最佳的学习率、批次大小（batch size）、迭代次数（epochs）以及优化器。

学习率控制模型每次迭代更新步幅的大小，是影响模型性能的直接因素之一。当学习率较高时，模型可能在最优解周围震荡或者偏离；当学习率较低时，模型训练的过程将会很缓慢，需要更多的时间收敛，有可能陷入局部最优结。在实际预测中，学习率需要多次尝试才能确定，比较好的方法时动态调整学习率，比如使用学习率衰减或自适应学习率的优化器 Adam,可以根据梯度自动调整学习的大小。

批次大小（batch size）对模型的训练效果也具有重要影响。batch size 较小的时候，可以提高训练模型的稳定性和泛化能力。batch size 较大的时候，可以加快模型的训练过程，但会降低模型的稳定性和准确性。因此，通过不断尝试确定合适的 batch size 是很有必要的。

迭代次数（epochs）代表了模型在训练集中迭代的次数。epochs 过小的时，将会导致模型欠拟合；epochs 过大的时，可能导致模型过拟合。通常先设置一个比较大的 epochs，并结合早停策略，当模型在验证集的性能不再提升的时候，所对应的 epochs 就是比较合理的数值。

优化器主要规定了参数更新的具体算法。常用的优化器主要是 Adam，它结合了动量方法和 RMSprop 算法的优点,可以自适应地调整每个参数地学习率，在各种数据处理中具有较好的表现，也可以考虑其他优化器，如 SGD、Adagrad。

在 LSTM 模型实际预测中，通常利用网络搜索法或贝叶斯优化等方法寻找最佳的参数组合。先设置参数的取值范围，经过模型的多次训练，记录下每次训练后的模型在验证集中的表现，最终确定最佳的参数组合。

中国知网 https://www.cnki.net

综上所述，在使用 LSTM 神经网络模型对中证 100 指数进行股票预测的时候，选择较佳的学习率、批次大小、迭代次数和优化器对模型在验证集中的表现具有直接影响。本文使用 python 通过网络搜索法最终确定模型的参数分别是：学习率 0.01，批次大小 16，迭代次数 1000，优化器选择 Adam。这些参数可以很好地平衡 LSTM 模型的训练效率和预测性能，希望模型对中证 100 指数的股票预测中取得较好的结果。

（三） 模型训练

根据前面构建好的 LSTM 模型进行训练，即建立一个输入层神经元为 14、隐含层神经元数目为 200、输出神经元为 1 个、步长为 5、层数为 4 层的 LSTM 神经网络，其中，激活函数选择 tanh 函数，损失函数为 MSE，学习率为 0.01，epochs 为 1000 ，batch_size 为 16，优化器（optimizer）是 Adam， 并对中证 100 指数的收盘价进行预测。LSTM 模型训练部分选取 2015 年 01 月 01 日至 2023 年 5 月 31 日的数据，其中 80%的数据作为训练集，20%的数据作为测试集，并预测 2023 年 6 月中的 20 天数据，最后与实际值进行对比分析。模型结果显示测试集的 RMSE 和 MAPE 分别是 151.96 和 2.80%，模型训练的损失图如图 4-1 所示，测试集模型的拟合效果如图 4-2 所示；

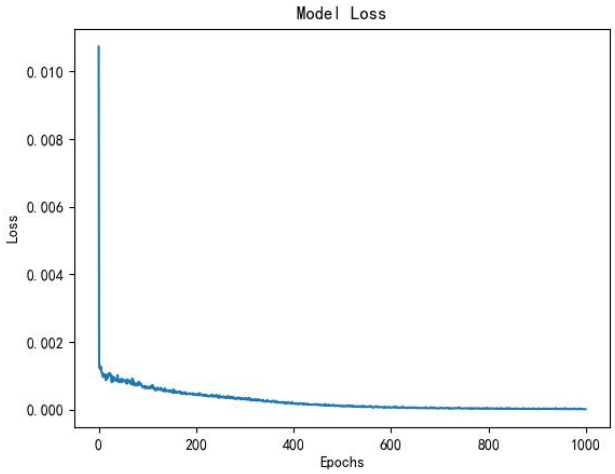

图 4-1 LSTM 神经网络模型训练的损失图

如图 4-1 所示，随着训练模型的迭代次数的增加，LSTM 的损失值 loss 快速降低，然后出现了细微的波动，最后逐渐趋近于零。表明 LSTM 在训练的时候逐步收敛，模型的拟合效果得到显著提高。

损失值快速下降阶段，随着模型开始训练，loss 值快速下降，表明模型能够从数据中快速提取有用的信息，逐渐提高了模型对训练集数据的拟合效果。损失

中国知网 https://www.cnki.net

值的细微波动阶段，可能是模型在训练过程中出现了噪声或者遇到了局部最优的情况，这些波动并没有导致 loss 值明显上升，表明模型在不断调整和优化，具有一定的稳定性。最后，损失值逐渐逼近于零的过程表明，模型在训练集数据中具有很好的拟合效果。

总之，loss 图可以看出 LSTM 模型在训练过程中具有较好的表现，从刚开始时的快速下降，到出现细微波动，再到最终的稳定，表明这一模型对中证 100 指数具有比较好的拟合能力，需要通过后面的测试集数据进一步验证模型的性能。

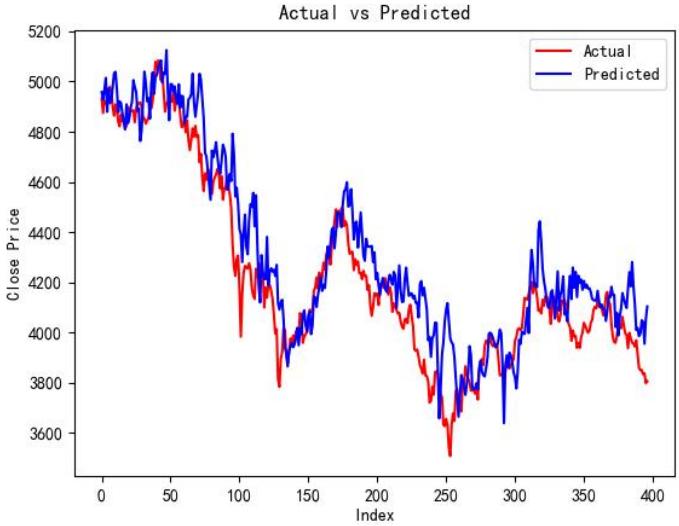

图 4-2　LSTM 神经网络模型测试集模型的拟合效果

如图 4-2 所示，在使用 LSTM 模型对测试集数据进行验证时，预测出来的结果与真实值在总体趋势上基本保持一致，但也存在着差异，这可能是由多种因素造成的：首先，股票数据包含一定的遭受，它受各种复杂因素的影响，如宏观经济政策、公司之间的竞争和市场情绪等；其次，尽管 LSTM 神经网络处理复杂的数据具有较大优势，也很难很好的捕捉股票市场中的所有波动，特别是存在极端值的情况下。

LSTM 对股票测试集的预测中仍存在着一些两点。第一，预测出来的结果跟实际值在趋势上保持一致，表明模型捕捉到了中证 100 指数在在宏观上的未来走势，对投资者具有一定参考价值。第二，中证 100 指数的股票价格受各种复杂因素的影响，虽然预测结果不是特别准确，模型表现出能够捕捉这些复杂数据之间的关系。第三，LSTM 模型可以反映出股票在未来的中长期去世的变化，这对进行长期投资的投资者来说具有一定的参考价值。

总之，虽然预测出的结果与真实值存在些许差异，但 LSTM 为分析中证 100

中国知网 https://www.cnki.net

指数的未来趋势可以提供参考价值，未来结合其他工具进一步改进模型，提高模型的预测准确性。

（四） LSTM 神经网络模型预测

对中证 100 指数 2023 年 6 月的 20 天数据进行预测，模型在训练预测中的表现如图 4-3 所示，预测结果的评价指标如表 4-1 所示。

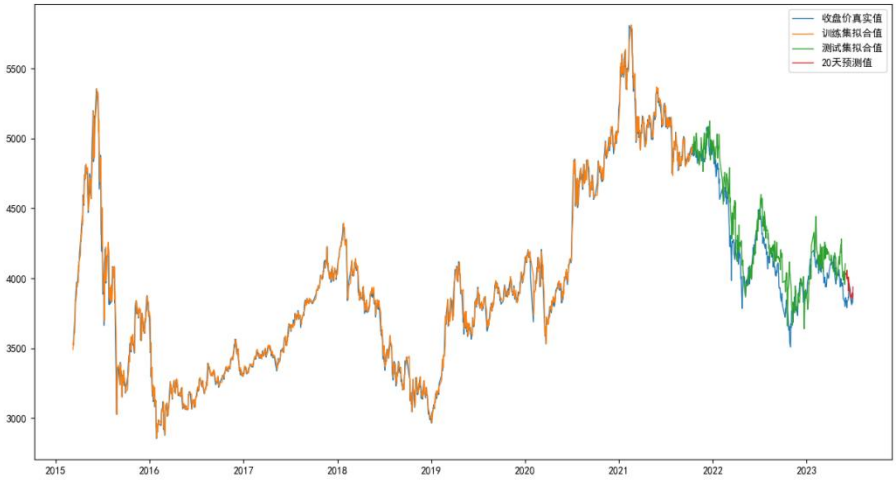

图 4-3 LSTM 神经网络模型拟合预测结果

如图 4-3 所示，可以模型具有很好的拟合能力。首先，在训练集中，模型表现的很出色，预测出的股票价格和真实值高度一致，很好地学习到了数据中的有效信息，并捕捉到了数据的趋势。其次，在测试集和验证集中，尽管模型预测出的股票数据和真实值之间存在些许误差，但模型对中证 100 指数的未来走势在宏观上进行很好的预测。考虑到股票市场的复杂性，在测试集和验证集中的误差是可以接受的。

表 4-1 LSTM 神经网络模型结果的评价指标

	MAE	RMSE	MAPE
训练集	39.0477	59.2591	0.99%
测试集	115.3614	151.9648	2.80%
验证集	111.025	139.6921	2.90%

如表 4-1 所示根据，可以看出 LSTM 神经网络模型对中证 100 指数预测时，表现出比较好的效果。在训练集，模型表现出了很好的拟合效果，它的评价指标 MAE 为 39.05，RMSE 为 59.26，MAPE 为 0.99%。在测试集和验证集中表现基本一致，虽然相比在训练集中的预测性能有所降低，但总体上它的误差基本维持

中国知网 https://www.cnki.net

在较低的水平下，其中，测试集中的评价指标 MAE 为 115.36，RMSE 为 152，MAPE 为 2.80%。验证集中的评价指标 MAE 为 111.03，RMSE 为 139.7，MAPE 为 2.90%。可以看出，训练出的模型具有较高的稳定性，即在两个不同的数据集中预测出的误差基本一致，模型很好的学习到输入数据复杂的关系，对股票研究者具有一定的参考价值。尽管 LSTM 预测的出结果的评价指标比在训练集中的大，不能因此觉得模型效果不好，股票数据本身具有噪声，并且影响股票价格变动的因素众多，这点误差是在可接受的范围内，因此用 LSTM 对中证 100 指数进行预测还是很有效果的，希望在之后的研究中对模型进一步优化，结合其他统计工具可以更有效地对股票市场数据进行预测。

4.3 单一模型预测结果汇总分析

1.通过对比分析不同模型，可以更全面地了解各个模型在预测股票价格方面的优缺点。这有助于在实际应用中选择最适合的模型。在本次预测研究中，本文采用了三种时序预测模型：ARIMA、BP 和 LSTM，预测结果及其相对误差已成功汇总到表 4-2 中。

表 4-2　三个模型预测结果的相对误差

日期	真实值	ARIMA 预测值	相对误差	BP预测值	相对误差	LSTM预测值	相对误差
2023/6/1	3806.87	3797.46	0.25%	3812.39	-0.15%	4103.9688	7.80%
2023/6/2	3861.83	3792.23	1.80%	3817.34	1.15%	4030.0278	4.36%
2023/6/5	3844.25	3789.55	1.42%	3868.82	0.64%	4036.392	5.00%
2023/6/6	3808.16	3794.03	0.37%	3841.25	0.87%	4016.8452	5.48%
2023/6/7	3789.34	3797.08	0.20%	3827.74	1.01%	3996.834	5.48%
2023/6/8	3820.19	3793.11	0.71%	3784.00	0.95%	4058.706	6.24%
2023/6/9	3836.7	3789.76	1.22%	3826.61	0.26%	4013.4797	4.61%
2023/6/12	3844.43	3793.20	1.33%	3842.32	0.05%	3973.0999	3.35%
2023/6/13	3864.91	3796.79	1.76%	3861.35	0.09%	3912.646	1.24%
2023/6/14	3864.02	3793.89	1.82%	3884.54	0.53%	4009.8389	3.77%
2023/6/15	3925.5	3790.13	3.45%	3886.04	1.01%	3980.846	1.41%
2023/6/16	3963.35	3792.50	4.31%	3960.51	0.07%	3910.7952	1.33%
2023/6/19	3930.91	3796.36	3.42%	3992.57	1.57%	3917.832	0.33%
2023/6/20	3924.24	3794.51	3.31%	3970.74	1.18%	3877.3337	1.20%

中国知网 https://www.cnki.net

2023/6/21	3864.03	3790.61	1.90%	3925.09	1.58%	3863.168	0.02%
2023/6/26	3809.7	3791.95	0.47%	3854.14	1.17%	3885.028	1.98%
2023/6/27	3845.43	3795.84	1.29%	3865.99	0.53%	3893.7534	1.26%
2023/6/28	3840.8	3794.97	1.19%	3862.14	0.56%	3851.612	0.28%
2023/6/29	3821.84	3791.16	0.80%	3848.76	0.70%	3875.7202	1.41%
2023/6/30	3842.45	3791.56	1.32%	3821.31	0.55%	3894.7202	1.36%
均值	3858.00	3793.12	1.62%	3870.59	0.72%	3947.30	2.89%

如表 4-2 所示，在用单一模型 ARIMA 模型、BP 模型和 LSTM 模型分别对中证 100 指数进行预测时，从相对误差的均值来看，这三个模型在对中证 100 指数预测时，都表现出了较好的结果。其中，BP 神经网络模型预测出的中证 100 指数效果最好，预测出来的结果十分稳定，相对误差基本保持在 2%以内，相对误差的平均值为 0.72%，可以看出，训练出的 BP 模型的预测性能很好。ARIMA 模型对中证 100 指数的预测效果次之，用它预测出的值基本变动不大，相对误差基本上保持在 2%左右，也有几个误差比较大的数据，可能是预测股票价格波动比较大引起的，相对误差的均值是 1.62%，可以看出，ARIMA 模型对股票价格进行短期预测的效果还是可以的。在进行时间序列预测时，ARIMA 模型擅长预测趋势性比较强的数据，但对于像股票这样波动性比较大，进行较长时间的预测，效果就不太性，因它可以更好地捕捉时间序列数据的趋势性，可以结合其他模型可以达到更好的预测效果。LSTM 神经网络模型对中证 100 指数预测的效果不是很好，尽管相对误差的均值为 2.89%，处于低水平，但从预测值的每个相对误差可以看出，LSTM 对股票价格预测的稳定性不是很好，最小的预测误差是 0.02%，是这三个模型预测出误差最小的值，可以看出它是可以很好捕捉历史信息，但它预测结果中也有三个模型中误差最大的数值，可能是模型对历史信息的提取不到造成的，总体上在可接受范围内。这三个模型对中证 100 指数预测的结果各具有特点，BP 神经网络模型预测出的值更加准确，ARIMA 预测出的结果更稳定，LSTM 预测出的结果波动比较大，将这三种模型进行结合，有可能提高对中证 100 指数的预测效果。

2. 通过对 ARIMA、BP 和 LSTM 模型对中证 100 指数预测进行对比分析，可以得出 BP 神经网络模型具有较好的预测效果，它们预测结果的评价指标 MAE、RMSE 和 MAPE 如表 4-3 所示。

中国知网 https://www.cnki.net

表 4-3　三个单一模型的评价指标

模型	MAE	RMSE	MAPE
ARIMA模型	62.89	77.31	1.62%
BP神经网络模型	28.22	33.40	0.73%
LSTM神经网络模型	111.03	139.69	2.89%

如表 4-3 所示是对 ARIMA 模型、BP 神经网络模型和 LSTM 神经网络模型对中证 100 指数预测结果的整体性评价，从中可以看出，BP 神经网络模型的预测效果是最好的，表明训练后的 BP 模型具有很好的性能，它的评价指标 MAE、RMSE 和 MAPE 分别是 28.22，33.40 和 0.73%，显著低于 ARIMA 模型和 LSTM 模型，表明 BP 神经网络模型很好地学习和适应了给定的复杂非线性数据。而 LSTM 神经网络模对中证 100 指数的预测效果相对另外两个模型较差，表明训练后的 LSTM 模型的泛化能力相对弱，它的评价指标 MAE、RMSE 和 MAPE 分别是 111.03，139.69 和 2.89%，相对高于 ARIMA 模型和 LSTM 模型的。ARIMA 模型对中证 100 指数的预测效果比较适中，它的评价指标 MAE、RMSE 和 MAPE 分别是 62.89，77.31 和 1.62%。

ARIMA 模型适合对具有趋势性或稳定性强的数据具有较高的预测效果，对于波动性较大的股票数据，通常预测效果不是很好，因此，在用 ARIMA 模型对中证 100 指数进行预测时表现一般。BP 神经网络模型在对复杂的非线性数据进行预测时具有更好的效果，因此，用它对中证 100 指数进行预测时具有很好的预测效果，它的 MAE、RMSE 和 MAPE 均很低，表明它在捕捉股票数据的波动性和处理非线性方面具有较强的能力。LSTM 神经网络模型具有长时依赖性，在处理时间序列数据时具有较强的预测能力，可以很好地捕捉历史信息，用它对中证 100 指数进行预测时，表现差强人意，可能是中证 100 指数的波动性和数据特征较为复杂导致的。为了进一步提高模型预测的准确性，本文尝试将这几种模型进行，从而组合模型对中证 100 指数预测准确性。

中国知网 https://www.cnki.net

第五章 ARIMA-BP-LSTM 组合模型预测

5.1 组合模型预测原理

在股票预测中，准确地对股票进行预测一直是比较有挑战的任务，由于影响股票价格的因素多，股票价格是复杂的非线性数据，使用单一预测模型很难全面地捕捉影响股票价格的因素，因此，将不同预测股票数据的单一模型进行结合，成为提高股票预测准确的有效策略。组合模型的基本思路是将不同的单一预测模型按着定权或变权的方法结合在一起，同时减少单一模型预测带来的误差，提高模型的稳定性和准确性，不同的单一模型在预测股票数据时可能都具有各自的优势，即使某一单一模型预测效果不如其他的，但它仍包含有效的信息，通过跟他进行组合模型，可能会提高模型整体的预测准确性。

组合模型的组合方法主要分为定权法和变权法两种，定权法是每个单一模型的权重是恒定的，如等权重法和加权平均法，而变权法是在组合预测是预测的每一期数据，三个模型的权重是变化的，如变权组合法。

（一） 等权重法

等权重法[38]是最简单的一种组合方法，它假定每个模型基本具有相同的预测效果，因此，对每个模型给予相同的权重，如果具有 n 个模型对股票数据进行预测，则每个模型的权重为 1/n。组合模型的预测值用 F_t 表示：

$$F_t = \frac{1}{n}\sum_i^n P_{it} \tag{5.1}$$

其中，P_{it} 是第 i 个模型在时间 t 的预测值。等权重法适用于单一模型预测出的结果没有太大差异，用等权重法进行模型组合简单易性，不需要专门进行权重计算，减少了过度依赖单一模型的风险。但等权重法忽略了不用预测模型之间的差异，可能会导致无法利用好最佳的模型，在单一模型之间预测效果差异太大时，可能无法适用。

（二） 加权平均法

加权平均法[39]是定权组合的一种方法，它是用多个预测模型改进整体预测效果的方法，它是赋予每个单一模型一个权重，并将它们进行加权求和，计算出来的结果就是组合模型的预测值，它最重要的是确定单一模型的权重，主要目的是

中国知网 https://www.cnki.net

最小化预测误差并充分利用好每个模型的特点:

$$F_t = w_1 \times P_{1t} + w_2 \times P_{2t} + w_3 \times P_{3t} \tag{5.2}$$

其中P_{1t}，P_{2t}，P_{3t}分别代表不同模型在同一时间点t的预测值，而 w_1，w_2，w_3是相应的权重。

权重通过最小化平均相对误差函数获得，该函数定义为：

$$E(w_1, w_2, w_3) = \frac{1}{N}\sum_{t=1}^{N}\left|\frac{T_t - (w_1 \times P_{1t} + w_2 \times P_{2t} + w_3 \times P_{3t})}{T_t}\right| \tag{5.3}$$

其中T表示实际真实值，N 是时间序列的长度。优化过程中施加约束确保权重和为 1，即$\sum_{i=1}^{3} w_i = 1$，并且每个权重都非负 ，即$w_i \geq 1$。

使用加权平均法对单一模型进行组合可以降低对单一依赖，降低出现过拟合的风险，可以降低单一模型预测出极端值的影响，提高模型的稳定性和准确率。组合模型的性能依赖选择单一模型的性能和多样性。

（三） **权变组合法**

变权组合法[40]是在预测每个时点的时候对权重值进行调整，以期最小化预测的历史数据最小化误差，这个误差通常是相对误差。这种方法主要时动态地调整各单一模型的权重，使得组合模型得整体误差达到最小。设组合模型的预测值为F_t，变权组合中，相对误差E的目标函数是：

$$E = \frac{1}{T}\sum_{t=1}^{T}\left|\frac{T_t - F_t}{T_t}\right| \tag{5.4}$$

其中，T_t是是指时间t时刻的真实值。各单一模型的权重是当相对误差E达到最小值时取得值，这里采用约束优化算法，三个单一模型的权重之和为 1，且每个权重为非负值。用变权组合法进行组合预测模型具有一定的优势，通过约束优化算法动态地调整各单一模型的权重，以适应单一模型的不同时间点出现的各种变动。通过目标函数E最小化组合模型预测结的相对误差，理论上可以很好地提高组合模型整体的预测准确率。然而，变权组合法存在着一定的局限性，实施起来相对复杂，同时用目标函数E对预测出的历史数据和真实值进行约束优化算

中国知网 https://www.cnki.net

法时，要选择合适的T，当它过大时，得出的最佳权重可能存在过度拟合历史数据的风险，,降低模型的泛化能力；当它过小时，不能很好的反应出近期内各单一模型对时间序列数据预测性能。

5.2 ARIMA-BP-LSTM 组合预测模型

通过将三个单一模型 ARIMA 模型、BP 神经网络模型和 LSTM 模型对中证 100 指数的预测结果进行组合，这种方法主要是为了能够充分发挥各单一模型的优势，提高整体模型对股票预测的稳定性和准确率。ARIMA 模型可以很好的捕捉时间序列数据的趋势效应,BP 神经网络模型擅长对各种复杂的非线性数据进行处理，而 LSTM 神经网络模型在捕捉股票数据的长期依赖关系具有更好的效果。通过将这三个模型进行组合，可以各单一模型存在的不足，同时可以更好的发挥预测效果较佳模型的优势，通过组合各单一预测模型结果，可以提高更为可靠的股票预测结果。

（一） 等权重法组合模型的预测结果

使用等权重法对各单一模型进行组合，能够有效的平衡各单一预测模型优势与不足，得到一个更加稳定的预测结果，当单一模型预测效果差异性比较大时，等权重法可以分散风险从而提高组合模型的预测效果，它预测出结果的评价指标如表 5-1 所示。

表 5-1　等权重法预测结果的评价指标

模型	MAE	RMSE	MAPE
ARIMA模型	62.89	77.31	1.62%
BP神经网络模型	28.22	33.40	0.73%
LSTM神经网络模型	111.03	139.69	2.89%
等权重法	37.68	46.89	0.98%

如表 5-1 所示，用等权重法形成的组合模型对中证 100 指数预测的结果相对 ARIMA 模型和 LSTM 神经网络模型得到了明显的提高，它的评价指标 MAE，RMSE 和 MAPE 分别是 37.68 ，139.69 和 0.98%，虽然比起预测最佳的单一模效

中国知网 https://www.cnki.net

果稍微低些，但组合模型相比单一模型具有很好的稳定性，在有些情况下具有较大的参考价值。从 MAE 的评价指标来看，BP 神经网络模型预测结果最为准确，预测结果的 MAE 仅为 28.22，可见 BP 神经网络模型对股票的波动得到了较好的把握。其次是等权重法组合模型，它预测结果的评价指标 MAE 为 37.68，经过组合模型预测后，比起另外两种单一模型准确率得到了极大的提升，然后是 ARIMA 模型，它预测结果的评价指标 MAE 为 62.89，比起前两个模型略高，ARIMA 模型预测出的股票价格相对稳定，数据变动不大，可以很好的展现股票未来短期的波动趋势。而 LSTM 对中证 100 指数预测出结果的评价指标 MAE 为 111.03，表明 LSTM 模型在股票股票数据中的误差最大。从 RMSE 评价指标来看，这几个模型预测结果的性能跟 MAE 指标下一致。BP 神经网络模型预测结果的 RMSE 为 33.40，可以看出它的预测误差的波动性比较小。用等权重法形成的组合模型预测结果的 RMSE 为 46.89,仅次于 BP 神经网络的结果，表明等权重法组合模型可以很好的降低预测极端值带来的影响，模型更为稳定。而 ARIMA 模型和 LSTM 模型预测结果的评价指标分别是 77.31 和 139.69，表明这两种模型捕捉股票数据中的极端值效果不是很好。从 MAPE 评价指标来看，等权重法组合模型预测结果的 MAPE 值为 0.98%，可以看出组合模型在数据的整体性预测具有较好的效果，虽然略高于 BP 模型的，但优于 ARIMA 模型和 LSTM 模型的 MAPE 值，表明等权重法组合模型预测出的股票数值更为稳定。

综上所述，等权重法组合预测模型对中证 100 指数的预测优于单一模型 ARIMA 和 LSTM 的预测值，略低于 BP 神经网络模型的预测性能。等权重法通过将这三种模型预测结果平均化，这种方法可以降低有价值的单一模型个别较大的预测误差，并给出比单一模型预测值更为稳定的预测结果。这点就可以从三个评价指标 MAE、RMSE 和 MAPE 的结果可以看出，等权重法组合各单一模型预测结果后，可以有效地平衡各单一模型不同的优缺点，得到较为稳定的结果。

等权重法组合预测的效果优于单个 ARIMA 模型和 LSTM 模型的预测，但略逊于 BP 神经网络模型。等权重法将三种模型的预测结果平均化，这种方法通常能够减少单一模型可能引入的大的预测误差，并提供一个比任何单一模型都要稳健的结果。这在 MAE、RMSE 和 MAPE 的比较中得到了体现，等权重法的所有指标都显著优于 LSTM 模型，大部分优于 ARIMA 模型，并且仅稍微差于 BP 神

中国知网 https://www.cnki.net

经网络模型。等权重法在整合了各模型的预测后，能有效平衡不同模型的优缺点，得到了一个较为稳健的预测效果。

（二） 加权平均法组合预测模型

加权平均法对各单一模型进行组合，能够有效的平衡各单一预测模型优势与不足，充分发挥个模型的优势，得到一个更加准确的预测结果，当单一模型预测效果差异性比较大时，加权平均法可以分散风险从而提高组合模型的预测效果。加权平均法组合模型的预测结果的准确性较单一模型具有明显提高。如表 5-2 所示。

表 5-2　加权平均法预测结果的评价指标

模型	MAE	RMSE	MAPE
ARIMA 模型	62.89	77.31	1.62%
BP 神经网络模型	28.22	33.40	0.73%
LSTM 神经网络模型	111.03	139.69	2.89%
加权平均法	20.41	26.77	0.53%

如表 5-2 所示，用加权平均法形成的组合模型对中证 100 指数预测的结果相对 BP 神经网络模型、ARIMA 模型和 LSTM 神经网络模型得到了明显的提高，

它的评价指标 MAE，RMSE 和 MAPE 分别是 20.41，26.77 和 0.53%，此时 ARIMA 模型、BP 神经网络模型和 LSTM 神经网络模型的权重分别是 0.298, 0.651, 和 0.051，组合模型比单一模型对股票的预测效果更好，选择合适的组合模型可以显著地提高对股票数据的预测效果，同时每个单一模型都具有一定优势，即使这个单一模型的预测效果不如其他模型其他模型那么好，大多数情况下这些模型都具有一定优势，可以给投资者提供一定的参考价值。

从 MAE 的评价指标来看，加权平均法模型预测结果最为准确，预测结果的 MAE 仅为 20.41，可见加权平均法模型很好的平衡了这三个模型的预测结果，从三个模型的权重可以看出，BP 模型对组合模型的贡献最大，权重为 0.651，ARIMA 模型预测结果对组合模型的贡献次之，权重为 0.298，而 LSTM 模型预测结果对组合模型的贡献最少，权重仅为 0.051。虽然 LSTM 的权重很小，但它对组合模型的作用很大，因为它没有很好的捕捉异常值对预测结果的影响，在组合模型中可以很好的调节哪些波动比较大的股票数值。其次是 BP 神经网络模型，它预测

中国知网 https://www.cnki.net

结果的MAE仅为28.22，可见BP神经网络模型对股票的波动得到了较好的把握。然后是 ARIMA 模型，它预测结果的评价指标 MAE 为 62.89，比起前两个模型略高，ARIMA 模型预测出的股票价格相对稳定，数据变动不大，可以很好的展现股票未来短期的波动趋势。而LSTM对中证100指数预测出结果的评价指标MAE为 111.03，表明 LSTM 模型在股票股票数据中的误差最大。从 MAPE 评价指标来看，加权平均法组合模型预测结果的 MAPE 值为 0.53%，可以看出组合模型在数据的整体性预测具有较好的效果，优于 BP 模型、ARIMA 模型和 LSTM 模型的 MAPE 值，表明加权平均法组合模型预测出的股票数值更为稳定。

从加权平均法组合模型预测结果可以看出，合理的组合模型可以提高单一模型预测的准确性，特别是对股票这种波动性较大的数据来说，尽管加权平均法组合模型的预测效果很不错，但它高度依赖各个单一模型预测的结果以及合理的权重。

（三） 变权组合预测模型

用变权组合法对各单一模型进行组合，能够有效的平衡各单一预测模型优势与不足，充分发挥个模型的优势，得到一个更加准确的预测结果。这种方法是通过动态调整各个单一模型的权重，当单一模型预测效果差异性比较大时，变权组合法可以分散风险从而提高组合模型的预测效果。变权组合法组合模型的预测结果的准确性较单一模型具有明显提高,相较于单一模型，变权组合法组合模型可以有效地降低预测误差，增强预测结果的可靠性。如表 5-3 所示。

表 5-3　变权组合法预测结果的评价指标

模型	MAE	RMSE	MAPE
ARIMA 模型	62.89	77.31	1.62%
BP 神经网络模型	28.22	33.40	0.73%
LSTM 神经网络模型	111.03	139.69	2.89%
变权组合法	31.43	38.88	0.81%

如表 5-3 所示，用变权组合法形成的组合模型对中证 100 指数预测的结果相对 ARIMA 模型和 LSTM 神经网络模型得到了明显的提高，它的评价指标 MAE，RMSE 和 MAPE 分别是 31.43 ，38.88 和 0.81%，虽然比起预测最佳的单一模效果稍微低些，但组合模型相比单一模型具有很好的稳定性。从 MAE 的评价指标

中国知网 https://www.cnki.net

来看，BP 神经网络模型预测结果最为准确，预测结果的 MAE 仅为 28.22，可见 BP 神经网络模型对股票的波动得到了较好的把握。其次是变权组合法组合模型，它预测结果的评价指标 MAE 为 31.43，经过组合模型预测后，比起另外两种单一模型准确率得到了极大的提升.而 ARIMA 模型和 LSTM 模型的评价指标 MAE 分别是 62.89 和 111.03，比起前两个模型略高，ARIMA 模型预测出的股票价格相对稳定，LSTM 模型在股票股票数据中的误差最大。

从 RMSE 评价指标来看，ARIMA 模型 BP 模型、LSTM 模型和组合模型的评价指标 MAPE 分别是 1.62%，0.73%，2.89%和 0.81%。模型预测结果的性能跟 MAE 指标下一致。这些模型对股票进行了很好的预测，可以看出组合模型在数据的整体性预测具有较好的效果，虽然略高于 BP 模型的，但优于 ARIMA 模型和 LSTM 模型的 MAPE 值，表明等权重法组合模型预测出的股票数值更为稳定。

变权组合法组合模型性能的提升主要是它能够动态的对各模型的权重进行调整，根据每个模型过去预测结果的误差对权重进行不断优化，它的适用性使得在金融市场预测中比较常用，以适应多变的市场状态。

5.3 三种模型组合预测对比分析型

（1）本文先用三个单一预测模型 ARIMA、BP 和 LSTM 对中证 100 指数分别进行了预测，然后通过三种常用的组合方法等权重法、加权平均法和变权组合法对股票数据进行组合预测，结果显示，用加权平均法组合形成的 ARIMA-BP-LSTM 模型预测效果最好，比单一模型进行预测效果更好，如表 5-4 所示。

表 5-4　三个模型预测结果的相对误差

日期	真实值	等权重法	相对误差	加权组合法	相对误差	变权组合法	相对误差
2023/6/1	3806.87	3904.61	2.57%	3822.92	0.42%	3904.61	2.57%
2023/6/2	3861.83	3879.87	0.47%	3820.79	1.06%	3879.87	0.47%
2023/6/5	3844.25	3898.25	1.40%	3853.83	0.25%	3868.82	0.64%
2023/6/6	3808.16	3884.04	1.99%	3836.22	0.74%	3826.62	0.48%
2023/6/7	3789.34	3873.88	2.23%	3827.30	1.00%	3818.24	0.76%
2023/6/8	3820.19	3878.61	1.53%	3800.82	0.51%	3786.83	0.87%
2023/6/9	3836.70	3876.62	1.04%	3825.24	0.30%	3815.19	0.56%

中国知网 https://www.cnki.net

2023/6/12	3844.43	3869.54	0.65%	3834.42	0.26%	3827.10	0.45%
2023/6/13	3864.91	3856.93	0.21%	3844.77	0.52%	3841.34	0.61%
2023/6/14	3864.02	3896.09	0.83%	3863.99	0.00%	3873.47	0.24%
2023/6/15	3925.50	3885.67	1.01%	3862.36	1.61%	3861.89	1.62%
2023/6/16	3963.35	3887.93	1.90%	3907.95	1.40%	3904.33	1.49%
2023/6/19	3930.91	3902.25	0.73%	3930.33	0.01%	3992.57	1.57%
2023/6/20	3924.24	3880.86	1.11%	3913.49	0.27%	3970.74	1.18%
2023/6/21	3864.03	3859.62	0.11%	3881.88	0.46%	3890.06	0.67%
2023/6/26	3809.70	3843.71	0.89%	3837.21	0.72%	3840.84	0.82%
2023/6/27	3845.43	3851.86	0.17%	3846.54	0.03%	3850.64	0.14%
2023/6/28	3840.80	3836.24	0.12%	3841.61	0.02%	3843.96	0.08%
2023/6/29	3821.84	3838.55	0.44%	3833.00	0.29%	3834.21	0.32%
2023/6/30	3842.45	3835.86	0.17%	3816.23	0.68%	3815.49	0.70%
均值	3858.00	3870.34	0.98%	3850.05	0.53%	3862.34	0.81%

如表 5-4 所示，三种组合方法形成的 ARIMA-BP-LSTM 模型对中证 100 指数预测的结果表现很不错，加权平均法组合模型预测效果最好，变权组合法组合模型预测的效果次之，而等权重法组合模型预测的效果在三个组合模型中最差，因为每个单一模型预测的性能是不一样的，将它们预测的结果最为直接的进行平均，将会弱化性能较好的单一模型。三个组合模型预测出的相对误差基本保持在2%以内，可以看出，组合模型可以降低单一模型预测结果中出现偏差较大的情况，提高模型的稳定性和准确性，其中等权重法组合模型预测出的值出现几个误差较大的值（2.57%和 2.23%），表明等权重法组合模型提高模型的稳定性没另外两个模型的小强。而变权组合法出现的异常值 2.57%，是因为用变权组合法动态调整每个预测值的权重，需要用历史预测值进行优化，因此前面两个预测值通过将三个预测模型的均值作为变权组合法组合模型的初始值，可以看出，变权组合法组合模型预测出的其余相对误差基本保持很低的水平。三个组合方法都有预测出相对误差最小的值，等权重法组合模型最小的相对误差为 0.12%，加权平均法组合模型最小的相对误差为 0.00%，边权组合法组合模型最小的相对误差为 0.08%，可见组合模型在一定程度上比单一模型具有更高的预测效果。

从相对误差的均值来看，等权重法的均值为 0.98%，表明用它形成的组合模型对股票预测中相对稳定；加权平均法相对误差的均值为 0.53%，表明用它进行

中国知网 https://www.cnki.net

对股票进行预测具有最好的预测效果，通过分配不同的权重明显提高模型的预测能力；变权组合法相对误差的均值为 0.81%，它是根据时间变化动态的调整每个模型的参数。因为变权组合法的权重是动态调整的，在股票市场波动较大时，更为实用，可以在很大程度上提高模型的适应能力。

表 5-5　三个单一模型的评价指标

ARIMA-BP-LSTM组合方法	MAE	RMSE	MAPE
等权重法	37.68	46.89	0.98%
加权平均法	20.41	26.77	0.53%
变权组合法	31.43	38.88	0.81%

如表 5-5 所示是用等权重法、加权平均法和变权组合法形成的组合模型对股票预测结果的整体性评价，从中可以看出，加权平均法组合模型的预测效果是最好的，表明它很好的整合了三个单一模型的优势，评价指标MAE、RMSE和MAPE分别是 20.41，26.77 和 0.53%，显著低于等权重法组合模型的预测结果。加权平均法的 MAE 为 20.41，低于等权重法的 37.68 和变权组合法的 31.43。同样，加权平均法的 RMSE 指标为 26.77，低于等权重法的 46.89 和变权组合法的 38.88。表明加权平均法预测出股票数据具有最小的波动性。加权平均法的 MAPE 仅为 0.53%，远低于等权重法的 0.98%和变权组合法的 0.81%，表明组合模型的预测准确率较高，其中加权平均法预测出的结果最好。

中国知网 https://www.cnki.net

第六章 总结与展望

6.1 总结

本文主要是对中证 100 指数的收盘价进行预测，使用 ARIMA 模型、BP 神经网络模型和 LSTM 神经网络模型分别进行预测，并基于三个单一模型的预测结果，构建了一种组合模型，研究表明，组合预测模型比单一模型在预测中证 100 指数时表现更好，单一模型中 BP 神经网络模型预测的结果准确率最高，它的 MAPE 为 0.73%。变量选取中，本文通过相关性分析，从价格指标、成交量指标、技术指标、宏观经济指标、情绪指标和汇率指标等方面选取了 14 各指标作为 BP 神经网络模型和 LSTM 神经网络模型的输入变量，ARIMA 模型的输入变量为中证 100 指数的收盘价。

在单一模型预测中，BP 神经网络模型的预测效果是最好的，它的评价指标 MAE、RMSE 和 MAPE 分别是 28.22，33.40 和 0.73%，显著低于 ARIMA 模型和 LSTM 模型，表明 BP 神经网络模型很好地学习和适应了给定的复杂非线性数据。而 LSTM 神经网络模对中证 100 指数的预测效果相对另外两个模型较差，表明训练后的 LSTM 模型的泛化能力相对弱，它的评价指标 MAE、RMSE 和 MAPE 分别是 111.03，139.69 和 2.89%。ARIMA 模型对中证 100 指数的预测效果比较适中，它的评价指标 MAE、RMSE 和 MAPE 分别是 62.89，77.31 和 1.62%。

在组合模型预测中，加权平均法组合模型的预测效果是最好的，评价指标 MAE、RMSE 和 MAPE 分别是 20.41，26.77 和 0.53%，显著低于等权重法组合模型的预测结果，表明它很好的整合了三个单一模型的优势。加权平均法的 RMSE 指标为 26.77，低于等权重法的 46.89 和变权组合法的 38.88。表明加权平均法预测出股票数据具有最小的波动性。加权平均法的 MAPE 仅为 0.53%，远低于等权重法的 0.98%和变权组合法的 0.81%，表明组合模型的预测准确率较高，其中加权平均法预测出的结果最好。

ARIMA 模型适合对具有趋势性或稳定性强的数据具有较高的预测效果，对于波动性较大的股票数据，通常预测效果不是很好，因此，在用 ARIMA 模型对中证 100 指数进行预测时表现一般。BP 神经网络模型在对复杂的非线性数据进行预测时具有更好的效果，因此，用它对中证 100 指数进行预测时具有很好的预

中国知网 https://www.cnki.net

测效果，它的 MAE、RMSE 和 MAPE 均很低，表明它在捕捉股票数据的波动性和处理非线性方面具有较强的能力。LSTM 神经网络模型具有长时依赖性，在处理时间序列数据时具有较强的预测能力，可以很好地捕捉历史信息，用它对中证 100 指数进行预测时，表现差强人意，可能是中证 100 指数的波动性和数据特征较为复杂导致的。

组合模型可以降低单一模型预测结果中出现偏差较大的情况，提高模型的稳定性和准确性。组合模型在一定程度上比单一模型具有更高的预测效果。等权重法形成的组合模型对股票预测中相对稳定。加权平均法用它进行对股票进行预测具有最好的预测效果，通过分配不同的权重明显提高模型的预测能力。变权组合法根据时间变化动态调整每个预测值的权重，需要用历史预测值进行优化。在股票市场波动较大时，更为实用，可以在很大程度上提高模型的适应能力。

本文研究的创新点是提出一种新的模型组合方法，将多个模型的预测结果进行组合，从而提高了对股票的预测准确率。此外，从多角度选择了数据指标，充分考虑了影响股票价格波动的多方面因素，为模型提供了更加可靠的数据支持。

综上所述，本文研究中证 100 指数时，单一模型对股票预测时存在一定的局限性，预测出的股票值偶尔出现相对误差比较大的预测值，基于此，提出的组合预测模型预测出的结果更加稳定和准确，很少出现误差较大的预测值，这对股票预测歼九具有一定的参考价值。

6.2 展望

股票预测一直是金融领域中的热门话题，股票预测的准确性对投资者来说具有重要影响作用。基于本文的研究结果，通过对中证 100 指数的预测，可以对未来股票研究的趋势进行一定的展望。

首先，有更多的模型将会应用到股票预测研究中，除了本文使用的 RIMA 模型、BP 神经网络模型和 LSTM 神经网络模型外，还可以考虑其他类型的时间序列模型，机器学习和深度学习等。其次，将单一预测模型进行组合的方法可以得到进一步优化，提出效果更好的新方法。未来可以尝试用更多的组合方法，如集成学习法，模型融合等方法，获得更加稳定准确的预测结果。最后，影响股票的相关数据如市场情绪指标等更加全面丰富，机器学习和神经网络在股票预测领域中将会获得更快的发展。

中国知网 https://www.cnki.net

参考文献

[1]陈志勇. 股票预测中的文本大数据挖掘研究[D].西北大学,2015.

[2]李春伟. 基于神经网络与遗传算法的股票智能预测[D].西北工业大学,2005.

[3]杨易. 基于机器学习算法模型的白酒股票预测研究[D].山东大学,2022.

[4]厉晓洁,夏换.基于机器学习算法的股价回归预测研究[J].科技资讯,2023,21(14):227-231.

[5]黄梦婷.基于 ARIMA 模型的股票价格预测实证研究[J].内江科技,2023,44(03):61-62.

[6]曾丽芳,李丽萍,江绍萍.基于 BP 神经网络的股票价格预测[J].云南民族大学学报(自然

[7]张杰. 基于 LSTM 的股票预测实证分析[D].山东大学,2020.

[8]王莉琳,张维,赖敏等.基于 ARIMA-GM 组合模型的湖北省电力需求预测研究[J].我国农村水利水电,2013(04):101-105.

[9]于春蕾,李梦悦,尹伟石.基于 PCA-BP 组合模型的股价预测分析[J].长春理工大学学报(自然科学版),2021,44(04):125-130.

[10]高宏.股票价格技术分析的数学原理及超前预测方法[J].我国商论,2023(12):121-125.

[11]郝雨婕.万科股票的基本面分析报告[J].现代营销(信息版),2019(09):5.

[12]周润佳.基于深度学习的股票趋势预测算法[J].计算机与现代化,2023(01):69-73+107.

[13]褚剑峰. 基于自然语言处理与深度学习的网络舆情对股票影响的研究[D].上海财经大学,2023.

[14]Huang, X., Zhou, H., & Zhu, H. (2005). A framework for tying macroeconomic forecasts to the stock market. Journal of Financial and Quantitative Analysis, 40(4), 935-958.

[15]Kim T, Kim H Y. Forecasting stock prices with a feature fusion LSTM-CNN model using different representations of the same data[J]. PloS one, 2019, 14(2): e0212320.

[16]Yaqub M U, Al-Ahmadi M S. Application of combined ARMA-neural network models to predict stock prices[C]//Proceedings of the The 3rd Multidisciplinary International Social Networks Conference on SocialInformatics 2016, Data Science 2016. 2016: 1-5.

[17]Bollen, J., Mao, H., & Zeng, X. (2011). Twitter mood predicts the stock market. Journal of Computational Science, 2(1), 2-8.

[18]刘洁.ARMA 模型在股票价格预测中的应用——以格力电器为例[J].我国管理信息化,2021,24(11):153-155.

中国知网 https://www.cnki.net

[19]赵康银,薛亚楠.基于 ARIMA 模型的 TCL 集团股票预测及评价[J].广西质量监督导报,2020(09):144-145.

[20]郭改文,王诗涵.基于灰色理论与 ARIMA 模型的股票价格预测[J].河南教育学院学报(自然科学版),2023,32(02):22-27.

[21]谢玉莹.基于 ARIMA 类模型的农业股票价格实证研究——以隆平高科为例[J].河北企业,2023(02):40-42.

[22]丁宇昕. 基于 SVM 的股价预测模型研究[D].山西大学,2022.

[23]林娜娜,秦江涛.基于随机森林的 A 股股票涨跌预测研究[J].上海理工大学学报,2018,40(03):267-273+301.

[24]胡佩. 基于 ANN 方法的股票预测模型[D].重庆大学,2015.

[25]丁宇昕. 基于 SVM 的股价预测模型研究[D].山西大学,2022.

[26]林娜娜,秦江涛.基于随机森林的 A 股股票涨跌预测研究[J].上海理工大学学报,2018,40(03):267-273+301.

[27]杨易. 基于机器学习算法模型的白酒股票预测研究[D].山东大学,2022.

[28]管健. 基于 RNN-CNN 模型股票价格预测方法研究[D].南京信息工程大学,2023.

[29]肖田田.基于 K-means-LSTM 模型的证券股价预测[J].科技和产业,2024,24(03):210-215.

[30]孙娜,周绍伟,潘姿宇.基于 XGBoost-LSTM 模型的多特征股票价格预测研究[J].数学建模及其应用,2023,12(04):32-39.

[31]曹玉贵,谢梦醒.基于 WD-CNN-LSTM 模型的股票价格预测分析[J].华北水利水电大学学报(社会科学版),2023,39(05):15-22.

[32]张怡.基于 ARIMA 和 AT-LSTM 组合模型的股票价格预测[J].电脑知识与技术,2022,18(11):118-121.

[33]刘一舟. 基于 LSTM 和 XGBoost 组合模型的股票走势预测研究[D].中南财经政法大学,2022.

[34]刘宇婷. 基于 DBLSTM-ARIMA 模型的股票价格预测研究[D].江西财经大学,2022.

[35]李佳徽. 基于 LS-SVR 和 Markov 混合模型的股票价格预测研究[D].重庆大学,2023.

[36]宋丽娜.基于情感分析和 PCA-LSTM 模型的股票价格预测[J].我国管理信息化,2021,24(21):159-161.

[37]朱柳燕. 基于 LSTM 和新闻情感的股票行情预测研究[D].苏州大学,2021.

科学版),2023,32(05):658-665.

中国知网 https://www.cnki.net

[38]李俊杰. 宏观经济指标组合预测的实证分析[D].东北财经大学,2022.

[39]郭为民.灰色理论和加权平均法组合预测家用空调产品销售量[J].内蒙古科技与经济,2021(15):61-62..

[40]王文姣,张娜.基于 LSTM 变权组合模型的股价预测[J].商展经济,2023(07):95-97.

中国知网 https://www.cnki.net