基于 ARIMA - RNN 混合模型的股价预测

管学英

(重庆工商大学 数学与统计学院，重庆 400067)

摘　要: 提升时间序列模型的预测精度需要全面了解其数据的线性和非线性复合特征，利用 ARIMA 以及 RNN 模型分别对时间序列进行建模，挖掘其线性以及非线性规律，最后得到两种模型的综合预估结果. 选取沪深 300 指数(000300) 2006 年 1 月 4 日 ~ 2021 年 11 月 26 日中所有交易日的 K 线数据为样本，分析结果说明，ARIMA - RNN 混合模型的精度比单一循环神经网络模型的预测精度要高，混合模型对于短期动态与静态预测成效较高，有利于投资者和企业做出更加科学可行的决策.

关键词: 股票价格; 组合模型; ARIMA 模型; 循环神经网络; 深度学习

中图分类号: F832.5; TP183　**文献标识码:** A　**文章编号:** 1672 - 0946(2024)02 - 0250 - 07

DOI:10.19492/j.cnki.1672-0946.2024.02.008

Stock price prediction based on ARIMA - RNN hybrid model

GUAN Xueying

(School of Mathematics and Statistics, Chongqing Technology and Business University, Chongqing 400067, China)

Abstract: Improving the prediction accuracy of a time series model required a comprehensive understanding of the linear and nonlinear composite characteristics of its data, and this paper used ARIMA and RNN models to model the time series respectively, and mined the linear and nonlinear laws, and finally obtained the comprehensive prediction results of the two models. This paper selected the K-line data of all trading days of the CSI 300 Index (000300) from January 4, 2006 to November 26, 2021 as the sample, and the analysis results showed that the accuracy of the ARIMA-RNN hybrid model was higher than that of the single recurrent neural network model, and the hybrid model had a higher effect on short-term dynamic and static prediction, which was conducive to investors and enterprises to make more scientific and feasible decisions.

Key words: stock prices; combinatorial models; ARIMA model; recurrent neural network; deep learning

收稿日期: 2023 - 05 - 16.

基金项目: 经济社会应用统计重庆市重点实验室重点项目(KFJJ2022056)

作者简介: 管学英(1999 -)，女，硕士，研究方向: 数理统计.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

在人工智能算法蓬勃发展之前,回归分析等统计模型和自回归移动平均(ARMA) 等时间序列模型及其变体 [自回归条件异方差(ARCH) 和广义自回归条件异方差(GARCH)] 等流行于股票价格的. 然而这些统计模型并没有完全捕捉到股票价格数据的复杂性,因为股票数据是非线性的、非平稳的,甚至是季节性波动的,因此这些方法的基本假设很少得到满足.

近年来许多学者应用人工智能方法研究金融数据. 相关文献提出深度学习网络、模糊神经网络、支持向量机等基于人工智能技术的模型用于时间序列预测. 俞国红等(2013) 采用 ARMA 预测股价,先获取股价的线性信息,再利用单隐层前馈神经网络探究其非线性变化规律. 刘述忠(2018) 提出了基于 GM – RBF 神经网络的股价预测模型,张青(2019) 先利用 ARMA 模型分析“华泰证券”股票收盘价时序数据的线性规律,再用支持向量机分析其非线性部分,均可得到相对于单一预测模型,组合预测模型精度更高. 曾丽芳等(2022) 建立了 BP 神经网络模型、PCA – BP 神经网络模型、GA – BP 神经网络模型和 ARIMA(6, 1, 6) 模型对上证综合指数的收盘价格进行预测,结果表明 GA – BP 神经网络预测模型与其他三种模型相比具有更小的误差.

本文利用 ARIMA 和 RNN 的组合模型预测股票价格,将预测结果与股价实际值进行比较,并结合实例对组合模型的预测有效性进行验证.

1　模型介绍

1. 1　ARIMA 模型

ARIMA 模型,即差分自回归移动平均模型,是金融时间序列问题中常用于预测的模型,它的估计基础为实际问题中的历史数据,若股价遭受外界不可预测的冲击时(如金融危机等) ,该模型可快速做出调整,对时间序列中的一个时间段内的数据进行预测.

ARIMA 模型由三部分组合而成(自回归模型、移动平均模型以及差分) ,表示为 ARIMA(p,d,q) ,自回归(AR) 用于比较过去值和现在值之间的相似性,MA 为移动平均,考虑过去的预测误差对当前值的影响,d 为使序列平稳需要进行的差分次数.

ARIMA 模型的表现形式为:

$$y_t = \mu + \sum_{i=1}^{p} \gamma_i y_{t-i} + \varepsilon_t + \sum_{i=1}^{q} \theta_i \varepsilon_{t-1} \qquad (1)$$

其中: y_t 为当前值,μ 为常数项,ε_t 为随机扰动项序列.

ARIMA 模型建模步骤如下:

1) 对股价序列进行平稳性检验,通常股价数据波动会呈现非平稳状态,需对其进行差分运算,使得差分后的股价数据平稳;

2) 在数据平稳后对其进行白噪声检验;

3) 若序列为平稳非白噪声,利用软件计算数据的自相关系数与偏自相关系数,再进行时间序列相关模型识别(AR、MA、ARMA 等) ;

4) 根据模型对数据进行预测并分析.

1. 2　RNN 神经网络模型

对于复杂的非线性关系,神经网络模型的预测精度较高,故常用于金融时间序列数据. RNN 的特点在于按链式结构连接所有节点(即循环单元) ,是一种递归神经网络,输入为序列数据,在序列的演进方向进行递归 . RNN 神经网络包括双向循环神经网络和长短期记忆网络,这两种网络的应用较为广泛,结构见图 1.

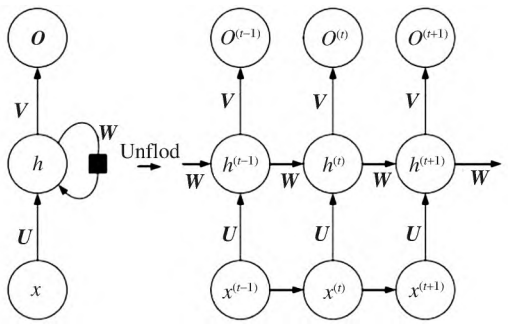

图 1　RNN 神经网络结构

Figure 1　RNN neural network structure

RNN 作为应用较为广泛的深度学习模型,其概念具有独特性,主要表现在其跨时间步上以及多个隐藏层存在于输入和输出之间. 每个层由一个时间步代表,神经网络在每一步学习到的数据特征都可以在所有时间步进行共享,由前向后依次进行每个时间步的输入,学习能力很强.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

RNN 的前向传播过程本质上是不断循环简单神经网络的传播,且时间步之间彼此相互关联,由当前时间步的隐藏层信息传递到下一时间步. RNN 输入到隐藏的连接由权重矩阵 U 参数化,隐藏到隐藏的循环连接由权重矩阵 W 参数化以及隐藏到输出的连接由权重矩阵 V 参数化. RNN 与传统多层感知机的最大区别是其内部多了时刻这个概念. 本次时刻的值由本次时刻的输入值与上一时刻的隐藏层的值的共同影响. RNN 隐藏层的值 h 由本次的输入值 x 和上一次隐藏层的值 h 共同决定. 由 RNN 计算展开图说明,在 t 时刻,输入值 $x^{(t)}$,隐藏层 $h^{(t)}$,输出值 $o^{(t)}$. $h^{(t)}$ 的值由 $x^{(t)}$ 和 $h^{(t-1)}$ 共同决定. 式(2)、(3)为 RNN 的计算方法:

$$o_t = g(Vh_t) \tag{2}$$

$$h_t = f(Ux_t + Wh_{t-1}) \tag{3}$$

RNN 的输出层中每个节点都连接到隐藏层中的每个节点,是一个全连接层. 将式(3)代入到式(2)进行迭代运算,可得如下复合函数:

$$o_t = g(Vh_t) = Vf(Ux_t + Ws_{t-1}) = Vf(Ux_t + Wf(Ux_{t-1} + Wh_{t-2})) = Vf(Ux_t + Wf(Ux_{t-1} + Wf(Ux_{t-2} + Wh_{t-3}))) = Vf(Ux_t + Wf(Ux_{t-1} + Wf(Ux_{t-2} + Wf(Ux_{t-3} + \cdots)))) \tag{4}$$

由式(4)可得 RNN 的输出值 o_t 受前面每次输入值的影响. RNN 适合处理时序数据. 具备如下两个优点:

1) RNN 是从一种状态转移到另外一种状态,在变化的历史状态下,RNN 在转移过程中不会有任何操作,使得最终得到的高学习效率模型必须输入大小相同.

2) 每个时间步都实现参数共享. 以上两个优点使得 RNN 在所有时间步长和所有序列长度下都可以合理地操作单个模型 f. 因此,RNN 不需要重新学习独立模型 g、f 通常代表激活函数,在 RNN 中选择双曲正切函数 tanh 作为激活函数,模型训练效果较好.

图2 为计算 RNN 训练损失的计算图,即将 X 作为输入序列映射到输出值 O 对应序列的训练损失计算图. 假设 O 是没有归一化的对数概率,当使用 softmax 输出时,损失 L 衡量每个与 O 对应训练的目标 y 的距离.

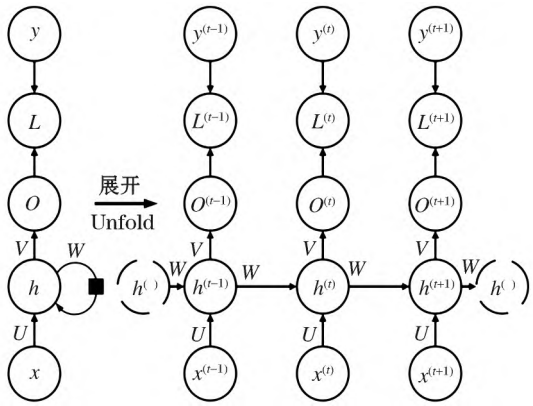

图2 计算循环神经网络损失的计算图

Figure 2 Computational plot for calculating recurrent neural network losses

损失 L 内部计算 $\hat{y} = \mathrm{softmax}(o)$,将得到的 $\hat{y}$ 与目标 y 做比较. 具体的更新方程如下:

$$a_t = b + Wh_{t-1} + Ux_t \tag{5}$$

$$h_t = \tanh(a_t) \tag{6}$$

$$o_t = c + Vh_t \tag{7}$$

$$\hat{y}_t = \mathrm{softmax}(o_t) \tag{8}$$

权重矩阵 U、W 和偏置向量 b 是输入层到隐藏层的连接; 权重矩阵 V 和偏置向量 c 是隐藏层到输出层的连接. 整个 RNN 将输入时间序列映射到相同长度的输入序列. y 是与 x 时间序列匹配的所有时间步的损失之和.

2 模型建立

2.1 ARIMA 模型建立与求解

本文选取沪深 300 指数(000300)股票在 2006 年 1 月 4 日 ~ 2021 年 11 月 26 日中所有交易日的日收盘价数据(共计 3 865 组),利用 Python 进行 ARIMA 建模并进行相关检验. 由于股价瞬息万变,最高价和最低价只能代表某一时点的供求关系情况,其对于股价的总体预测帮助不大. 股票的收盘价即为当天交易结束时的价格,股民经过了一天的股价动向观测分析,一般会选择在最后进行交易,因此本文选取收盘价作为研究对象. 见图 3.

根据时间序列建模步骤,首先要求序列必须平稳,即对数据进行平稳化处理,由沪深 300 指数收盘价时序图发现,该时间序列存在一定程度的波动性.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

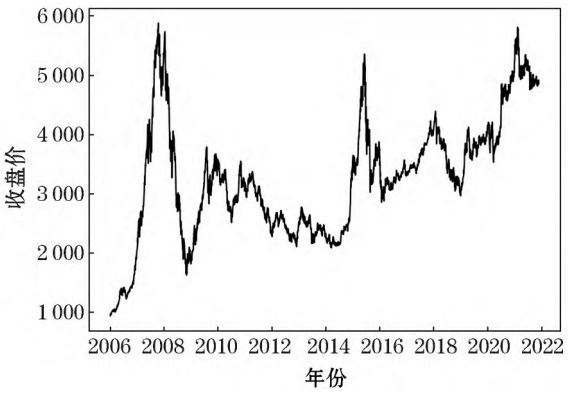

图 3　沪深 300 指数收盘价时序图

Figure 3　Timing of the closing price of the CSI 300 Index

对该序列进行单位根检验，得出 p 值较大，可以判断其为非平稳序列. 进一步运用差分法将其转化成平稳时间序列（见图 4）. 对一阶差分后的序列进行单位根检验，发现新序列是平稳的（不存在单位根），因此确定 d 取值为 1，建立 ARIMA（p，1，q）模型.

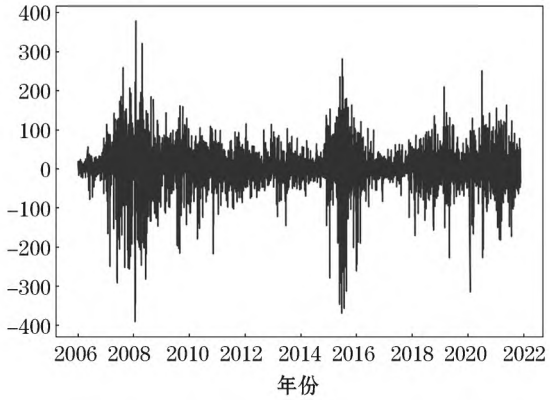

图 4　一阶差分后的时序图

Figure 4　Timing after first-order difference

根据图 5、6 确定 ARIMA 模型中参数 p 和 q 的取值.

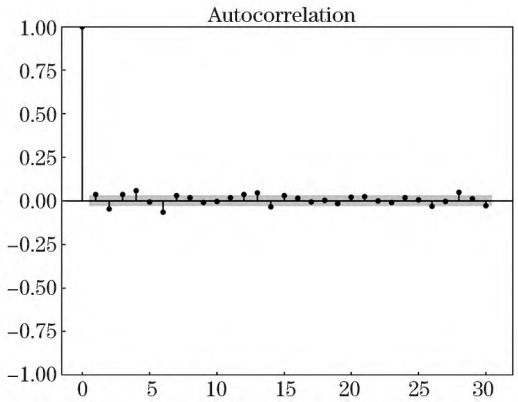

图 5　一阶差分后的 ACF 图

Figure 5　ACF plot after first-order difference

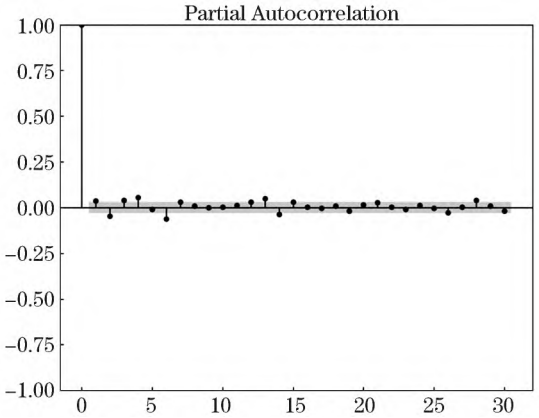

图 6　一阶差分后的 PACF 时序图

Figure 6　PACF timing after first-order difference

对差分后序列的计算其延迟 6 阶统计量，发现 p 值小于 0.05 的显著性水平，故其不能视为白噪声，即一阶差分后的序列还有重要信息需要挖掘. 由于该序列通过白噪声检验，根据 Python 建模可选择最佳阶数为 $p=2$，$q=3$，建模结果见表 1. 所有系数的置信区间都不包含零，故在 95% 的置信水平下，所有系数均显著.

表 1　ARIMA（2，1，3）建模结果

Table 1　ARIMA（2，1，3）modeling results

	系数	标准误	z	$P>\|z\|$	[0.025	0.975]
ar. L1	0.125 0	0.019	6.598	0.000	0.088	0.162
ar. L2	−0.917 5	0.017	−53.157	0.000	−0.951	−0.884
ma. L1	−0.085 3	0.022	−3.894	0.000	−0.128	−0.042
ma. L2	0.880 2	0.021	42.124	0.000	0.839	0.921
ma. L3	0.067 2	0.011	6.240	0.000	0.046	0.088
sigma2	3 371.762 9	41.152	81.395	0.000	3 291.107	3 452.419

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

接下来对模型进行相关检验,通过绘制残差及其密度图(见图7)验证残差项是否符合正态分布假定,显示残差项基本符合正态分布的特征.

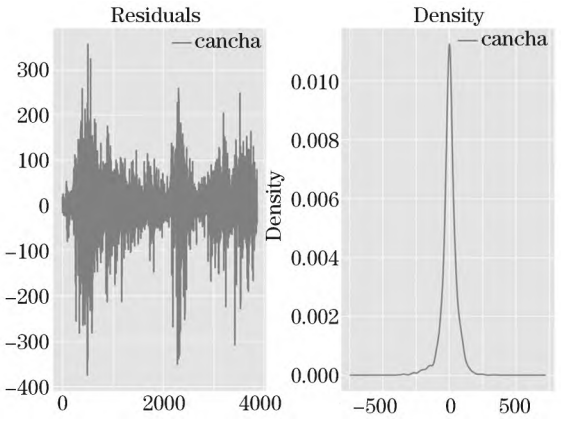

图7 残差及其密度图

Figure 7 Plot of residuals and their densities

预测后5天的股价与实际股价比较如表2所示,计算预测值与目标值之间的*MAE*为18.212 190,*RMSE*为23.179 900.

表2 ARIMA模型预测结果

Table 2 ARIMA model prediction results

日期	实际股价	ARIMA预测股价
2021-11-29	4 851.423	4 860.464
2021-11-30	4 832.026	4 859.407
2021-12-01	4 843.851	4 856.436
2021-12-02	4 856.163	4 857.035
2021-12-03	4 901.018	4 859.836

2.2 RNN模型建立

本文选取沪深300指数(000300)2006年1月4日~2021年11月26日中所有交易日的K线数据作为训练集(包含3 865组数据),2021年11月29日~2022年1月28日的数据(包含44组数据)作为测试集,包括开盘价、收盘价、最低价、最高价、成交量和成交金额等6个属性.

对训练数据最大值-最小值归一化,加速网络收敛,消除特殊特征的主导.每条样本含15个时间步,对应下一时间步作为标签值.利用Keras创建RNN模型,初始化顺序模型,定义输入层及带5个神经元的隐藏层以及线性的输出层,见图8.

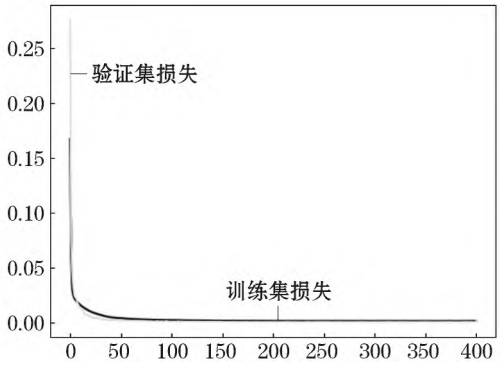

图8 RNN模型损失计算结果

Figure 8 RNN model loss calculation results

预测结果见表3.

表3 RNN模型预测结果

Table 3 RNN model prediction results

日期	实际股价	RNN预测股价
2021-11-29	4 851.423	4 914.929
2021-11-30	4 832.026	4 819.281
2021-12-01	4 843.851	4 789.710
2021-12-02	4 856.163	4 795.555
2021-12-03	4 901.018	4 967.391

循环神经网络预测目标值的走势形态与实际股价较为接近(见图9),计算预测值与目标值之间的*MAE*为51.474 620,*RMSE*为55.146 012.两个评价指标的值与ARIMA预测的结果对比得出ARIMA预测效果更佳.

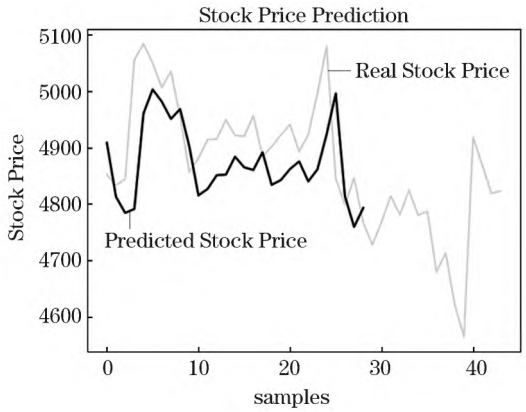

图9 RNN模型预测结果

Figure 9 RNN model prediction results

2.3 ARIMA-RNN模型建立

ARIMA模型的预测结果以及预测误差中分别包含沪深300股价的线性、非线性规律.基于这一

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

点,将 ARIMA 模型所得的误差序列输入 RNN 模型中,进一步分析其非线性规律,最后混合预测模型的预测值由 ARIMA 的预测结果与 RNN 的预测误差相加得到. 混合模型原理见图 10.

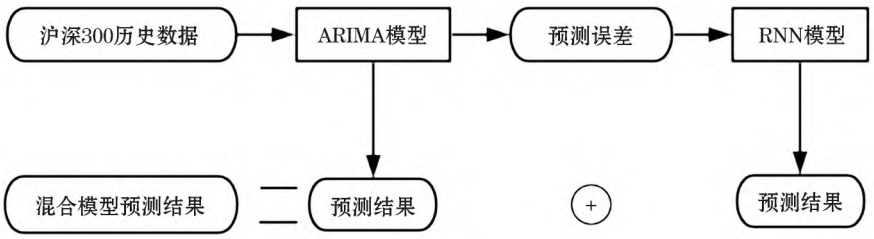

图 10　ARIMA – RNN 模型原理示意图

Figure 10　Schematic diagram of the ARIMA – RNN model

混合模型预测结果见表 4.

表 4　ARIMA – RNN 模型预测结果

Table 4　ARIMA – RNN model prediction results

日期	实际股价	ARIMA 预测股价	RNN 预测误差	混合模型预测股价
2021 – 11 – 29	4 851.423	4 860.464	– 4.165 992	4 856.298
2021 – 11 – 30	4 832.026	4 859.407	– 1.746 690	4 857.660
2021 – 12 – 01	4 843.851	4 856.436	– 1.349 618	4 855.087
2021 – 12 – 02	4 856.163	4 857.035	– 2.205 517	4 854.830
2021 – 12 – 03	4 901.018	4 859.836	– 6.667 532	4 853.168

衡量各个模型预测效果的优劣指标选择均方误差(*MSE*) 、均方根误差(*RMSE*) 和平均绝对误差(*MAE*) ,其定义分别为:

$$MSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i)^2 \tag{9}$$

$$RMSE = \frac{1}{N}\sum_{i=1}^{N}(y_i - \hat{y}_i^2)^{1/2} \tag{10}$$

$$MAE = \frac{1}{N}\sum_{i=1}^{N}(|y_i - \hat{y}_i|) \tag{11}$$

其中: $\hat{y}_i$ 为预测值, y_i 为实际值, N 为预测样本数.

如表 5 所示,可见 ARIMA 短期预测效果以及混合模型均优于 RNN 单一模型.

表 5　三种模型的统计指标

Table 5　Statistical metrics for the three models

统计指标	ARIMA	RNN	ARIMA – RNN
MSE	537.307 780	3 041.082 602	619.690 384
RMSE	23.179 900	55.146 012	24.893 581
MAE	18.212 190	51.474 620	18.185 486

从表 5 的对比结果可知,混合模型与 ARIMA 模型的预测效果较为接近. 部分学者在实证中得到神经网络模型相比于传统的时间序列模型的预测精度要高的结论,本文所选取的沪深 300 指数数据中并不适用. 对于大部分金融数据来说,神经网络的应用会更合适,具体问题需要进一步细化才能作出结论. 对于沪深 300 指数,ARIMA 模型的均方误差和平均绝对误差相对神经网络模型要低得多,这两种模型的预测能力谁更强并没有唯一的结论,只适用于部分股票,侧面说明股票价格的波动具有不确定性.

2.4　结论与展望

本文选取沪深 300 指数股票历史收盘价作为时间序列数据,构建了传统时间序列中的 ARIMA 模型、神经网络中的 RNN 模型以及 ARIMA – RNN 混合模型,对未来短期内的股票收盘价进行预测,ARIMA 与 ARIMA – RNN 混合模型的预测效果比单一的 RNN 模型理想,在实际股市分析中可以考虑选取这三种模型对股票价格数据作短期预测,再结合实时的市场加以判断,争取获得最大收益.

同时,本文提出的混合模型也存在不足,一是只采用静态和单步预测的方法,由于时间序列和神经网络可以实现多步预测,我们将在以后的工作中重点突破. 另外股价的波动是一个动态和连续的过程, 尝试考虑多个影响因素,细化指标,更合理地处理输入序列,以提高模型预测的准确性; 二是仅从相对误差上选取统计指标比较几种预测模型的拟合效果较为单一,若能综合考虑未来股价的变动趋势进行预测评价则会使模型更加完善,在模型中

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

考虑多方面的影响因素以及引创新性地构造股价指标,建模结果能够更加令人信服.

参考文献:

[1] 俞国红,杨德志,丛佩丽. ARIMA 和 RBF 神经网络相融合的股票价格预测研究[J]. 计算机工程与应用,2013(18):245-248.

[2] 刘述忠. 基于 GM-RBF 神经网络的股票价格预测分析[J]. 计算机与现代化,2018(8):8-11.

[3] 张 青. 基于 ARIMA-SVM 组合模型的创业板股票价格预测分析[J]. 广西质量监督导报,2019(12):131-132.

[4] 曾丽芳,李丽萍,江绍萍. 基于 BP 神经网络的股票价格预测[J]. 云南民族大学学报:自然科学版,2023,32(5):658-665.

[5] 陈小玲. 基于 ARIMA 模型与神经网络模型的股价预测[J]. 经济数学,2017(4):30-34.

[6] 任楚岚,宋才彦. 基于双向循环神经网络的金融数据预测研究[J]. 网络安全技术与应用,2022(4):53-55.

[7] 柏万宽. RNN 神经网络在股票指数价格预测模型的研究与应用[D]. 重庆:重庆大学,2018.

[8] 陈 佳. RNN 神经网络在股指预测中的应用研究[D]. 天津:天津科技大学,2020.

[9] 王子月. 循环神经网络股票预测[J]. 电脑知识与技术,2018(22):171-172.

[10] 张瑞雪,郝泳涛. 基于深度学习的股价预测研究[J]. 电脑知识与技术,2023,19(33):8-10.

[11] 孟海宁,童新宇,石月开,等. 基于 ARIMA-RNN 组合模型的云服务器老化预测方法[J]. 通信学报,2021(1):163-171.

[12] 沐年国,姚洪刚. 基于注意力机制的循环神经网络对金融时间序列的应用[J]. 现代电子技术,2021(14):1-5.

[13] 黄诗敏. 基于 ARIMA 模型的股价分析与预测——以招商银行为例[J]. 中小企业管理与科技,2022(11):184-187.

[14] KUFEL T. ARIMA-based forecasting of the dynamics of confirmed Covid-19 cases for selectedEuropean countries[J]. Equilibrium,2020,15(2):181-204.

[15] GAO S. Research on Stock Price Prediction Based on CNN-LSTM Combined Model[J]. Advances in Computer, Signals and Systems, 2023, 7(9): 73-79.

[16] JANA G C, SHARMAR, AGRAWALA. A 1D-CNN-Spectrogram based approach for seizure dection from EEG signal[J]. Procedia Computer Science, 2020, 167:403-412.

[17] REKHA K S, SABU M K. A cooperative deep learning model for stock market prediction using deep autoencoder and sentiment analysis[J]. PeerJ Computer Science, 2022, 8: e1158.

[18] CHO P, LEE M. Forecasting the volatility of the stock index with deep learning using asymmetric Hurst exponents[J]. Fractal and Fractional, 2022, 6(7): 394.

[19] PENG L, CHEN K, LI N. Predicting stock movements: using multiresolution wavelet reconstruction and deep learning in neural networks[J]. Information, 2021, 12(10): 388.

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net