河北经贸大学
Hebei University of Economics and Business

硕士学位论文

（学术学位）

基于两类改进的 MIDAS 模型的多维度混频股票价格预测研究

学位申请人：安肖倩

指 导 教 师：闫亮 副教授

学 科 专 业：统计学

学 位 类 别：理学硕士

培 养 学 院：统计与数学学院

答 辩 日 期：二〇二四年五月

中国知网 https://www.cnki.net

中图分类号：0213　　密　　级：公开

UDC：517　　学校代码：11832

基于两类改进的MIDAS模型的多维度混频股票价格预测研究

Research on multi-dimensional mixed stock price prediction based on two types of improved MIDAS models

学位申请人：安肖倩

指 导 教 师：闫亮 副教授

学 科 专 业：统计学

学 位 类 别：理学硕士

培 养 学 院：统计与数学学院

答 辩 日 期：二〇二四年五月

中国知网 https://www.cnki.net

摘要

在经济飞速发展的新时代，股票市场作为金融市场的重要组成部分，扮演着举足轻重的角色。它不仅有助于企业筹集资金来推动其发展，也为投资者提供了更广泛的投资机会。然而，股票市场的高风险性不容忽视，因此合理的股价预测能够为投资者提供指导，帮助降低其投资风险。

股票价格会受到来自多方面的影响，外部的宏观经济环境会对股票市场造成影响从而影响股票价格；企业自身的经营管理也会造成股价的变化；互联网时代信息交流方便，许多投资者通过网络获取最新的信息，投资容易受到影响；而股票的历史数据信息可以帮助识别股价发展的规律，很好的反映股票价格的趋势。因此本文从宏观经济环境、企业自身因素、投资者的因素、以及股票的历史数据几个方面对股价进行预测。由于选取的原始变量数较多维度过高，直接使用主成分分析难以实现降维的目的，而直接使用 Adaptive-Lasso 方法筛选出的变量维度仍然比较大，因此本文使用 Adaptive-Lasso 方法与主成分分析法的二次降维，充分利用数据信息。由于选取的指标因素较多，对于变量之间存在不同频率的数据，使用传统的方法对不同频率数据进行处理时，可能会造成信息的丢失，从而使预测结果不准确，使用混频数据抽样（MIDAS）模型可以实现对混频数据的预测。为提高预测精度本文基于以下两个方法探讨对混频数据下股票价格的预测。

（1）建立反向无约束混频数据模型（RU-MIDAS）实现低频解释变量对高频变量的预测。首先对高频的交易和技术指标以及低频的宏观经济指标进行 Adaptive-Lasso 以及主成分分析的二次降维构建 PCA-RU-MIDAS 模型，对不同频率的数据进行频率对齐，研究结果表明使用 PCA-RU-MIDAS 模型可以实现低频数据对高频收盘价的预测，相较与单一模型的预测精度有明显提升。

（2）在预测日度收盘价时将宏观经济指标和财务指标加入模型中，可以充分的利用影响股票价格的因素，提高股价预测的准确性。因此本文将不同观测频率的指标结合，构建 GARCH-MIDAS 模型将低频的月度宏观经济指标以及季度财务指标转化为高频的数据，并对两个指标以及基本交易技术指标进行 Adaptive-Lasso 以及主成分分析的两步降维法，选取第一主成分进行拟合，形成包含宏观经济信息以及财务信息的日度条件波动率。将日度条件波动率、基本交易技术指标以及投资者情绪值作为 BP 神经网络模型

中国知网 https://www.cnki.net

的输入特征来预测股票的价格。研究结果表明本文使用 GARCH-MIDAS-BP 混频模型与投资者情绪指标的加入可以提高模型的预测精度，证明了相较与单一模型以及非混频的模型本文构建的混频数据模型预测的有效性。

关键词：混频数据模型；Adaptive-Lasso；RU-MIDAS；GARCH-MIDAS；BP 神经网络；股价预测

中国知网 https://www.cnki.net

Abstract

In the new era of rapid economic development, the stock market, as an important component of the financial market, plays a crucial role. It not only helps companies raise funds to drive their development, but also provides investors with a wider range of investment opportunities. However, the high risk of the stock market cannot be ignored, so reasonable stock price predictions can provide guidance for investors and help reduce their investment risks.

Stock prices are influenced by various factors, with the external macroeconomic environment playing a crucial role in shaping the stock market and impacting stock prices. The operation and management of the enterprise itself can also cause changes in stock prices; In the Internet era, the easy exchange of information over the Internet has empowered investors to swiftly access the latest market updates, thereby influencing their investment decisions; The historical data information of stocks can help identify the patterns of stock price development and reflect the trend of stock prices well. Therefore, this article predicts stock prices from several aspects, including macroeconomic environment, enterprise factors, investor factors, and historical data of stocks. Since the number of original variables selected is too high compared with the multidimensional analysis, it is difficult to achieve the purpose of dimensionality reduction by direct use of principal component analysis, while the dimensions of variables screened by direct use of Adaptive-Lasso method are still relatively large. Therefore, in this thesis, Adaptive-Lasso method and principal component analysis method are used for secondary dimensionality reduction to make full use of data information. Due to the selection of many index factors, for the data with different frequencies among variables, the traditional method may cause the loss of information when processing the data with different frequencies, thus making the prediction results inaccurate. The mixed frequency data sampling (MIDAS) model can be used to predict the mixed frequency data. In order to improve the prediction accuracy, this thesis discusses the prediction of stock price under

中国知网 https://www.cnki.net

mixed frequency data based on the following two methods

(1) A reverse unconstrained mixed-frequency data model (RU-MIDAS) is established to predict the low-frequency explanatory variables to the high-frequency variables. Firstly, a PCA-RU-MIDAS model was constructed by Adaptive Lasso and the two-step dimensionality reduction method of principal component analysis for high-frequency trading and technical indicators and low-frequency macroeconomic indicators, and frequency alignment was performed for data of different frequencies. The results show that PCA-RU-MIDAS model can realize the prediction of high frequency closing price with low frequency data, and the prediction accuracy is significantly improved compared with that of a single model.

(2) Adding macroeconomic and financial indicators into the model when predicting daily closing prices can make full use of the factors affecting stock prices and improve the accuracy of stock price predictions. Therefore, this article combines indicators with different observation frequencies to construct a GARCH-MIDAS model that converts low-frequency monthly macroeconomic indicators and quarterly financial indicators into high-frequency data. The two indicators and basic trading technology indicators are subjected to Adaptive Lasso and a two-step dimensionality reduction method using principal component analysis. The first principal component is selected for fitting, forming a daily conditional volatility that includes macroeconomic and financial information. The daily conditional volatility, basic trading technical indicators and investor sentiment are used as the input features of BP neural network model to predict the stock price. The research results show that the GARCH-MIDAS-BP mixing model and the investor sentiment index can improve the prediction accuracy of the model, which proves the validity of the mixing data model constructed in this thesis compared with the single model and non-mixing model.

Key words: Mixing data model; Adaptive-Lasso; RU-MIDAS; GARCH-MIDAS; BP Neural Network; Stock price forecasts

中国知网 https://www.cnki.net

目 录

1 绪论.....1
1.1 研究背景和意义.....1
1.2 国内外研究现状.....2
1.2.1 传统预测方法.....2
1.2.2 神经网络预测方法.....2
1.2.3 混频预测方法.....3
1.2.4 LASSO 类预测方法.....5
1.2.5 文献评述.....6
1.3 研究方法.....6
1.4 研究内容及结构.....7
1.5 本文的创新点.....9
2 理论基础.....10
2.1 AdaptiveLasso 相关理论.....10
2.2 主成分分析相关理论.....11
2.3 混频数据模型相关理论.....12
2.3.1 MIDAS 模型.....12
2.3.2 RU-MIDAS 模型.....14
2.3.3 频率对齐方法.....15
2.3.4 GARCH-MIDAS 模型.....17
2.4 BP 神经网络相关理论.....18
3 基于 RU-MIDAS 的股票价格预测.....21
3.1 数据选取与处理.....21
3.2 宏观经济变量的筛选.....22
3.2.1 宏观经济指标的选取与处理.....22
3.2.2 宏观经济指标的筛选.....23
3.3 周频传统交易技术变量的筛选.....26
3.4 模型结果与比较.....27
4 基于 GARCH-MIDAS 的股票价格预测.....31
4.1 数据选取.....31
4.2 财务指标的筛选.....32
4.2.1 指标选取与处理.....32
4.2.2 财务指标的筛选.....33
4.3 传统指标的筛选.....35
4.3.1 传统指标选择与处理.....35

中国知网 https://www.cnki.net

4.3.2 传统指标的筛选.....35
4.4 情绪指标的构建.....36
4.4.1 股票文本的抓取与处理.....36
4.4.2 投资者情绪值的构建.....37
4.5 GARCH-MIDAS 模型估计波动率.....39
4.6 基于混频模型的 Adaptive-Lasso-GARCH-MIDAS-BP 模型的建立.....42
4.6.1 输入数据的预处理.....42
4.6.2 BP 神经网络模型的建立.....42
4.6.3 模型比较.....43
5 结论与展望.....46
5.1 结论.....46
5.2 展望.....46
参考文献.....48
附录 部分核心 R 代码.....52

中国知网 https://www.cnki.net

1 绪论

1.1 研究背景和意义

股市投资有风险入股须谨慎，但是随着我国金融经济的发展，人们的工资水平逐渐提高，物质和精神世界变得丰富多彩，为实现资产的增值不少人选择投资股票，因此股票投资在人们的生活中并不少见，股票市场是推动经济发展的强大动力来源，上市公司通过运营公司股票稳定公司发展，从而增加企业的实力。但是由于股票的价格会由于多种因素的影响涨跌，股票的运行情况非常复杂，股票价格的形成机制也是复杂繁琐的。股票投资与其他投资行为相比有较高的投资收益，但是高收益意味着较高的投资风险，互联网的普及使投资者有了较大的交流平台，同时一些信息也会造成投资者的投资倾向偏移，不利于投资者理性投资，从而会影响股票市场。政治、经济、市场因素以及技术因素都会导致股价的变化。因此，股票市场千变万化，由于股票价格的变动是不确定的，因此股票投资的风险很高。这种风险不仅对投资者不利，对国家的经济和企业的发展也不利。而随着现代计算机网络的发展，机器学习领域对于股票的预测结果更加高效和准确。从金融市场的预测到审批贷款、风险评估，机器学习算法对金融领域的发展起到了极大的促进作用，股票预测已经成为一种切合实际的需求。

股票市场对国家的经济发展也有十分重要的意义。但是由于股票市场的不确定性以及极大的风险性，股民不能准确掌握选择股票投资的科学理论，错误的投资方法可能会导致股价的波动，给自身带来更大的风险，因此对股票进行研究和预测有利于帮助投资者掌握投资方法，使投资更加科学合理。要建立股票预测模型，采用更科学合理的方法预测股票的未来走势及股票价格，为投资者提供科学的方法，使投资者更好地掌握股票预测的方法降低投资风险，选择具有高价值的股票进行投资，实现个人利益最大化。股票价格的变化是复杂的，不符合特定规律的，是受各种因素影响的，公司的财务状况、股票的历史数据、股票技术指标、社交媒体上的新闻信息以及财经网站上的投资者言论都会对股票的价格波动产生较大的影响。企业的财务情况决定投资者是否会选择该公司进行投资，通过分析企业的财务状况及发展前景决定投资主体。股票的历史数据反映该股票的历史发展趋势，历史研究的目的是让历史为现在服务而非盲目的信任历史，历史

中国知网 https://www.cnki.net

数据的价值在于他提供的历史事实，判断还是要主观进行。股票历史数据不代表未来的表现，但是可以根据历史数据提取变化特征，为研究提供数据支持。技术指标可以很好地反映股票的走势情况，对于股票市场的波动有很好的解释效果。因此结合多方面的指标数据可以全面地反映影响股票价格及波动的因素，运用神经网络预测模型对于股票的预测有很大的指导作用。

1.2 国内外研究现状

随着计算机应用的发展，各种统计方法发展迅速，对于股票的预测方法也呈现出多种预测方法，传统的统计方法对股票进行预测效果可能不太理想，随着人工智能和神经网络的发展，其更多的应用到股票预测当中，经过对大量的数据训练，可以起到很好的预测效果。

1.2.1 传统预测方法

传统方法在股票预测方面，钟骐[1]通过 R 软件建立 ARIMA-GARCH 模型，对 3 月最后三个交易日的收盘价进行预测，预测值与真实值非常接近，能够为有关该只股票的决策提供一定的帮助。胡雪梅、蒋慧凤[2]通过逻辑回归模型，将技术指标与之结合，得到提高可以提高股票价格预测精度的方法。杨宇塬、张梅[3]利用 ARIMA 模型对开盘价进行预测，预测结果表明误差较小，说明该模型对开盘价的预测具有现实意义，使用 ARIMA 模型进行预测可以提供给投资者和投资机构一些参考标准。由于股票价格数据具有非平稳和非线性的特点，传统模型对于线性模型具有很好的拟合效果，而对于复杂的股票价格数据无法很好地拟合，因此出现了许多新的模型和新的方法来预测股票的价格。深度学习就是一种很好的预测方法，其被日益广泛地应用于股票预测中，相比传统的预测模型，使用深度学习方法进行预测能够得到更好的结果。

1.2.2 神经网络预测方法

神经网络在股票预测方面，刘瑜儒等[4]在对股票价格进行预测时，首先采用 LSTM 模型进行预测，为保证模型预测的准确性采用了 GA 遗传算法，通过辨别机制，获取股

中国知网 https://www.cnki.net

票价格涨跌信号。梁宇佳、宋动峰[5]根据投资者情绪理论、自然语言处理方法和机器学习理论，使用 LSTM 模型，基于历史股票价格，并通过建立投资者情感指数来预测股票价格走势。赵传君等[6]用 LSTM 神经网络模型，构建包含股票历史交易数据和投资者情绪指标的预测模型，其中投资者情绪指标是用情感词典和金融词典将股票评论数据量化得到的。张月[7]将 BP 神经网络模型与其他模型相结合，组成多组合预测模型，并对 GA 遗传算法进行改进，最后得出不同模型的预测效果。赵昊然[8]将 LASSO 回归模型与神经网络模型相结合。首先利用 LASSO 回归模型对变量进行筛选降维，然后建立 BP 神经网络模型。周润佳[9]利用 CNN 和 LSTM 对特征进行提取，并结合注意力机制和对抗训练的股票趋势预测算法。朱睿琪[10]针对目前我国抱团股的走势和发展问题，利用时序序列的基本特点，使用了基于长短期记忆网络(LSTM)的方式对股票的涨跌进行了预测。

White[11]在 1988 开创了用神经网络理论预测股价的先河，用神经网络来预测 IBM 的每股收益。Hammad、HallAEL[12]等尝试利用多层 BP 神经网络预测约旦证券市场中的股价，通过此次研究证明了 BP 神经网络在预测某些股票市场的股价方面比传统的标准模型更准确。林杰等[13]从上证综指和深证成指中选取一些股票，根据以往的股票数据来预测股价，并取得了超出预期的结果。吴薇等[14]对上证综指的股指运用 BP 神经网络算法进行预测，并进行优化，最终得到了很好的预测精度。黄丽[15]将 BP 神经网络与免疫算法相结合，避免了神经网络陷入局部最小化，将预测模型中纳入非线性动力学特征的算法，避免了神经网络在训练时陷入局部最小化的可能。韩磊[16]通过 BP 神经网络对五只纳指股票的价格进行预测，测试结果表明预测效果有效。Kimoto 等[17]基于神经网络的 TOPIX 股票价格预测分析系统，对美国东京证券期权交易所的最新股票价格进行预测，结果表明，股票长期盈利表现能力表现方面神经网络模型要优于 TOPIX 加权平均指数。

1.2.3 混频预测方法

利用不同频率的数据构建模型时，直接进行同频化处理就会造成信息的丢失及预测结果的不准确。MIDAS 模型刚提出时，主要是用高频的金融数据对低频波动过程进行预测，或者对低频宏观经济变量利用高频宏观基本面数据进行预测。Ghysels 等[18]最早提出混频数据抽样（MIDAS）模型，它可以对混合频率的数据直接进行处理，不需要进

中国知网 https://www.cnki.net

行频率的转换。随着应用场景复杂性的提高，原始 MIDAS 模型也总是在不断地拓展。无约束 U-MIDAS 模型是 Foroni 等[19]人在 2015 年基于 MIDAS 模型提出的。Clements 和 Galvão[20]引入了被解释变量的滞后项作为解释变量，提出了 AR-MIDAS 模型。

李合龙等[21]用 GARCH-MIDAS 混频数据抽样模型研究投资者情绪对中国股市收益率波动的影响。吴鑫育和王小娜[22]构建双重非对称 GARCH-MIDAS（DAGARCH-MIDAS）模型，研究在不同样本区间内比特币对整体股票市场的影响，以及在全样本期间内比特币对不同行业股票市场影响。韩娅玲[23]采用 GARCH-MIDAS-A 模型，为了捕捉股票市场中的滞后效应和杠杆效应，从而在对股票市场的波动性研究中综合了长期、短期效应和不对称性效应。周昡[24]首次采用 GARCH-MIDAS-S-L 等混频模型预测中国股票市场的 VaR 和 ES。与传统的 GARCH 模型族对比，GARCH-MIDAS-S-L 等混频模型既可以刻画长期波动、区分长期不对称效应，也可以描述短期波动，区分短期不对称效应。雷立坤[25]等通过建立 GARCH-MIDAS 模型，基于经济不确定性指数和股价指数两个变量的影响，对上证综指波动率进行了分析，结果表明经济不确定性指数对波动率的预测有很大的改进。王新宇[26]等通过 GARCH-MIDAS 模型对利率和收盘价对数收益率的变化进行分析，表明二者会造成债券市场收益率的波动，间接影响了金融市场。

Xu[27]为解决非线性关系和混合频率数据的两个问题。为此，我们将混合频率数据引入 SVR 中，并开发了一个新的 MIDAS-SVR 模型。它可以通过求解二次规划的拉格朗日对偶技术来估计。然后，我们使用混合频率市场情绪作为协变量，应用 MIDAS-SVR 模型预测中国上证和深交所的周回报率。Krs 和 Karan[28]基于 MIDAS 和 GARCH 这两个基于统计的模型的充足波动率预测性能，并将结果与期权抽样的波动率指数进行了比较。我们的结果表明，与 GARCH 模型和 IV 方法相比，MIDAS 产生了优越的预测性能。罗楠等[29]为了解决处理复杂的相关性数据以及变量之间的采样频率差等问题，在数据结构不改变的情况下使用 MIDAS 模型和 Lasso 模型的组合模型对因变量进行预测。

然而 MIDAS 模型对高频变量预测低频变量的预测方面有较大的研究成果，但是在关于低频变量预测高频变量的情况没有很好的方法，这时就研究新的混频数据模型来针对这一问题。Foroni 等[30]提出了一种反向的用低频预测高频，并且不加约束的混频数据抽样模型（Reverse U-MIDAS）可以很好地对上述问题提供解决方法。利用低频预测高频时如果低频和高频之间的倍数差较小，那么该模型就会有很好的预测效果，但是如果对于低频和高频变量之间存在较大倍数差距的情况下，需要使用另一种混频预测模型。

中国知网 https://www.cnki.net

因此，在有关经济预测的方面，刘金全等[31]运用蒙特卡罗模进行模拟，发现 MIDAS 模型对中国宏观经济研究适用性很强，有很好的效果。王维国等[32]在使用 U-MIDAS 模型对中国季度 GDP 地进行预测时发现，模型的预测效果较好，因此该模型更适合在中国宏观经济中使用。许启发等[33]通过对 MIDAS 模型和 RU-MIDAS 模型进行研究，在这两个模型的基础上，施加了一个约束项，于是研究出了有约束的反向混频数据抽样模型（RR-MIDAS），将此模型运用于实际的数据模拟中可以发现其预测效果有较大的提升，预测效果良好。耿鹏等[34]分别用 MIDAS 模型对中国季度 GDP 预测，使用向前 h 步预测得到了很好的效果。

目前主成分分析、因子分析方法广泛应用于处理高维变量中。为将主成分分析方法与混频数据分析相结合。研究现状下关于主成分分析和混频数据分析的结合，会先将变量进行主成分分析提取主要因子，从而降低数据的维度，然后将筛选出的高频主要因子与低频因变量运用混频数据分析方法进行预测研究。Gao 和 Yang[35]首先对股指情绪指标和股指期货情绪指标使用主成分分析进行处理得到主要成分，然后再使用 MIDAS 模型，研究主要高频成分对低频股指期货收益的预测效果。

1.2.4 LASSO 类预测方法

在变量选择方面，秦晔玲和朱建平[36]基于变量选择的基本概念，对资产组合构建提出了自适应 Lasso 算法，并且运用该算法预测指数的未来走势。王爽[37]将 Lasso 及改进的 Lasso 方法与 BP 神经网络模型、平衡纵向数据模型及半参数 Logistic 模型相结合，探究组合模型在变量选择的上的应用。杨青龙等[38]对高维的变量使用 Lasso 方法做选择，然后使用传统 Logit 模型预测企业财务困境，并且对比了机器学习方法对企业财务困境的预测精度。牛勇等[39]为寻找商品房价格的影响因素，使用 Lasso 和 Adaptive Lasso 方法进行变量选择，分析合肥市商品房价格的变化主要受那些变量的影响。齐文雪[40]利用 Adaptive Lasso 方法，对我国中小企业信用风险进行建模。

Lasso 方法是统计学家 Tibshirani[41]在 1996 年提出的一种变量选择方法。Katayama 等[42]提出了用 Lasso 方法预测因子，并将其运用在高维多元线性回归分析的模型。

中国知网 https://www.cnki.net

1.2.5 文献评述

在本文中，对国内外股票价格预测的文献进行总结和整理，可以发现传统研究主要关注的是相同频率的数据，通过过滤原始数据来保持相同频率，这将导致信息丢失。

21 世纪初期，Ghysels[18]通过对波动率的研究在 MIDAS 模型的基础上发现了混频 GARCH-MIDAS 模型，国内外研究人员也运用相关模型对股市的波动进行研究。这一模型在保留了原始数据的信息的同时，深入探讨了相关变量对股票市场波动的影响。另一方面，由于宏观经济变量数目较多，维度较大，普通的降维方法计算复杂，在此情况下，使用 Adaptive-Lasso 方法选择变量指标，可以有效的避免经验判断，可以选取出更少的变量，并且变量筛选的速度更快。神经网络模型比传统模型的优点在于神经网络可以进行非线性处理，因此使用神经网络模型对数据进行预测，有较好的自适应性和学习能力。

首先，本文使用 Adaptive-Lasso 方法对变量进行选择，对选择出的宏观经济变量、技术交易变量、财务变量运用主成分分析方法得到主要因子。其次，使用混频 GARCH-MIDAS 模型预测条件波动率。最后，运用 BP 神经网络模型对股价进行预测，BP 神经网络模型的输入变量包括条件波动率（包含财务指标和宏观指标）、技术指标以及投资者情绪值。在实证部分建立 Adaptive-Lasso-GARCH-MIDAS-BP 模型，实证分析对比该模型与不含投资者情绪值的模型的预测效果。

1.3 研究方法

本文的研究方法如下：

（1）文献研究法：文献研究法：经过文献整理对有关股票预测的文献进行整理，对股票预测的方法有一定的了解，在此基础上构建本文研究框架。

（2）统计分析法：运用统计软件对数据进行整理，通过建立 Adaptive Lasso 对股票特征数据进行筛选，建立反向无约束混频数据模型（RU-MIDAS）、混频模型（GARCH-MIDAS）、神经网络模型进行预测分析。

（3）对比分析法：本文收集股票相关指标数据进行分析、整理，建立股价预测模型，首先加入宏观经济变量、财务变量、技术交易变量、投资者情绪变量，然后研究不

中国知网 https://www.cnki.net

加入投资者情绪时的模型，分析加入投资者情绪前后对模型预测准确率的影响。

1.4 研究内容及结构

本文针对不同频率的变量，研究基于非同频数据情况下股价的预测问题，现有研究已证实，股票波动率信息确实对股价有较强的预测性，故本文将股票的波动率作为 BP 神经网络模型的输入特征来对股价进行预测。由于所选取指标维度较大，需要进行降维处理，因此本文对宏观经济变量、财务变量以及传统技术交易指标，利用 Adaptive-Lasso 变量筛选方法对变量进行筛选，并用主成分分析进行进一步的降维。首先利用周频、月频数据对周频股票收盘价利用 RU-MIDAS 模型进行预测。对于月频、季频的不同频的数据采用GARCH-MIDAS模型估计波动率，然后运用BP神经网络模型对股价进行预测，BP 神经网络模型的输入变量包括条件波动率（包含财务指标和宏观指标）、技术指标以及投资者情绪值。本文的结构图如图 1-1 所示。具体章节安排如下：

第一章为绪论。主要包含研究背景和意义、国内外研究现状、研究内容和结构以及创新点。

第二章为模型理论。介绍文中使用模型的理论基础。包括 Adaptive-Lasso 模型、RU-MIDAS 模型相关理论、GARCH-MIDAS 模型相关理论、BP 神经网络模型的相关理论。最后，总结了评估各模型预测效果的评价标准。

第三章为 RU-MIDAS 实证分析部分。首先利用使用 Adaptive-Lasso 方法对月宏观经济变量、周频交易和技术指标进行变量筛选，并进行主成分分析降维，使用月频因子得分以及周频因子得分，利用频率对齐方法将高频周频数据与低频月频数据对齐，方便建立模型。使用 midasr 包中的 midas_r 函数对模型进行拟合，最后利用 predict 函数对股价进行预测。

第四章为 GARCH-MIDAS-BP 实证分析部分。主要是数据的选取与处理以及模型的构建。首先使用 Adaptive-Lasso 方法对输入变量进行筛选，以确保选取的变量具有较高的预测能力。其次，利用主成分分析方法对筛选后的宏观指标和财务指标进行降维，分别提取宏观因子以及财务因子的第一主成分，结合股票收益率构建 GARCH-MIDAS 模型，从而估计条件波动率。该模型包含了宏观经济变量和财务变量，能够更全面地反映市场波动情况。将条件波动率以及传统交易技术指标和投资者情绪指标加入 BP 神经网

中国知网 https://www.cnki.net

络模型中，基于该模型预测股票价格。并与不包含投资者情绪值的模型、与不使用 GARCH-MIDAS 模型的单一神经网络模型进行比较，最后得出本文所用模型的预测能力。

第五章为总结与展望。对本文的研究内容、方法和结论进行总结，并对可改进的地方提出了未来的展望。

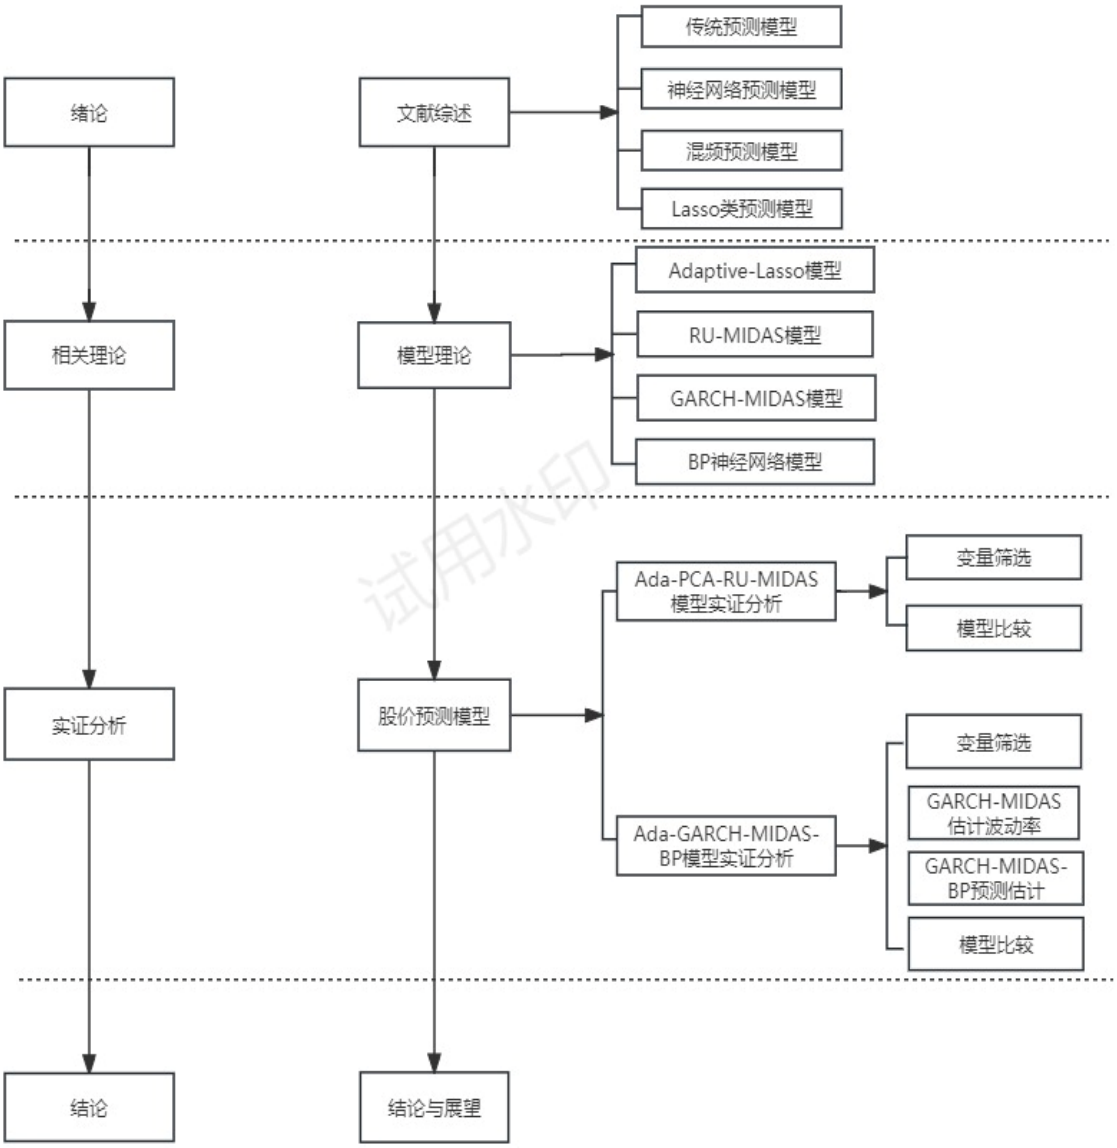

图 1-1 本文结构图

中国知网 https://www.cnki.net

1.5 本文的创新点

（1）股票价格的变化受基本股票指标、宏观经济指标、财务指标、投资者情绪等多种因素的影响，因此本文综合考虑以上影响股票价格的指标，并利用 Adaptive-Lasso 方法对原始变量进行筛选，提出分两步降维方法，基于 Adaptive-Lasso 和主成分分析法，从原始宏观指标中提取少数因子，选择对股票价格影响较大的主要变量并以主要变量建立模型，最大程度上保留了原数据的信息。

（2）在过去的研究中目前没有发现反向无约束混频抽样模型（RU-MIDAS）方法应用到股票预测中去，因此本文利用周频、月频指标结合主成分分析模型利用 RU-MIDAS 模型实现低频变量对高频变量的预测。

（3）由于各影响股票价格的指标之间的频率不同，因此为融合不同频率的数据考虑在混频数据下建立 GARCH-MIDAS 混频模型将不同频率的指标结合将低频信息转化成高频信息将其作为 BP 神经网络模型的特征输入之一与非混频数据时的预测结果对比，判断两种情况下的模型之间的预测精度和拟合程度。

中国知网 https://www.cnki.net

2 理论基础

2.1 Adaptive Lasso 相关理论

由于变量的维度较高，为从高维数据中进行变量选择，Lasso 方法将对因变量影响相对较小的变量从模型中消除，其对应的回归系数变为 0，最终实现变量降维。Lasso 通过对系数施加惩罚项，通过将某些变量系数趋向于零来排除，从而达到变量筛选的目的。通过选择与因变量最相关的变量来提高模型的预测精度。然而，Lasso 的缺点在于对于更动态的系统，Lasso 选择的变量可能不满足一致性。Zou[43]提出了 Adaptive-Lasso 其中自适应权重用于惩罚 II 范数中的不同系数。Zou[43]表明，Adaptive-Lasso 具有预言的特性——它能够筛选出正确的预测变量，且能够有效正确的估计非零估计量。

对 Lasso 方法的优化可以得到 Adaptive Lasso 方法，Lasso 回归将自变量的系数压缩，通过删除系数为零的变量，来剔除不重要的变量，从而实现变量筛选。对于样本数据 $(x_i, y_i), i=1,2,...,n$， $x_i=(x_{i1}, x_{i2},..., x_{ip})^T$ 是解释变量， y_i 是被解释变量。

令 $\hat{\beta}=(\hat{\beta}_1, \hat{\beta}_2,..., \hat{\beta}_p)$，则 $\hat{\beta}$ 的 Lasso 估计为：

$$\hat{\beta}=\arg\min_{\beta}\left\{\|Y-X\beta\|_2^2+\lambda\sum_{j=1}^{p}|\beta_j|\right\}, \tag{2.1}$$

其中 $\|Y-X\beta\|_2^2=\sum_{i=1}^{n}(Y_i-(X_i\beta))^2$ 。 $\hat{\beta}$ 的 Adaptive Lasso 估计为：

$$\hat{\beta}(\lambda)=\arg\min(\|Y-X\beta\|_2^2/n+\lambda\sum_{j=1}^{p}\frac{|\beta_j|}{|\hat{\beta}_{init,j}|}), \tag{2.2}$$

其中 $\lambda\geq 0$ 是惩罚项， $\hat{\beta}_{init}$ 是初始估计。Adaptive Lasso 首先选用岭回归方法对 $\hat{\beta}_{init}$，估计，选取调和参数 λ 时通过多次交叉验证方法；得出初始估计 $\hat{\beta}_{init}$ 后，选取调节参数 λ 进行计算时使用 10 折交叉验证的方法，可以计算出调节参数 λ。

Lasso 方法在 λ 的选取上起着至关重要的作用，它通过将系数趋向于零来实现对自变量的压缩，对于部分 j 来说，相比最小二乘方法，Lasso 方法能够使 $\hat{\beta}_j(\lambda)$ 更好的压缩，从而得到 $\hat{\beta}_j(\lambda)=0$，于是可以选取较为合适的变量。Lasso 方法的所有变量都受到同样的惩罚，可能发生过度惩罚或者低估变量的情况，但是 Adaptive Lasso 方法通过给不同

中国知网 https://www.cnki.net

的变量赋予不同的惩罚来选择变量，引入权重参数对每个变量的惩罚进行调整，当变量的系数较大时会分配一个较小的权重系数，使其受到的惩罚较小更容易在变量选择时被保留下来，而当变量系数较小时会有一个较大的权重系数去惩罚较小的变量系数，这样可以通过对不同变量的合理惩罚实现对变量的准确选择。Adaptive Lasso 方法改进了 Lasso 方法在变量选择中不能同时满足模型选择的相合性和参数估计达到 $\sqrt{n}$ 的收敛速度的不足，使得选出的变量更加精确。

2.2 主成分分析相关理论

主成分分析法（PCA）是一种数据降维的方法，主要原理是将原始变量进行重新组合，形成新的互相不相关的几个综合变量，这些综合变量被称为主成分，可以通过较少的主成分来表示原始变量的大部分信息，减少数据维度的同时保留数据的主要特征。通过将原始变量按照方差最大化的方向投影到新的坐标轴上，在新的坐标系上方差逐渐降低。方差越大，表示主成分包含的信息越多。主成分分析能够降低数据的维度，并且在最大程度上保留了原数据的信息，对数据降维有重要的意义。

主成分分析的主要步骤是：

（1）原始数据标准化

$$Z_{\mathrm{ij}} = \frac{x_{ij} - \bar{x}}{\sqrt{\mathrm{var}(x_j)}} \qquad i = 1,2,\cdots,n; \quad j = 1,2,\cdots,p \tag{2.3}$$

其中，$\bar{\mathrm{x}}_j = \frac{1}{n}\sum_{i=1}^{n} x_{ij}, \mathrm{var}(x_j) = \frac{1}{n-1}\sum_{i=1}^{n}(x_{ij} - \bar{x}_j)^2$， $j = 1,2,\cdots,p$

（2）计算相关系数矩阵

$$R = \begin{bmatrix} \mathrm{r}_{11} & r_{12} & \cdots & r_{1p} \\ r_{21} & r_{22} & \cdots & r_{2p} \\ \vdots & \vdots & \ddots & \vdots \\ r_{p1} & r_{p2} & \cdots & r_{pp} \end{bmatrix} \tag{2.4}$$

其中，$\mathrm{r}_{ij} = \frac{1}{n-1}\sum_{t=1}^{n} x_{ti}x_{tj}$， $i, j = 1,2,\cdots,p$。

（3）特征值特征向量的分解和选择

中国知网 https://www.cnki.net

$$F_{\mathrm{j}} = \alpha_{j1}x_1 + \alpha_{j2}x_2 + \cdots + \alpha_{jp}x_p \qquad i, j = 1,2,\cdots,m \tag{2.5}$$

（4）计算主要主成分相对应的贡献率

$$\text{第}K\text{个主成分的贡献率} = \frac{\lambda_{\mathrm{k}}}{\sum_{i=1}^{m}\lambda_i} \tag{2.6}$$

$$\text{第}K\text{个主成分的累计贡献率} = \frac{\sum_{i=1}^{\mathrm{k}}\lambda i}{\sum_{i=1}^{m}\lambda_i} \tag{2.7}$$

（5）计算主成分得分

$$\begin{bmatrix} \mathrm{F}_{11} & F_{12} & \cdots & F_{1K} \\ F_{21} & F_{22} & \cdots & F_{2K} \\ \vdots & \vdots & \ddots & \vdots \\ F_{\mathrm{n}1} & F_{n2} & \cdots & F_{nk} \end{bmatrix} \tag{2.8}$$

观察得到的主成分的累计贡献率 K。当累计贡献率越接近 1 时，说明所选主成分数据的整体信息的反映越准确。但是研究一般选取 K>85%，当 K>85%时认为主成分可以反映原始数据的主要信息，主成分的选择有效。

2.3 混频数据模型相关理论

2.3.1 MIDAS 模型

2004 年，Ghysels 等[18]人提出混频数据抽样模型（Mixed Data Sampling， MIDAS）。MIDAS 模型构建的思想源于分布滞后模型，它采用分布滞后模型的权重设置，利用高频数据和低频数据的信息来建立模型，通过多项式权重函数实现高频数据预测低频数据，通过将高频数据和低频数据结合起来，可以更加准确的分析和预测股票价格的变化。基础的 MIDAS(m，K)回归模型为：

$$y_t = \beta_0 + \beta_1 B(L^{1/m};\theta)x_t^{(m)} + \varepsilon_t^{(m)} \tag{2.9}$$

在此式中， y_t 为被解释变量（低频数据）， x_t 为解释变量（高频数据），m 表示因变量和自变量之间观测频率之比。比如说因变量为年度数据，自变量为季度数据，那

中国知网 https://www.cnki.net

么因变量和自变量之间的观测频率之比即为 m = 4。ε_t 为随机扰动项，服从于均值为 0 的正态分布。滞后权重多项式函数 $B(L^{1/m};\theta)$ 可表示为：

$$B(L^{1/m};\theta)=\sum_{k=0}^{K}w(k;\theta)L^{k/m} \tag{2.10}$$

其中，$w(k;\theta)$ 是权重函数，$L^{k/m}$ 是高频滞后算子，使解释变量滞后 k 期即 $L^{k/m}x_t^{(m)}=x_{t-k/m}^{m}$。L 表示解释变量 x_t 对应的最大滞后阶数。

在 MIDAS 建模过程中，L 的确定至关重要，不合适的滞后阶数可能会导致模型出现过拟合或者欠拟合的结果，从而对模型的预测效果也会产生影响，因此模型的最终形式和模型参数估计的结果取决于滞后阶数的选择。根据现有的研究发现，L 的取值与频率倍差 m 有关，当 m 较小时（例如，$m=4$），有 $L>>m$；当 m 处于中等水平时，L 约等于 m；当 m 较大时，有 $L<m$。MIDAS 模型中的参数根据滞后 K 阶解释变量来获取，若 y_t 是 2020 年的第三季度数据，x_t 是 2020 年的月度数据则 $x_{t-3/3}^{(m)}$ 表示为 2020 年六月的月度数据，$x_{t-1/3}^{(m)}$ 表示为 2020 年八月的月度数据，以此类推。有约束的混频数据抽样模型，权重函数的各权重值加和为 1。

MIDAS 模型具有下列优势：（1）模型形式简单，参数估计简单，结构灵活；（2）解释变量可以是不同类型的多个变量，这些变量的观测频率可以是多种，从而更全面的理解和分析问题；（3）可以保留高频数据的信息，同时可以实现对低频响应变量的准确预测；（4）具有很强的拓展性，可将其与 GARCH、ANN、SVM、BP 等模型相结合，构建组合模型，实现对混频数据的分析。

无约束 U-MIDAS 模型是 Foroni[19]等人在 2015 年基于 MIDAS 模型的基础上提出的，当对权重无约束即权重函数恒等于 1 时，模型由 MIDAS 模型转化为 U-MIDAS 模型。U-MIDAS 模型适用于变量之间观测频率差小的情况，该模型对权重没有限制，能较好解决 Almon 函数多项式在某些情况下存在的问题。U-MIDAS 模型可以直接使用最小二乘法进行参数估计，当输入变量和输出变量的观测频率差异很小时，U-MIDAS 的样本外预测效果比原 MIDAS 模型效果更好。

中国知网 https://www.cnki.net

2.3.2 RU-MIDAS 模型

Foroni 等[30]鉴于现有混频数据模型主要是利用高频数据中的信息，提高对低频数据预测的效果，高频响应变量与低频解释变量之间的动态关联关系无法被解释，基于此，提出反向无约束混频数据抽样（RU-MIDAS）模型，能够实现低频数据对高频数据的反向预测。Foroni 等[30]给出了 RU-MIDAS 模型推导的详细过程和估计参数的方法，运用 RU-MIDAS 模型，用季度数据来预测月度宏观经济指标，研究发现季度数据对月度宏观指标的预测结果会产生很大的影响。因此 RU-MIDAS 模型在金融市场和宏观经济领域预测中非常具有实用价值。

首先，将高频变量的时间下标定义为 $\tau = 1/m, 2/m, \cdots, (m-1)/m, 1, \cdots$ m 表示高频变量与低频变量之间存在的倍差，将低频变量的时间下标定义为 $t = 0,1,2,\cdots$。假设 x_t 为高频解释变量，y_t 为低频响应变量。L 为高频滞后算子，满足 $L^j x_t = x_{\tau - j/m}$，引入多项式汇总算子 $\omega(L)$，满足：

$$\omega(L) = \omega_0 + \omega_1 L + \cdots + \omega_{m-1} L^{m-1} \tag{2.11}$$

进一步引入低频滞后算子 Z，满足 $Z = L^m$，同时定义高频滞后算子多项式 $\gamma_0(L)$，使 $g_0(L) = \gamma_0(L) d(L)$。令 $\tilde{c}_0(L) = \gamma_0(L) c(L) \omega(L)$，$g_0(Z) = \gamma_0(L) d(L)$，$\tilde{\gamma}_0(L) = \gamma_0(L)\omega(L)$ 则：

$$\tilde{c}_0(L)\, x_t = g_0(Z) y_t + \tilde{\gamma}_0(L)\, e_{x\tau} \tag{2.12}$$

其中，$\tau = 0,1,2,\cdots$，上式为准确的 RU-MIDAS 模型。

Foroni 等[30]指出，RU-MIDAS 模型具有如下特点：（1）高频响应变量 x_t 受到自身高频滞后以及低频外生变量 y_t 的多阶滞后和误差项 $e_{x\tau}$ 的影响。（2）模型具有时期性，根据高频时期 $s = 1,2,\cdots,m$，可以得到高频时间下标 $t + s/m$，$t = 0,1,2,\cdots$，得到的模型形式也会不同。

RU-MIDAS 模型具有以下几个优势：（1）属于没有约束的单方程模型，并且简单灵活；（2）可以避免模型设定误差；（3）参数估计使用 OLS 估计方法，过程简单；

中国知网 https://www.cnki.net

（4）可以进行直接多步向前预测，使计算过程更加简单，避免误差累加。

2.3.3 频率对齐方法

将$\{y_\tau, \tau \in Z\}$表示高频被解释变量，其滞后过程表示为$L^H \mathrm{y}_\tau = y_{\tau-1/m}$，其中$L^H$表示高频滞后算子；$\{\mathrm{x}_t, t \in Z\}$表示低频解释变量，$L^L \mathrm{x}_t = x_{t-1}$表示滞后过程，其中低频滞后算子用$L^L$表示；$\{Z_\tau, \tau \in Z\}$表示高频解释变量，与高频被解释变量同频，$L^H \mathrm{Z}_\tau = Z_{\tau-1/m}$表示滞后过程。m 为低频和高频变量之间的观测频率差，当$m=1$时$\mathrm{x_t}$和y_τ频率相同，而当$m>1$时，$\mathrm{x_t}$和y_τ就不是同频关系，表示混频的数据。此时，在任意两个低频时刻 t 和$(t+1)$间隔内均可以在$\tau = \mathrm{t}+1/m, t+2/m, \cdots, t+m/m$时刻处观测到 m 个高频变量$y_{t+h/m}$和$Z_{t+h/m}$，其中$h=1,2,\cdots,m$。

为了实现$\mathrm{x_t}$对高频被解释变量y_τ的预测，需要根据二者之间的倍差 m，将高频变量y_τ转换为低频的形式，表示为$(y_{t+1/m}, y_{t+2/m}, \cdots, y_{t+m/m})^T$，从而实现将频率实现对齐，记为$\{y_{t+\mathrm{h}/m}\}_{\mathrm{h}=1}^m$，频率对齐矩阵表示为：

$$y_\tau \equiv \begin{bmatrix} y_{1/m} & y_{2/m} & \cdots & y_{m/m} \\ y_{l+1/m} & y_{l+2/m} & \cdots & y_{l+m/m} \\ \vdots & \vdots & \ddots & \vdots \\ y_{t+1/m} & y_{t+2/m} & \cdots & y_{t+m/m} \\ \vdots & \vdots & \ddots & \vdots \\ y_{T-1+1/m} & y_{T-1+2/m} & \cdots & y_T \end{bmatrix}, \tag{2.13}$$

其中，$T=1,2,\cdots,T$。

为将频率进行转换，根据频率倍差 m 和最大滞后阶数 l，将高频解释变量Z_τ转换为低频向量，表示为$(Z_t, Z_{t-1/m}, \cdots, Z_{t-l/m})^T$，频率对齐用矩阵如下：

中国知网 https://www.cnki.net

$$z_\tau \equiv \begin{bmatrix} z_\mu & z_{\mu-1/m} & \cdots & z_{\mu-1/m} \\ z_{\mu+1} & z_{\mu+1-1/m} & \cdots & z_{\mu+1-l/m} \\ \vdots & \vdots & \ddots & \vdots \\ z_t & z_{t-1/m} & \cdots & z_{t-1/m} \\ \vdots & \vdots & \ddots & \vdots \\ z_T & z_{T-1/m} & \cdots & z_{T-l/m} \end{bmatrix}, \tag{2.14}$$

其中，$t=u,u+1,\cdots,T$，u 是满足 $u-1/m>0$ 的最小整数；本文通过 AIC 准则或 BIC 准则来确定 l 的取值，当 m 较小时，有 $l \geq m$，而当 m 较大时，有 $l \leq m$。

从频率对齐的结果可以看出，高频变量 y_τ 可以划分为 m 个时期，记为 $h=1,2,\cdots,m$。其中，$\tau=t+1/m$ 时刻处观测到 $(y_{1/m},y_{1+1/m},\cdots,y_{t+1/m},\cdots y_{T-1+1/m})^T$，为 h=1 时期的数据；$\tau=t+2/m$ 时刻处观测到 $(y_{2/m},y_{1+2/m},\cdots,y_{t+2/m},\cdots y_{T-1+2/m})^T$，是 h=2 时期的数据；以此类推，$\tau=t+m/m$ 时刻处观测到 $(y_{m/m},y_{1+m/m},\cdots,y_{t+m/m},\cdots y_T)^T$，是 $h=m$ 时期的数据。

$t=1,2,\cdots,T$ 为 x_t 的观测时间，t 时刻的 x_t 与其后 m 个高频变量 $\{y_{t+h/m}\}_{h=1}^m$ 之间的观测数据的时间间隔会根据 h 的变化而发生变化。在 $h=1$ 时期上，x_t 与 $y_{t+1/m}$ 间隔一个高频时期；在 h=2 时期上，x_t 与 $y_{t+2/m}$ 间隔两个高频时期，由此可以推出，在 $h=m$ 时期上，x_t 与 $y_{t+m/m}$ 间隔 m 个高频时期。

假定响应变量 $\{y_{t+h/m}\}_{h=1}^m$ 受到低频解释变量 x_t 当期及其滞后 p 的影响，即 $(x_t,x_{t-1},\cdots,x_{t-p})^T$。

同时受到高频解释变量 Z_τ 滞后 1 期的影响，$(Z_{t+h/m-1/m},Z_{t+h/m-2/m},\cdots,Z_{t+h/m-l/m})^T$。分别在各个时期上 $h=1,2,\cdots,m$ $h=1,2,\cdots,m$，构建与 $(x_t,x_{t-1},\cdots,x_{t-p})^T$ 和 $(Z_{t+h/m-1/m},Z_{t+h/m-2/m},\cdots,Z_{t+h/m-l/m})^T$ 的回归模型，可得到 RU-MIDAS 模型形式表示如下：

$$y_{t+h/m}=\sum_{i=0}^{p}\beta_{h,i}x_{t-i}+\sum_{j=1}^{l}\alpha_{h,j}z_{t+h/m-j/m}+\varepsilon_{t+h}, \tag{2.15}$$

中国知网 https://www.cnki.net

其中，p 表示低频解释变量 x_t 的最大滞后阶数，$\beta_{h,i}$ 表示各滞后项的回归参数；l 表示高频解释变量 z_t 的最大滞后阶数，$\alpha_{h,i}$ 表示各滞后项的回归参数；$\varepsilon_{t+h/m}$ 为随机误差项；$h=1,2,\cdots,m$ 表示 $y_{t+h/m}$ 相对于低频解释变量 x_t 的向前预测步数。

通过分别构建 x_t 与 m 个高频 $\{y_{t+h/m}\}_{h=1}^{m}$ 之间的动态模型，可以发现，x_t 对 $\{y_{t+h/m}\}_{h=1}^{m}$ 的影响是通过 m 个时期上的 m 个模型的回归系数差异来体现的，是低频自变量对高频因变量短期影响，这个影响是动态的，可以更好的预测高频因变量的走势。

2.3.4 GARCH-MIDAS 模型

Engle[50]提出的 GARCH-MIDAS 模型研究低频宏观经济数据与高频股票市场波动的关系。将股价的波动分为短期成分和长期成分两个成分，受股票每日交易信息影响的短期成分用 GARCH（1，1）过程表示；受低频宏观经济指标影响的长期成分用 MIDAS 模型表示。具体表达式如下：

$$r_{i,t}=\mu+\sqrt{h_{i,t}\varepsilon_{i,t}} \tag{2.16}$$

$$h_{i,t}=\tau_i\times g_{i,t} \tag{2.17}$$

$$g_{i,t}=(1-\alpha-\beta)+\alpha\frac{(r_{i,t-1}-\mu)^2}{\tau_i}+\beta g_{i,t-1} \tag{2.18}$$

$$\tau_i=m+\sum_{j=1}^{M}\theta_j\sum_{k=1}^{K}\varphi_k(\omega_{1,j},\omega_{2,j})X_{t-k}^{F_j} \tag{2.19}$$

$$\varphi_k(\omega_{1,j},\omega_{2,j})=\sum_{j=1}^{M}\frac{(k/K)^{\omega_{1,j}^{-1}}(1-k/K)^{\omega_{2,j}^{-1}}}{\sum_{l=1}^{K}(l/K)^{\omega_{1,j}^{-1}}(1-l/K)^{\omega_{2,j}^{-1}}} \tag{2.20}$$

其中，M 为宏观变量的数量。其中，式（2.16）为均值方程，$\gamma_{i,t}$ 表示 i月第t天 股价的对数收益率，μ 是 $\gamma_{i,t}$ 的条件期望，通常取 0，条件波动率为 $h_{i,t}$，$h_{i,t}$ 由 $g_{i,t}$ 和 τ_i 构成。$g_{i,t}$ 是 $h_{i,t}$ 的高频短期成分，服从 GARCH（1，1）过程，α 与 β 为参数且满足 $\alpha+\beta<1$。τ_i 是

中国知网 https://www.cnki.net

$h_{i,t}$ 的低频长期成分，m 为常数项，$X_{t-k}^{F_j}$ 为第 j 个低频宏观因子的 k 阶滞后项，θ 表示第 j 个低频因子的各阶滞后项对 τ_i 的影响，θ 为正表明两者正相关，θ 为负表明两者负相关。K 表示解释变量 $X_t^{F_j}$ 的最大滞后阶数，式（2.19）中 $\omega_{1,j},\omega_{2,j}$ 是权重函数的参数，$\varphi_k(\omega_{1,j},\omega_{2,j})$ 为权重函数。

2.4 BP 神经网络相关理论

BP 神经网络（Back Propagation）又叫做是误差逆传播算法，是一种黑箱模式的建模工具，不需要知道映射关系的数学表达式，只需要输入和输出就可以自动构成网络，可以适应复杂的数据模式。由于神经网络具有非线性激活函数，可以处理非线性的问题，神经网络可以利用以往信息进行学习，快速计算最优解，训练出最优神经网络完成对未来的预测。使用快速下降法通过反向传播大量的训练数据和不断调整权值和偏置，使误差的平方和最小。

（1）神经元

每个神经元都接受来自其他神经元的输入信号，并对接收到的输入信号加权然后输入到激活函数中进行激活，得到最终的输出信号，然后作为下一层的神经元传递信息。通过神经元之间的连结和传递信息，神经网络可以实现对输入数据的处理和学习，最终输出准确输出结果。图 2-1 为神经元模型结构图。

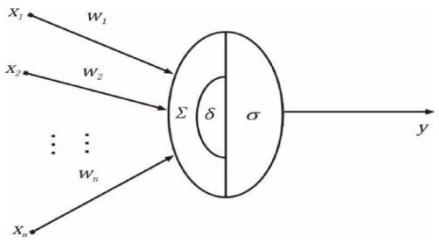

图 2-1 神经元结构图

（2）权值和偏置

权值和偏置是神经元之间连接的参数，主要用来调整信息的传递和处理过程。权值

中国知网 https://www.cnki.net

是神经元之间的连接强度或权重，每个连接都有一个权值来调整对下一个神经元的信号强度，是输入对输出的影响程度，连接上下两层神经元之间的权值为ω_1，ω_2,…，ω_n通常采用梯度下降法，神经网络会根据数据的反馈结果不断调整权重使输出结果变的更准确。偏置是神经元的一个参数表示神经元的偏移量，增强了神经元的灵活性，使其更容易适应各种输入数据。添加偏置项的作用类似于一个全局的常数，通过训练过程不断调整偏置，可以改变神经网络的输出结果。权值和偏置是神经网络中很重要的参数，对神经网络的效果影响很大。

（3）激活函数

添加激活函数就是为了增加非线性特征，线性是无法构成神经网络的，非线性可以增强神经网络的表达能力和拟合复杂函数的能力，因此对于非线性的问题来说需要通过激活函数进行转化得到一个非线性化的激活值。经常使用的激活函数有 sigmod 函数、Tanh 函数、relu 函数等。应用最广泛的是 sigmod 函数，其取值范围为（0，1），sigmod 函数和它的导数都是连续的。Sigmoid 激活函数为：$f(x)=\dfrac{1}{1+e^{-x}}$。

BP 神经网络是多层前馈神经网络，最基本的是三层前馈网络或三层感知器。其结构图如图 2-2 所示。

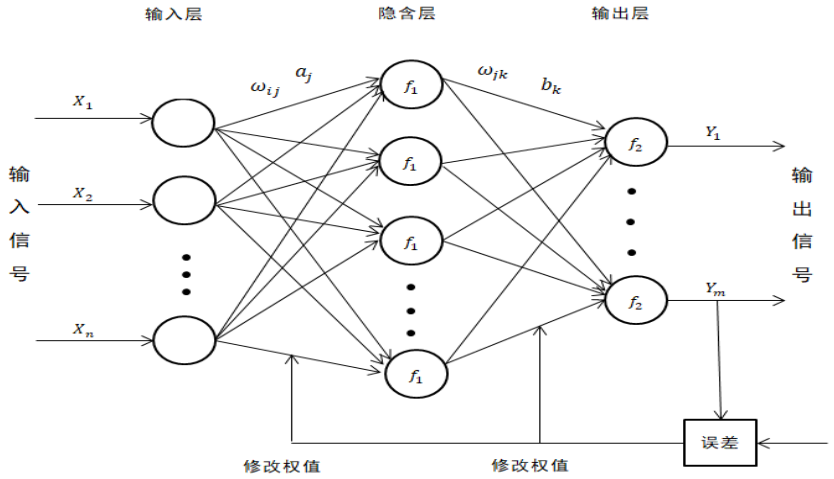

图 2-2 神经网络结构图

对于只含一个隐藏层的三层 BP 神经网络，模型传播过程如下：

（1）前向传播过程

中国知网 https://www.cnki.net

输入信息通过输入层进入网络，经过输入层与隐藏层之间的权值 ω_{ij} 以及偏置 a_j 的调整得到隐藏层第 j 个节点的输入值，通过 f_1 激活函数的激活得到得到隐含层第 j 个节点的输出值 Z_j 。

$$Z_{\mathrm{j}} = f_1(\sum_{i=1}^{N_1} \omega_{ij} X_i + a_j) \tag{2.21}$$

隐藏层的输入值经过隐藏层与输出层之间的权值和偏置调整得到输出层第 k 个节点的输入值，再输出层经过激活函数 f_2 的激活得到输出层的输出值 Y_k 。

$$Y_{\mathrm{k}} = f_2(\sum_{j=1}^{N_2} \omega_{jk} Z_j + b_k) \tag{2.22}$$

（2）反向传播过程

由于参数是随机的，因此得出的结果会与真实的结果产生较大的误差，为减小这个误差，需要根据误差来调整参数，直到调整到误差最小，这个过程是需要反向传播来实现的。反向传播的就是根据计算的误差大小，根据梯度下降法，梯度将输出层开始到输入层逆向传播，不断更新每一层的权值和偏置，直到误差达到可以接受的水平。误差函数计算公式如下：

$$E_{\mathrm{p}} = \frac{1}{2}(\sum_{k=1}^{L_2} y_k - T_k)^2 \tag{2.23}$$

其中 E_p 表示误差函数， y_k 表示输出层第 k 个节点的期望值， T_k 表示输出层第 k 个节点的输出值。

中国知网 https://www.cnki.net

3 基于 RU-MIDAS 的股票价格预测

股票市场在金融市场中是不可或缺的一部分，因此股票市场会受到交易量和股价的影响，同时也会受到宏观经济的影响。MIDAS 模型和 U-MIDAS 模型只能解决由高频到低频的分析问题而对于由低频预测高频的数据分析问题无法得到解决，因此，需要使用一种新的反向无约束混频数据抽样（ReverseU-MIDAS）模型，为探讨低频变量对高频变量的影响，需要首先建立高频响应变量与低频解释变量之间的关系模型。

3.1 数据选取与处理

选取北方稀土 2010 年 1 月至 2022 年 9 月交易日的周度交易及技术指标数据，月度数据为从 wind 数据库中 2010 年 1 月至 2022 年 9 月的月度宏观经济指标，共 34 项特征指标，研究数据均来源于 Wind 数据库。其中 2010 年 1 月至 2022 年 9 月的周频收盘价为响应变量，周频交易技术指标以及月频的宏观经济指标为解释变量构建 RU-MIDAS 模型，根据混频时间序列数据对股价做出预测。

本文选取的原始变量数较多维度过高，直接使用主成分分析难以实现降维的目的，而直接使用 Adaptive-Lasso 方法筛选出的变量维度仍然比较大，因此，首先利用 Adaptive-Lasso 模型对交易指标数据以及宏观经济数据进行变量选择，降低变量的维度，再利用主成分分析法对所筛选变量进行二次筛选，选取与因变量关系显著的主要变量。比较采用二次降维与仅使用 Adaptive-Lasso 方法降维时对模型预测效果的影响。其次对数据进行对齐处理，根据频率对齐方法，将左侧高频被解释变量即周频变量，根据与宏观解释变量之间的倍差 m=4 进行对齐，使每个时期数据与低频宏观经济变量的频率一致，对高频交易和技术变量也进行相同的处理，转化为与低频宏观经济变量的频率相同的向量。

中国知网 https://www.cnki.net

3.2 宏观经济变量的筛选

3.2.1 宏观经济指标的选取与处理

通过查阅相关文献可知，大多数研究者只选取几个有代表性的宏观经济指标，选取指标的方法没有固定的标准。因此为了更加全面的反映宏观经济因素对股票价格的影响，本文共选取了 34 个宏观经济变量，总共包括经济状况、消费、工业、金融、贸易 5 个宏观经济层面。各个指标变量的含义如下：

（1）经济状况：包括财政收入（PFR）和支出（PFI）

（2）消费：包括居民消费价格指数（CPI）、消费者信心指数（CCI）、消费者满意指数（CSI）、消费者预期指数（CEI）、商品零售价格指数（RPI）、社会消费品零售总额（RS）。

（3）工业：包括工业生产者购进价格指数（PPIRM）、PPI：生产资料（PPImc）、PPI：生产资料：原材料工业（PPImcrmi）、PPI：生产资料：采掘工业（PPImce）、企业商品价格指数（CGPI）、CGPI：矿产品（CGPIm）、工业增加值（IVA）、PPIRM：有色金属材料类（PPIRMfmm）。

（4）金融：包括各个金融机构指标，人民币：各项存款（Firmbd）、人民币：金融债券（FIfd）、外汇贷款余额（Fifel）、外汇各项存款余额（FIfedb）、各项贷款余额（FIlb）、存贷差（FIdld）、人民币：流通中货币（Firmbc）、新增人民币贷款（Finl）。

（5）投资：包括固定资产投资完成额（ICFA）、第二产业固定资产投资完成额（CFAIsi）

（6）贸易：包括进出口金额（IOP）、进口价值指数（IPI）、美元兑人民币（AERusd）、欧元兑人民币（AEReuro）、港元兑人民币（AERhkd）、111 日元兑人民币（AERjpy）、人民币实际有效汇率指数（REER）、人民币名义有效汇率指数（NEER）。

由于宏观经济指标共有 34 个指标 153 个月度数据观测值，选取数量较大，各指标之间存在量纲不一致的情况，为后续处理数据方便，对宏观经济变量进行标准化处理，以保证各指标的量纲不会对结果产生影响。

中国知网 https://www.cnki.net

3.2.2 宏观经济指标的筛选

Adaptive-lasso 的惩罚项可以根据变量之间的相关性进行调整，从而可以有效地选择相关的变量。当变量的系数较大时会分配一个较小的权重系数，使其受到的惩罚较小更容易在变量选择时被保留下来。因此，为选出与股票价格相关性更强的解释变量，本文变量系数的压缩采用岭回归的方法压缩，对初始变量系数的选取使用十折交叉验证方法，利用 Adaptive Lasso 方法再次进行十折交叉验证，得到变量的最佳回归系数。初始回归系数和最佳回归系数如表 3-1。

表 3-1 宏观经济指标初始回归系数和最佳回归系数

变量名	变量涵义	$\hat{\beta}_{init,j}$	$\hat{\beta}_{opti,j}$
X_1	CPI	0.330	0.291
X_2	RPI	0.041	0.000
X_3	CCI	0.030	0.000
X_4	CSI	0.168	0.165
X_5	CEI	-0.148	-0.141
X_6	PPIRM	0.046	0.000
X_7	PPImc	0.099	0.395
X_8	PPImcrmi	0.073	0.000
X_9	CGPI	0.193	0.473
X_{10}	CGPIm	-0.091	-0.170
X_{11}	Firmbd	-0.158	-0.321
X_{12}	FIfd	-0.010	0.000
X_{13}	Fifel	-0.191	-0.281
X_{14}	FIfedb	-0.012	0.000
X_{15}	FIlb	-0.075	0.000
X_{16}	FIdld	-0.028	0.000
X_{17}	CFAIsi	0.122	0.197
X_{18}	IOP	0.141	0.172
X_{19}	IPI	-0.086	0.000

中国知网 https://www.cnki.net

表 3-1 宏观经济指标初始回归系数和最佳回归系数（续）

变量名	变量涵义	$\hat{\beta}_{init,j}$	$\hat{\beta}_{opti,j}$
X_{20}	AERusd	-0.042	0.000
X_{21}	AEReuro	-0.045	0.000
X_{22}	AERhkd	-0.040	0.000
X_{23}	AERjpy	0.153	0.128
X_{24}	REER	-0.045	-0.051
X_{25}	NEER	0.017	0.000
X_{26}	PFR	0.005	0.000
X_{27}	PFI	-0.032	0.000
X_{28}	PPIRMfmm	0.007	0.000
X_{29}	IVA	0.077	0.000
X_{30}	PPImce	-0.376	-0.954
X_{31}	RS	-0.008	0.000
X_{32}	Firmbc	-0.053	0.000
X_{33}	Finl	-0.022	0.000
X_{34}	ICFA	-0.094	-0.145

最终得到用于股票价格预测的 Adaptive Lasso 回归模型为：

$$\begin{aligned}\hat{Y} = {} & 0.2912X_1 + 0.1651X_4 - 0.1460X_5 + 0.3946X_7 + 0.4725X_9 - 0.1703X_{10} - 0.3206X_{11} \\ & - 0.2805X_{13} + 0.1965X_{17} + 0.1721X_{18} + 0.1275X_{23} - 0.0506X_{24} - 0.9540X_{30} - 0.1452X_{34}\end{aligned} \quad (3.1)$$

通过 Adaptive-Lasso 方法从 34 个宏观经济变量中筛选出对股票价格影响较大的 14 个重要解释变量，其中对股票价格有正向影响的有居民消费价格指数（CPI）、消费者满意指数（CSI）、PPI 生产资料（PPImc）、企业商品价格指数（CGPI）、第二产业固定资产投资完成额（CFAIsi）、进出口金额（IOP）、111 日元兑人民币（AERjpy）。对股票价格的负向影响有消费者预期指数（CEI）、CGPI 矿产品（CGPIm）、人民币各项存款（Firmbd）、外汇贷款余额（Fifel）、人民币实际有效汇率指数（REER）、PPI：生产资料采掘工业（PPImce）、固定资产投资完成额（ICFA）。

由于原始宏观经济变量维度较高，使用 Adaptive-lasso 筛选出的变量仍然较多，为

中国知网 https://www.cnki.net

避免指标间的多重共线性，且尽可能多地保留各指标的信息，本文对筛选出的 14 个宏观经济变量进行主成分分析降维得到宏观因子，在主成分降维之前需要检验数据是否适合该方法，首先对 14 个宏观经济变量进行 KMO 检验和 Bartlett's 巴特利球体检验得出 KMO 统计量为 MSA=0.73>0.7、巴特利特球体检验的检验统计值的显著性概率 P 值为 2.2e-16<0.05，故可以进行主成分分析。经过主成分分析最终得到 5 个主因子，其累计方差贡献率超过 80%。北方稀土经营范围为稀土精矿，稀土深加工产品、稀土新材料及稀土应用产品等，通过表 3-2 可知其第一主成分主要有 PPImc、CGPI、CGPIm、PPImce 表明第一主成分主要描述工业类产品价格指数信息，因此可以记为工业产品价格指数成分。第二主成分主要是金融和汇率方面的信息，因此记为金融汇率成分。

表 3-2 因子载荷矩阵

	Factor1	Factor2	Factor3	Factor4	Factor5
CPI	0.144	-0.649	-0.125	-0.178	0.043
CSI	0.267	0.182	0.726	-0.084	0.301
CEI	-0.045	0.013	0.987	0.131	-0.007
PPImc	0.991	-0.011	0.026	0.040	-0.104
CGPI	0.926	-0.186	0.022	-0.047	0.045
CGPIm	0.729	-0.234	0.405	0.165	0.349
Firmbd	0.257	0.551	0.067	0.633	0.469
Fifel	-0.103	0.849	0.125	0.369	0.203
CFAIsi	0.135	-0.386	-0.244	-0.093	-0.628
IOP	0.294	0.435	-0.101	0.736	0.007
AERjpy	0.090	-0.936	0.056	-0.129	-0.147
REER	-0.081	0.797	0.008	0.348	0.240
PPImce	0.952	-0.033	-0.001	0.137	-0.107
ICFA	-0.026	0.187	0.080	0.317	0.019

中国知网 https://www.cnki.net

3.3 周频传统交易技术变量的筛选

交易指标主要包括收盘价（close）、开盘价（open）、最高价（high）、最低价（low）、昨日收盘价（pre_close）、涨跌额（change）、涨跌幅（pct_chg）共 7 个交易数据指标。技术指标主要包括乖离率（BIAS）、随机指标（KDJ）、相对强弱指标（RSI）、威廉指标（WR）、移动平均线（MACD）5 项指标。

将收盘价作为因变量，其余 12 个指标作为自变量进行 Adaptive Lasso 回归，可以筛选出对收盘价有明显影响的变指标，结果表明有 8 个指标的系数被压缩到 0，各个变量的初始回归系数和最佳回归系数如表 3-3。

表 3-3 周频传统指标初始回归系数和最佳回归系数

变量名	变量涵义	$\hat{\beta}_{init,j}$	$\hat{\beta}_{opti,j}$
A_1	open	0.242	0.000
A_2	high	0.238	0.361
A_3	low	0.251	0.504
A_4	pre_close	0.244	0.133
A_5	change	0.089	0.000
A_6	pct_chg	0.011	0.000
A_7	BIAS	-0.009	0.000
A_8	KDJ	0.058	0.064
A_9	RSI	-0.203	-0.217
A_{10}	WR	-0.192	-0.269
A_{11}	WACD	0.367	0.397

可以发现系数不为 0 的变量有 7 个，因此利用 Adaptive-lasso 筛选出的传统变量为 high、low、pre_close、KDJ、RSI、WR、MACD，其中 high、low、pre_close、KDJ 均为正相关，最高、最低价、昨日收盘价以及涨跌额的升高均能反映股票价格的上涨，RSI、WR、MACD 为负相关。最终得到用于股票价格预测的 Adaptive Lasso 回归模型为：

$$\begin{aligned}\hat{Y} = {} & 0.361A_2 + 0.504A_3 + 0.133A_4 + 0.064A_8 - 0.217A_9 - 0.269A_{10} \\ & + 0.3973A_{11}\end{aligned} \tag{3.2}$$

由于主成分分析可以将高维变量合成低维的变量并且不会损失原始变量的信息，本文原始指标较多直接使用主成分分析降维效果不理想，难以实现降维的作用，因此在本文中先对原始指标经过 Adaptive-Lasso 方法剔除部分交易及技术指标后进行主成分分析

中国知网 https://www.cnki.net

降维，得出因子得分。首先对传统指标进行 KMO 检验和 Bartlett's 巴特利球体检验得出 KMO 统计量为 MSA=0.73、巴特利特球体检验的检验统计值的显著性概率 P 值为 2.2e-16<0.05 故可以进行主成分分析。表 3-4 为主成分分析的因子载荷矩阵，经过主成分分析得出两个主成分，其累计方差贡献率达到 81.4%。

表 3-4 因子载荷矩阵

	Factor1	Factor2
pre_close	0.993	0.093
high	0.989	0.132
low	0.936	0.117
KDJ	0.174	0.801
RSI	0.044	0.924
WR	-0.067	-0.971
WACD	0.386	0.438

3.4 模型结果与比较

RU-MIDAS 模型可以实现低频变量到高频变量的预测，高频变量为周度数据而解释变量包括高频周度数据和低频月度数据，视为一月为 4 周，则频率倍差 m=4，构建 RU-MIDAS 模型表示为：

$$\begin{aligned}\text{close}_{t+h/m} &= \alpha_{h,0} + \sum_{i=1}^{l_1} \alpha_{h,i}^{1} f1_{t+h/m-i/m} + \sum_{i=1}^{l_2} \alpha_{h,i}^{2} f2_{t+h/m-i/m} + \sum_{k=0}^{l_3} \beta_{h,i}^{1} h1_{t-k} \\ &+ \sum_{k=0}^{l_4} \beta_{h,k}^{2} h2_{t-k} + \sum_{k=0}^{l_5} \beta_{h,k}^{31} h3_{t-k} + \sum_{k=0}^{l_6} \beta_{h,k}^{4} h4_{t-k} + \sum_{k=0}^{l_7} \beta_{h,k}^{5} h5_{t-k} + \varepsilon_{t+h/m}\end{aligned} \tag{3.3}$$

其中，m 为频率倍差 m=4，$\alpha_{h,\mathrm{i}}$ 表示高频滞后变量的回归系数,$\beta_{h,k}$ 为低频滞后变量的回归系数，$\varepsilon_{t+h/m}$ 为随机扰动项。

本文使用 R 软件 midasr 包中的 midas_r 函数进行拟合。midasr 包分析混提供了处理混频时间序列数据处理的方法，是 MIDAS 回归进行估计、模型选择和预测的工具，主要针对响应变量和解释变量观测频率不同的指标变量。其中 midas_r 函数可以使用非线

中国知网 https://www.cnki.net

性最小二乘法对 midas 回归估计。mls 函数可以将高频的变量嵌入到低频率的时间序列数据中，是用于指定 MIDAS 模型的灵活函数。midas_r 函数在低频周期结束时观察低频变量的惯例，因此当前低频周期的高频值总是滞后的。该月度的第一周则是 3 个高频滞后落后，即月度对应每周的第一周例如，9 月的低频值应 9 月第一周。在一个低频月度周期内可以观察到 4 个高频周度数据。使用 mls 函数实现低频数据与高频数据对齐，将高频响应变量数据向低频数据对齐，将高频解释变量也进行低频对齐。根据对齐结果，将高频的周度变量划分为 m 个时期，本文 $m=4$， $h=1$ 时是在 $t+1/4$ 时刻观测到的高频变量的值， $h=2$ 时是在 $t+2/4$ 时刻观测到的高频变量的值， $h=3$ 时是在 $(t+3/4)$ 时刻观测到的高频变量的值，$h=4$ 时是在 $t+4/4$ 时刻观测到的高频变量的值。即在任意两个相邻低频时期 t 和 $t+1$ 内，在每个 $t+h/m$ 高频时刻都可以观测到高频变量。分别构建低频解释变量对随后 m 个高频解释变量的动态模型，实现对高频响应变量的预测。RU-MIDAS 模型估计结果为表 3-5。该模型表明低频变量的滞后性可以用来预测高频响应变量。

表 3-5 模型估计结果

变量名	估计值	P 值
截距项	0.215	0.000****
F_{11}	0.110	0.091*
F_{12}	1.115	0.143
F_{13}	-0.023	0.673
F_{14}	0.007	0.503
F_{15}	0.086	0.137
F_{16}	0.056	0.206
F_{17}	-0.015	0.677
F_{18}	0.006	0.698
F_{19}	-0.043	0.118
F_{110}	0.116	0.002***
F_{111}	-0.030	0.126
F_{112}	0.012	0.285
F_{21}	0.044	0.000****

中国知网 https://www.cnki.net

表 3-5 模型估计结果（续）

变量名	估计值	P 值
F_{22}	-0.006	0.722
F_{23}	-0.008	0.466
F_{24}	0.008	0.045**
F_{25}	-0.009	0.239
F_{26}	0.001	0.457
F_{27}	0.012	0.254
F_{28}	-0.001	0.989
F_{29}	-0.021	0.141
F_{210}	0.027	0.122
F_{211}	-0.011	0.265
F_{212}	-0.001	0.830
H_{11}	-0.030	0.189
H_{12}	0.001	0.999
H_{13}	0.037	0.270
H_{21}	-0.080	0.025**
H_{22}	0.010	0.909
H_{23}	0.065	0.431
H_{31}	-0.011	0.281
H_{32}	-0.003	0.816
H_{33}	0.020	0.145
H_{41}	-0.091	0.025**
H_{42}	0.002	0.982
H_{43}	0.080	0.326
H_{51}	-0.052	0.076*
H_{52}	0.011	0.871
H_{53}	0.041	0.473

注：“ ”、*、**、***、****分别表示在 10%、5%、1%、0.01%、0 显著性水平下显著。

除了建立 PCA-RU-MIDAS 模型外本章还建立了 RU-MIDAS 模型与本文建立的模型

中国知网 https://www.cnki.net

的预测效果进行比较，比较模型使用二次降维与使用一次降维的差别，模型预测效果如表 3-6 所示。

表 3-6 模型预测效果比较

	RMSE	MAE	MAPE
PCA-RU-MIDAS	5.418	4.763	12.600
RU-MIDAS	7.003	6.121	16.451

由表 3-6 可以看出，PCA-RU-MIDAS 模型的 RMSE、MAE、MAPE 均小于 RU-MIDAS，表明使用主成分分析方法进行二次降维对模型的预测效果有明显的提升，使用 RU-MIDAS 模型进行预测不能充分的提取众多数据中的信息，导致模型的预测效果较差。本文使用的 PCA-RU-MIDAS 模型使用主成分分析进行降维充分提取数据中的信息。

中国知网 https://www.cnki.net

4 基于 GARCH-MIDAS 的股票价格预测

由于股票价格的变动受到多种因素的干扰，其变化趋势会受到多个事件和条件的影响，仅单一因素的影响对于股票市场这个复杂的交易市场来说是不够客观的。股票市场中不仅存在投资者也存在被投资者，股票的投资是双向选择的过程，因此在其中投资不可比避免的要和投资者的相关行为有关，影响投资者行为的不仅取决于投资者自身的感情倾向还取决于企业的经营情况以及外部的经济大环境，因此我们需要尽可能全面的获取更多数据，从投资者角度、企业角度以及宏观经济环境角度出发，尝试获得更好的预测效果。

4.1 数据选取

由于影响股票价格的因素是多元的，对于股票市场数据其涉及范围较广，如微宏观方面、技术方面、消息方面、资金政策方面等，其中宏观经济指标反映整体的经济运行情况，而微观的财务指标则可以反映企业自身的运行情况，技术方面主要包括基本的交易数据以及各项技术指标，消息方面主要涵盖了公司的各类新闻内容以及投资者的言论，因此为了全面考察各方面因素对股票价格的影响，本文选取上海证券交易所上市的北方稀土（600111）2010 年 1 月 1 日至 2022 年 9 月 30 日的数据。研究数据来源于 Wind 数据库，其中，日度数据为从 2010 年 1 月 4 日至 2022 年 9 月 30 日的交易数据及技术指标；月度数据为从 wind 数据库中 2010 年 1 月至 2022 年 9 月的宏观经济指标，共 34 项特征指标；季度数据为 2010 年 3 月 31 日至 2022 年 9 月 30 日的北方稀土各季度的财报数据，共 17 项主要特征作为影响股票价格的截面数据特征。

LASSO 方法用于产生特征子集，而 PCA 用于特征降维和产生线性无关的特征。本文选取的原始变量数较多维度过高，直接使用主成分分析难以实现降维的目的，而直接使用 Adaptive-Lasso 方法筛选出的变量维度仍然比较大，因此本文使用 Adaptive-Lasso 方法与主成分分析法的二次降维，首先使用 Adaptive-Lasso 方法将高纬度的原始变量筛选部分指标后，对筛选出的变量进行主成分分析降维，以实现对原始变量信息的充分提取，既保证了模型的简洁性也保证了变量使用的充分性。

中国知网 https://www.cnki.net

4.2 财务指标的筛选

4.2.1 指标选取与处理

财务数据收集了从 2010 年 3 月 31 日至 2022 年 9 月 30 日的各季度的财报数据分别从利润表、资产负债表、现金流量表三个财务报表中选取总共选取 17 项主要特征作为影响股票价格的截面数据特征，具体指标见表 4-1：

表 4-1 财务指标

财务报表	指标含义
利润表	营业收入(万元)
	营业成本(万元)
	营业利润(万元)
	利润总额(万元)
	所得税费用(万元)
	净利润(万元)
	基本每股收益(元)
资产负债表	货币资金(万元)
	存货(万元)
	流动资产合计(万元)
	固定资产净额(万元)
	资产总计(万元)
	流动负债合计(万元)
	负债合计(万元)
	所有者权益(或股东权益)合计(万元)
现金流量表	期初现金及现金等价物余额(万元)
	期末现金及现金等价物余额(万元)

另外以每个季度最后一个开盘日的收盘价格作为对应的股票价格。财务报表分为年度财务报表或者季度财务报表，均是按照从年初到报告期为区间计算的，因此在对季度财务数据处理时应用当期季度数据减去上期季度数据才能得到当期季度数据，即第二季度财务数据为第二季度数据减去第一季度数据，同样第三季度数据等于第三季度数据减

中国知网 https://www.cnki.net

去前两季度的数据，第四季度数据为第四季度数据减去前三季度数据。

财务数据中各项变量的平均值之间差值较大，会造成回归结果偏差，影响回归准确性，因此为消除量纲因素对结果造成的影响，在建立模型前对财务数据各变量进行标准化处理，利用 R 中的 scale 函数对数据进行处理。对于给定数列 $x=(x_1,x_2,\cdots,x_n)$ 有

$$x'_i=\frac{x_i-\bar{x}}{\sigma} \tag{4.1}$$

4.2.2 财务指标的筛选

股票的价格受到诸多财务指标数据的影响，因此使用 Adaptive Lasso 对 17 项财务指标进行筛选，得到对股票价格影响较大的重要指标。财务指标初始回归系数和最佳回归系数如表 4-2。

表 4-2 财务指标初始回归系数和最佳回归系数

变量名	变量涵义	$\hat{\beta}_{init,j}$	$\hat{\beta}_{opti,j}$
C_1	营业收入(万元)	0.066	0.296
C_2	营业成本(万元)	-0.004	0.000
C_3	营业利润(万元)	0.165	0.000
C_4	利润总额(万元)	0.164	0.000
C_5	所得税费用(万元)	-0.033	-0.276
C_6	净利润(万元)	0.221	0.871
C_7	基本每股收益(元)	0.201	0.127
C_8	货币资金(万元)	-0.026	0.000
C_9	存货(万元)	-0.157	-0.149
C_{10}	流动资产合计(万元)	-0.104	-0.603
C_{11}	固定资产净额(万元)	-0.059	-0.057
C_{12}	资产总计(万元)	-0.104	0.000
C_{13}	流动负债合计(万元)	0.095	0.250
C_{14}	负债合计(万元)	-0.046	0.000
C_{15}	所有者权益合计(万元)	-0.140	-0.281
C_{16}	期初现金及现金等价物余额(元)	-0.013	0.000
C_{17}	期末现金及现金等价物余额(万元)	-0.056	-0.069

中国知网 https://www.cnki.net

最终得到用于股票价格预测的 Adaptive Lasso 回归模型为：

$$\begin{aligned}\hat{Y} = 0.296C_1 - 0.276C_5 + 0.879X_6 + 0.127C_7 - 0.149C_9 - 0.603C_{10} \\ - 0.057C_{11} + 0.250C_{13} - 0.281X_{15} - 0.069C_{17}\end{aligned} \tag{4.2}$$

可以看出各变量的回归系数中有 7 个压缩到了 0 分别有营业成本、营业利润、利润总额、货币资金、资产总计、负债合计、期初现金及现金等价物余额。对股票价格有正向影响的有营业收入、净利润、基本每股收益、流动负债合计四个变量，对股票价格有负向影响的有所得税费用、存货、流动资产合计、固定资产净额、所有者权益合计、期末现金及现金等价物余额 6 个变量。表明当营业收入、每股收益越多时，说明企业的效益好，具有较好的投资价值从而导致股票价格的上涨，而存货越多时表明公司的库存商品越多说明企业的营业负担加重，可导致股票价格的下跌。

由于主成分分析可以将高维变量合成低维的变量并且不会损失原始变量的信息，为了提高模型预测的精确度，将财务数据纳入后续 GARCH-MIDAS 模型，需要减少变量个数，因此进行因子分析，减少变量格式并保留较多的原始信息。首先进行 KMO 检验和 Bartlett's 巴特利球体检验得出，KMO 统计量为 MSA=0.7、巴特利特球体检验的检验统计值的显著性概率 P 值为 2.2e-16<0.05 故可以进行主成分分析。经过主成分分析最终得到 4 个主因子，其累计方差贡献率为 79.1%。因子载荷见表 4-3。

表 4-3 财务指标因子载荷

指标	Factor1	Factor2	Factor3	Factor4
营业收入	0.789	0.323	0.241	-0.410
所得税	0.058	0.844	0.113	-0.186
净利润	0.314	0.911	0.212	-0.150
基本每股收益	-0.012	0.772	-0.146	0.080
存货	0.993	0.003	-0.091	0.005
流动资产合计	0.961	0.081	0.248	-0.058
固定资产净额	0.000	-0.042	0.032	0.269
流动负债合计	0.758	0.142	0.142	0.347
所有者权益合计	0.941	0.101	0.189	-0.038
期末现金及现金等价物余额	0.563	0.089	0.642	0.325

中国知网 https://www.cnki.net

由表 4-3 可知，第一主成分主要有营业收入、存货、流动资产合计等利润表和资产负债表的指标，因此第一主成分可表示为利润和资产因子。

4.3 传统指标的筛选

4.3.1 传统指标选择与处理

诸多学者将股票市场数据应用到股票预测中，股票市场数据又分为交易指标和技术指标数据。交易指标是历史交易信息，主要包括收盘价（close）、开盘价（open）、最高价（high）、最低价（low）、昨日收盘价（pre_close）、涨跌额（change）、涨跌幅（pct_chg）、成交量（vol）和成交额（amount）共 9 个交易数据指标。

技术指标是通过股票价格和交易量等市场数据计算得来的，通过技术指标可以发现股票的价格趋势和买卖信号，从而帮助投资者分析市场趋势和买卖时机。对于股票价格的预测发挥着重要的作用，许多预测研究都将技术指标纳入其中。常见的技术指标有：移动平均线指标（MA）、相对强弱指标（RSI）、随机指标（KDJ）、人气指标（AR）、意愿指标（BR）共 5 个技术指标。移动平均线指标是根据收盘价计算的，是最基础的技术指标，可以判断股票价格是向好发展还是向坏发展；相对强弱指标反映股票价格涨跌的速度和幅度；随机指标是反映股票市场上是否存在过度买入和过度卖出的信号；人气指标和意愿指标都是通过分析历史股票价格得到的技术指标。

同样通过标准化方法使不同特征变量的量纲规范化处理，通过降维将不相关的变量筛选掉，从而实现高效预测。利用 R 中的 scale 函数各变量数据进行标准化处理。

4.3.2 传统指标的筛选

将收盘价作为因变量，其余 13 个指标作为自变量进行 Adaptive Lasso 回归，可以将对 close 有明显影响的变指标找出来，结果表明有 8 个指标的系数被压缩到 0，各个变量的初始回归系数和最佳回归系数如表 4-4。

中国知网 https://www.cnki.net

表 4-4 传统指标初始回归系数和最佳回归系数

变量名	变量涵义	$\widehat{\beta}_{init,j}$	$\widehat{\beta}_{opti,j}$
D_1	open	0.194	0.000
D_2	high	0.190	0.168
D_3	low	0.199	0.825
D_4	pre_close	0.192	0.010
D_5	change	0.379	0.232
D_6	pct_chg	0.070	0.000
D_7	vol	0.000	0.000
D_8	amount	0.000	0.000
D_9	MA	0.191	0.004
D_{10}	RSI	0.001	0.000
D_{11}	KDJ	0.000	0.000
D_{12}	AR	0.244	0.000
D_{13}	BR	-0.241	0.000

可以发现系数不为 0 的变量有 5 个，因此利用 Adaptive-lasso 筛选出的传统变量为 high、low、pre_close、change、MA，均为正相关，最高、最低价、昨日收盘价以及涨跌额的升高均能反映股票价格的上涨，MA 为移动平均线指标，其反映的是股票价格向好发展与向坏发展的方向，从实际角度考虑，Adaptive-Lasso 筛选出的变量较为合理。

4.4 情绪指标的构建

4.4.1 股票文本的抓取与处理

本文将利用 Python 软件从东方财富网中抓取北方稀土 2010 年 4 月至 2022 年 9 月的股吧评论，在收集股吧评论时主要收集的信息包括发帖内容、帖子的阅读量、评论时间、回复量以及发帖作者。获取的部分原始股吧评论如表 4-5。

中国知网 https://www.cnki.net

表 4-5 部分爬虫原始股评数据

title	read	time	reply	author
稀土现货价格涨那么多，怎么估计还跌？	227	2022-09-27	1	威帝哥
一天杀一个白马可以理解但是杀了你 3 个多月了还在杀	225	2022-09-27	2	斐然钵满地花无缺
稀土产品价格上涨，股票也该涨了	169	2022-09-27	0	股友 rWHMuR
马上跌停了	154	2022-09-27	0	股友 29E98k7822
还好是分散投资。鸡蛋不能放到一个篮里	189	2022-09-27	0	深情的梅亦凡
直奔 20 而去！！	145	2022-09-27	0	牛牛 2509
哪个大资金会买基本面充满不确定性的票啊。哈哈哈哈	203	2022-09-27	0	牛牛 2509
国庆假期后，回魂。	150	2022-09-27	0	钻食王老 5
世上没有无缘无故的跌	441	2022-09-27	2	天下第一假值股

本文共抓取 40 万条股吧评论数据，由于数据中存在大量的噪声信息，股吧中除了投资者会发布一些评论，还有许多的广告资讯，这些混杂的信息体现不出投资者的情绪表达，因此需要对这些资讯以及重复出现的帖子进行删除，经过文本去噪后确定有效的股吧评论帖子数量为 33 万条。要对发帖的内容进行分词处理，因为中文的内容计算机无法识别标点符号，因此需要将中文评论进行分词处理获得单个词语，以便进行情绪分类。利用 Python 软件中的 jieba 工具，对去噪后的股吧评论内容进行分割。分词后的一些标点符号和一些连接词等内容对文本不会产生太大影响，因此可以将诸如“的”、“为”、“尽管”、“并”等与文本内容关系不大的词语剔除，本文综合了哈工大停用词表以及百度文库停用词表，经过去除停用词大量剔除无关因素有效地提高了情绪值提取效率。

4.4.2 投资者情绪值的构建

处理好股票评论之后，可以进行投资者情绪值的计算，情感倾向分析的方法分为两种，一种是基于情感词典的方法，一种是基于机器学习的方法，前者需要用到标注好的情感词典；后者需要进行人工识别对看涨看跌进行标注。本文使用的 SnowNLP 情感分析，是基于情感词典实现的，将文本分为积极和消极两类，使用 s.sentiments 计算情感分数，返回值为情绪的概率，大于 0.5 表示积极倾向，小于 0.5 表示消极倾向。表 4-6 展

中国知网 https://www.cnki.net

示了部分投资者情绪值。计算情绪值的流程图如图 4-1 所示。

表 4-6 投资者情绪值部分值

日期	情绪值	日期	情绪值
2021/1/1	0.543	2022/1/1	0.555
2021/1/2	0.468	2022/1/2	0.617
2021/1/3	0.532	2022/1/3	0.436
2021/1/4	0.501	2022/1/4	0.414
2021/1/5	0.455	2022/1/5	0.426
2021/1/6	0.461	2022/1/6	0.441

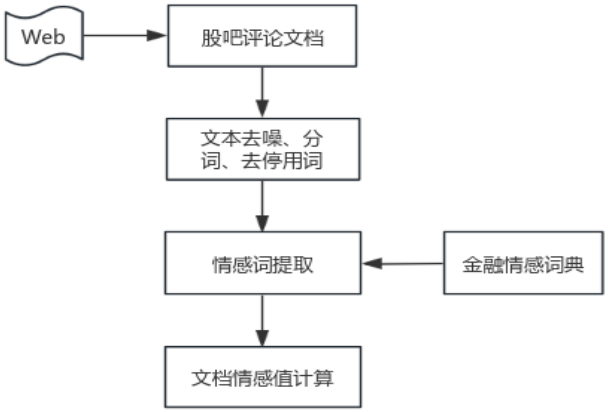

图 4-1 情绪分析流程图

通过计算对北方稀土 2010 至 2022 年的投资者情绪值进行分析，发现投资者情绪变化波动起伏较大，并不单纯的呈线性的上涨或下降的趋势，跨度空间为（0，1），表明在此时间段，不同投资者对于股票价格的看法不一致，对于同一支股票，在不同投资者心中对涨跌看法不同，可能有的投资者认为股票价格会涨，而另一些投资者认为股票价格会跌。投资者的情绪不稳定，反映到股票市场中，就带来了价格的变动。对比图 4-3 北方稀土收盘价变动图可以看出投资者情绪出现的最高值为2016年6月24日的0.9633，而后一个交易日北方稀土股票的收盘价涨幅为 0.23，情绪值的最低值为 2019 年的 6 月 18 日的 0.1543，后一个交易日北方稀土的收盘价跌幅为-0.15。因此可以发现投资者情

中国知网 https://www.cnki.net

绪对股票市场有着很重要的联系，股民情绪的稍微变动都有可能会造成股票价格的变化。因此，利用投资者情绪值可以实现对股票价格的预测。

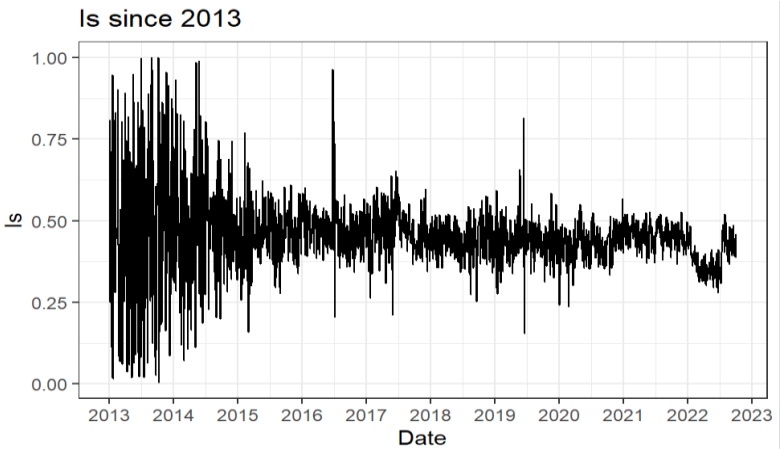

图 4-2 投资者情绪值时间序列图

图 4-3 收盘价变动图

4.5 GARCH-MIDAS 模型估计波动率

由于用 Adaptive-Lasso 筛选出的宏观经济指标与财务指标分别为月度数据和季度数据，而股票的日度数据为采用收盘价计算的对数收益率，为处理变量之间频率不同的问题，传统的研究方法通常是不采用高频变量或者是将高频变量转化为低频的方法使数据频率一致，然而传统的频率转换方法会造成数据信息的丢失，会造成实验结果的偏差，因此本文利用 GARCH-MIDAS 模型将宏观经济指标与财务指标作为低频变量，日度收益率作为高频变量，将不同频率的变量结合起来，构建包含宏观经济指标与财务指标的股票市场波动率。该模型是基于 R 软件 mfgarch 包中的 fit_mfgarch 函数进行建模的。

中国知网 https://www.cnki.net

mfgarch 包是用来估计 GARCH-MIDAS 模型的工具包，GARCH-MIDAS 模型将每日股票收益的条件方差分解为短期和长期分量，其中长期分量取决于以较低的频率采样的外生协变量。fit_mfgarch 函数是用来估计混合频率 GARCH 模型的。为保证参数优化的稳定性，将收益率乘以 100，公式为：$r_{i,t} = -(\ln(p_{i,t}) - \ln(p_{i,t-1}))*100$ 。

直接在模型中使用多个因子，随着变量个数的增多，模型的效果可能会降低。部分学者采用主成分分析提取宏观经济变量中的关键信息并运用到 GARCH-MIDAS 模型中，Asgharian 等[46]认为 GARCH-MIDAS 模型在计算上非常复杂，模型中存在多个宏观经济变量将导致识别或收敛问题。因此，在 MIDAS 方程中一次使用一个变量。为将不同变量中包含的信息纳入同一方程对变量进行主成分分析，并提取第一主成分作为宏观经济周期的代表。Stock 和 Watson[47][48]通过构建主成分，从大量宏观经济变量中提取组合信息。他们表明，这种方法可以有效地使用，而不是在一个回归中使用大量的变量。Fang 等[49]为预测美国黄金期货波动率使用 GARCH-MIDAS 模型，并运用主成分分析来提取不同宏观经济变量的关键信息，结果发现第一和第二主成分均能有效作为宏观经济变量的代理变量。因此本文对月度宏观经济变量和季度财务变量均选用第一主成分加入 GARCH-MIDAS 模型中。模型的具体结果见表 4-6。

表 4-7 GARCH-MIDAS 模型主要参数估计值

参数	估计值	P 值
mu	-0.084	0.498
alpha	0.092	0.000***
beta	0.905	0.000***
gamma	-0.036	0.109
m	1.621	0.000 ***
theta	-1.287	0.004***
w2	1.000	0.002***
theta.two	1.198	0.000***
w2.two	5.988	0.432

注：***、**和*依次表示在 1%、5%、10%的显著性水平下显著。

其中 mu 表示收益率的长期均值，theta 表示宏观经济指标以及财务指标对日度波动率的长期影响，w2 为最优估计权重，K 为最优滞后阶数，此处 K 取值为 36，即宏观指标因子滞后 36 个月，财务指标因子滞后 12 个季度，从表 4-7 可以看出模型的 alpha 和 beta 估计结果在统计意义上是显著的并且二者估计值之和接近 1，表明该模型能较好地

中国知网 https://www.cnki.net

拟合北方稀土股票的短期波动。theta 对应的宏观指标因子的值为-1.2872，即宏观经济变量对股票波动率的影响是反向的，当宏观经济变量的值较小时，股票市场的波动率较大，当企业的工业商品价格指数增加时，采购原材料等的成本增加，导致利润率下降，从而股票价格降低。Theta.two 对应财务指标因子，其值为 1.1982，表明财务变量的对股票波动率具有正向的影响。即当企业的营业收入、基本每股收益等增加时表明企业的盈利能力较好，股民对企业有信心追加投资从而造成股价的上涨。从最优估计权重上看，宏观经济因子的权重为 w2=1.0000，财务指标因子的权重为 w2.two=5.9880，表明随着两个因素滞后期数的增加，对该股票长期波动的影响是逐渐减弱的，符合经济市场运行的规律。其波动率图见图 4-4。

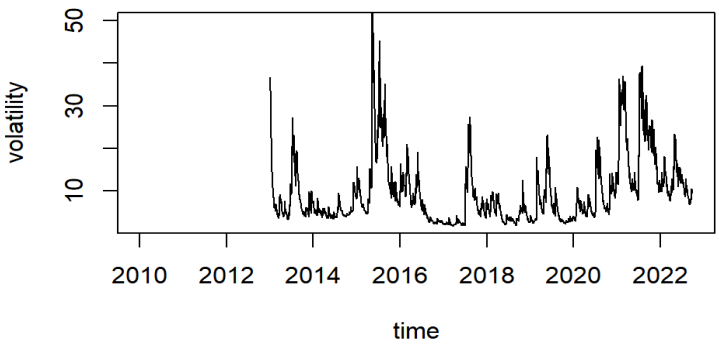

图 4-4 ht 条件波动率估计值

由于选取的滞后阶数为 36 个月 12 个季度，因此参数估计是从 2013 年 1 月 4 日开始的，该波动率包含宏观经济指标因素和财务指标因素，能够较好地估计波动率。2014 年我国的采取较为宽松的货币政策，利率水平下降，并且经过十八届三中全会中提出的多项改革措施，使得大部分投资者对经济增长的预期较高。2015-2016 年期间，该股票的条件波动率较大，说明在 2015 年到 2016 年股票价格的涨跌幅度变动较大。2019 年至 2020 年由于疫情的爆发，全国面临停工停产，股票市场遭受冲击，造成股票价格的波动。2021 到 2022 年我国就稀土行业首次立法，加速稀土行业可持续发展，由于稀土材料的需求在这两年中增长较大，造成稀土价格的上升，因此在 2021 到 2022 年期间股价的波动率较大。

中国知网 https://www.cnki.net

4.6 基于混频模型的 Adaptive-Lasso-GARCH-MIDAS-BP 模型的建立

4.6.1 输入数据的预处理

条件波动率 h 和第二日收盘价（close）、最高价（high）、最低价（low）、昨日收盘价（pre_close）、涨跌（change)以及移动平均线指标（MA）等 7 项作为神经网络模型的输入，来预测第二日收盘价，由于各变量之间量纲不一致，会导致各变量之间存在较大的差异，造成模型的预测结果不准确，因此本文采用归一化方法消除量纲的影响。本文采用 Max-Min 归一化法：

$$\bar{x} = \frac{x - x_{\min}}{x_{\max} - x_{\min}} \tag{4.3}$$

其中，x 为原始的拟合残差序列，$x_{\max}$ 和 $x_{\min}$ 分别为序列的最大值和最小值，$\bar{x}$ 即为归一化后的序列，归一化后的序列值在[0，1]之间。

4.6.2 BP 神经网络模型的建立

（1）确定 BP 神经网络结构

经过 Adaptive-Lasso 的筛选最终的 BP 神经网络模型中包含 6 个输入变量，即输入层为包含宏观经济信息和企业财务信息的条件波动率 h、最高价（high）、最低价（low）、昨日收盘价（pre_close）、涨跌（change）以及移动平均线指标（MA）等基本交易技术指标。因此输入层神经元个数为n =6。输出层为预测的收盘价，神经元个数为m = 1。隐藏层过多过少都会导致预测结果不准确，在实际中最常用的通常是只含一个隐含层的三层 BP 神经网络，隐藏层神经元个数一般根据经验公式：$s = \sqrt{n+m} + a(a = 1,2,\cdots,10)$ 来确定。本文输入神经元个数为 6 个，输出神经元个数为 1 个，因此根据经验公式该隐含层神经元的个数的取值范围为 $s = \sqrt{7} + a(a = 1,2,\cdots,10)$，即为 4 至 13 之间的整数。通过函查看隐含层节点数为 4 至 13 时的预测精度，可以确定最优的隐含层节点数。在训练次数不变的情况下，经过多次实验，最终确定 Adaptive-Lasso-GARCH-MIDAS-BP 模型的神经网络结构为 6-4-1。

中国知网 https://www.cnki.net

表 4-8 隐含层神经元个数训练结果

隐藏层神经元个数	RMSE	MAE	MAPE
4	0.82	0.70	2.47
5	0.83	0.71	2.48
6	0.84	0.73	2.55
7	0.85	0.74	2.56
8	0.86	0.75	2.60
9	0.89	0.78	2.72
10	0.89	0.77	2.71
11	0.97	0.84	2.94
12	0.90	0.79	2.75
13	1.00	0.87	3.06

（2）模型的参数及模型训练

本文使用 R 语言 AMORE 包中创建神经网络。AMORE 包是用来创建一个前馈人工神经网络，是较为灵活的神经网络包，可以增加多个隐藏层，包含的参数更加丰富，使用 newff 函数构建前馈神经网络，train 函数用来训练模型。输入层输入变量为 6 个，输出层的变量为 1 个，学习率的取值范围一般为 0.1 到 0.8 之间，本文设定学习率为 0.15。使用最小均方误差法作为训练误差函数。

使用 train 函数用来训练模型。同时加入测试集数据对训练的网络进行测试，利用 sim 函数进行网络仿真。对结果进行反归一化处理，公式为：$x=\bar{x}(x_{\max}-x_{\min})+x_{\min}$，经过反归一化处理，最终得到收盘价的预测结果。

4.6.3 模型比较

本文建立了加入投资者情绪的混频 GARCH-MIDAS-BP 模型，本章还建立了不加入投资者情绪的混频 GARCH-MIDAS-BP 模型、加入投资者情绪值的非混频单 BP 神经网络模型、不加入投资者情绪值的非混频单 BP 神经网络模型与本文建立的模型进行比较，通过模型结果的对比来验证本文最终建立的模型预测效果的有效性。

（1）比较标准

为评估预测模型的效果，通常会选择几个标准来评估预测结果的准确性。本文采用

中国知网 https://www.cnki.net

均方误差根(RMSE)、平均绝对误差(MAE)、平均绝对百分比误差(MAPE)，使用这些误差指标来衡量实际值和预测值之间的差异。误差指标越小，说明模型预测效果越准确。各项误差指标的表达式如下：

$$RMSE = \sqrt{\frac{1}{n}\sum_{t=1}^{n}(\hat{y}_t - y_t)^2} \tag{4.4}$$

$$MAE = \frac{1}{n}\sum_{t=1}^{n}|\hat{y}_t - y_t| \tag{4.5}$$

$$MAPE = \frac{100\%}{n}\sum_{t=1}^{n}\left|\frac{\hat{y}_t - y_t}{y_t}\right| \tag{4.6}$$

其中，式(4.4)-式(4.6)中，$\hat{y}_t$ 为模型的预测值，y_t 为序列真值，n 为预测期数。

（2）加入不同因素的模型比较

大数据时代的到来使得人类的交流方式多种多样，线上交流平台能够实现信息的共享，可以提供更加全面的信息，而这些信息能够反映投资者的一些态度看法。股票市场中散户投资者占绝大多数，但是由于他们对于投资的专业水平不够，对投资的认识不够清楚，容易受到外界环境的干扰，而社交平台是广大投资者交流信息的平台，在股票投资平台上每个时刻都会有较多的人发表评论，股票市场的稍微变动就有可能引起投资者态度的变化，投资者的情绪很容易受到影响，一旦这种情绪在社交平台传播，可能会造成其他投资者的恐慌，从而引起股票市场的波动，对股票价格的影响较大，因此在对股票价格预测时考虑投资者的情绪因素是非常有必要的。因此为了验证投资者情绪对股票价格的影响，本文对加入投资者情绪与不加入投资者情绪时的模型进行对比。

模型 1 包含 5 个基本交易指标和包含宏观经济因素以及财务因素的波动率h_t的 6 个输入变量对第二天收盘价进行预测。

模型 2 包含 5 个基本交易指标、宏观经济因素以及财务因素的波动率h_t和投资者情绪值的 7 个输入变量对第二天收盘价进行预测。

模型 3 仅包含基本交易指标的 5 个输入变量对第二天收盘价进行预测。

模型 4 包含基本交易指标和投资者情绪值的 6 个输入变量对第二天收盘价进行预测。

模型 1、模型 2 为加入与不加入投资者情绪的 GARCH-MIDAS-BP 模型，模型 3 与模型 4 为加入与不加入投资者情绪值的单 BP 神经网络模型。表 4-9 为不同模型的预测

中国知网 https://www.cnki.net

精度比较。

表 4-9 不同模型预测精度

模型	RMSE	MAE	MAPE
模型 1	0.826	0.712	2.477
模型 2	0.813	0.701	2.431
模型 3	0.894	0.764	2.666
模型 4	0.839	0.719	2.498

由上表可以看出，模型 2 的 RMSE、MAE、MAPE 均小于模型 1，模型 4 的 RMSE、MAE、MAPE 均小于模型 3，表明本文使用的加入投资者情绪后的模型可以提高模型的预测效果，说明投资者情绪确实能够影响股票的价格。模型 1 的 RMSE、MAE、MAPE 均小于模型 3，而模型 2 的 RMSE、MAE、MAPE 均小于模型 4，表明本文使用的 GARCH-MIDAS-BP 混频模型比传统的非混频 BP 神经网络模型的预测效果要好。最终预测结果表明本文建立的加入投资者情绪的混频 GARCH-MIDAS-BP 模型相较于其他模型具有较好的预测效果。

中国知网 https://www.cnki.net

5 结论与展望

5.1 结论

面对复杂的股票市场，通过对国内外学者的研究文献进行阅读借鉴其优秀经验，面对不同频率的多个特征变量，首先利用 Adaptive-Lasso 方法对宏观经济变量、财务变量、传统交易和技术指标进行筛选，筛选出对股票价格影响较大的变量，再多所筛选出的变量进行主成分分析再次降维。构建 Ada-PCA-RU-MIDAS 模型以及 Ada-GARCH-MIDAS-BP 模型分别对周频的收盘价和日度收盘价进行预测。具体结论如下：

（1）首先对周频交易和技术指标和月频宏观经济指标进行 Adaptive-Lasso 降维，得到 14 个宏观指标和 8 个基本指标，再根据频率对齐方法实现高频数据向低频数据的对齐。通过构建 RU-MIDAS 模型实现对高频响应变量的预测，再次与使用主成分分析方法的 PCA-RU-MIDAS 模型进行比较，结果发现使用主成分分析进行再一次降维对股价的预测效果要更准确。

（2）使用日度交易和技术指标、月度宏观经济指标、季度财务指标以及日度投资者情绪指标，首先进行 Adaptive-Lasso 降维，并将筛选的结果再次进行主成分分析降维，将月度以及季度指标纳入 GARCH-MIDAS 模型构建条件波动率，并将条件波动率、交易和技术指标、投资者情绪指标作为 BP 神经网络的输入特征实现对股票价格的预测，并对比不包含投资者情绪时的 Ada-GARCH-MIDAS-BP 模型，结果发现加入投资者情绪能提高模型的预测效果。对比包含条件波动率的 Ada-GARCH-MIDAS-BP 模型和不包含条件波动率的 Ada-BP 模型，以及是否加入投资者情绪值变量的模型，结果发现使用混频方法的 Ada-GARCH-MIDAS-BP 模型要优于不使用混频方法的 Ada-BP 模型，加入投资者情绪变量的模型要优于不加投资者情绪变量的模型。

5.2 展望

在完成了本文研究工作的基础上，对后续相关研究进行了展望：

（1）使用 RU-MIDAS 模型进行预测时对于滞后阶数的选择不够完善，后期可以补

中国知网 https://www.cnki.net

充较为完善的方法，可以与其他模型滞后阶数进行比较选择最优滞后阶数。

（2）本文使用 BP 神经网络模型对股价进行预测，对隐藏节点的选择依靠的是经验公式，参数的设定也没有一定的标准，后续可以通过其他模型进行优化。

（3）本文使用的是 BP 神经网络与 GARCH-MIDAS 模型的结合，未来可以将 GARCH-MIDAS 模型与更多类型的模型结合，通过结合不同模型期待可以对预测效果有提升。

中国知网 https://www.cnki.net

参考文献

[1] 钟骐. 基于 ARMA-GARCH 模型的股票价格分析及预测[J]. 中国市场, 2017, 920(1): 68-69+75.

[2] 胡雪梅, 蒋慧凤. 具有技术指标的逻辑回归模型预测谷歌股票的涨跌趋势[J]. 系统科学与数学, 2021, 41(3): 802-823.

[3] 杨宇塬, 张梅. 基于 ARIMA 模型的股票价格实证分析[J]. 科技资讯, 2021, 19(29): 121-123+127.

[4] 刘瑜儒, 周龙武, 庞利. 基于 LSTM-GA 的股票价格涨跌预测模型[J]. 中国集体经济, 2021, (30): 90-91.

[5] 梁宇佳, 宋东峰. 基于 LSTM 和情感分析的股票预测[J]. 科技与创新, 2021, (21): 126-127.

[6] 赵传君, 刘金峰, 武美龄, 等. 基于数值与文本特征的 LSTM 股票价格预测研究[J]. 山西大学学报（自然科学版）, 2023, 1-6.

[7] 张月. 基于 BP 神经网络多组合模型的股票数据分析[D]. 阜阳: 阜阳师范大学, 2022.

[8] 赵昊然. 基于 LASSO 和 BP 神经网络的股票价格预测研究[D]. 桂林: 广西师范大学, 2022.

[9] 周润佳. 基于深度学习的股票趋势预测算法[J]. 计算机与现代化, 2023, 329(1): 69-73+107.

[10] 朱睿琪, 孙丽, 沈嘉和. 基于 LSTM 对股票走势的预测研究[J]. 信息技术与信息化, 2022, 270(09): 24-27.

[11] Halbert W. Economic prediction using neural networks: the case of IBM daily stock returns[C]. International Conference on Neural Networks IEEE1, 1988, (2): 451-458.

[12] Hammad A A A, Hall A E L. Forecasting the Jordanian stock prices using artificial neural networks[M]. New York: ASME Press, 2007.

[13] 林杰, 郭耀煌. 用神经网络方法预测股票短期走势[J]. 西南交通大学学报, 1998, (03): 67-72.

[14] 吴微, 陈维强, 刘波. 用 BP 神经网络预测股票市场涨跌[J]. 大连理工大学学报, 2001, 41(1): 9–15.

[15] 黄丽. BP 神经网络的 IAPSOBPNN 组合训练算法[J]. 重庆工学院学报(自然科学版). 2008, (09): 120-126.

[16] 韩磊. 利用 BP 神经网络系统对股票市场进行预测与分析的研究[D]. 天津: 天津大学, 2013.

[17] Kimoto T, Asakawa K, Yoda M, et al. Stock market prediction system with modular neural network[C]. International Joint Conference on Neural Networks, 1990, (1): 1-6.

中国知网 https://www.cnki.net

[18] Ghysels E, Valkanov R. The MIDAS touch: mixed data sampling regression models[J]. Cirano Working Papers, 2004, 5(1): 512-517.

[19] Foroni C, Marcellino M, Schumacher C. Unrestricted mixed data sampling (MIDAS): MIDAS regressions with unrestricted lag polynomials[J]. Journal of the Royal Statistical Society Series A: Statistics in Society, 2015, 178(1): 57-82.

[20] Clements M P, Galvão A B. Macroeconomic forecasting with mixed-frequency data: Forecasting output growth in the United States[J]. Journal of Business and Economic Statistics, 2008, 26(4): 546-554.

[21] 李合龙, 任昌松, 丘润文, 等. 基于 GARCH-MIDAS 的混频投资者情绪对股市波动的影响[J]. 系统管理学报, 2013, 1-15.

[22] 吴鑫育, 王小娜. 比特币对我国股票市场波动性的影响——基于双重非对称 GARCH-MIDAS 模型的实证研究[J]. 重庆理工大学学报（社会科学）, 2022, 36(08): 65-75.

[23] 韩娅玲. 基于非对称 GARCH-MIDAS 模型的上证指数波动性分析[J]. 统计与决策, 2021, 37(24): 157-160.

[24] 周昡. 基于 GARCH-MIDAS 模型的中国股票市场 ES 预测研究[D]. 成都: 西南财经大学, 2021.

[25] 雷立坤, 余江, 魏宇, 等. 经济政策不确定性与我国股市波动率预测研究[J]. 管理科学学报, 2018, 21(06): 88-98.

[26] 王新宇, 朱新缘, 王宁. 债券市场收益率波动与风险测量研究——基于 GARCH-MIDAS 模型分析[J]. 价格理论与实践, 2018, (10): 101-104.

[27] Xu C. A novel (U) MIDAS-SVR model with multi-source market sentiment for forecasting stock returns[J]. Neural computing and applications, 2020, 32(10): 5875-5888.

[28] Krs M, Karan M. Stock exchange volatility forecasting under market stress with MIDAS regression[J]. International Journal of Finance and Economics, 2021, 28(1): 295-306.

[29] 罗楠, 王璐, 吴江斌, 等. 基于 Lasso-MIDAS 模型的混频时间序列预测研究[J]. 计算机应用研究, 2022, 39(04): 1003-1007.

[30] Foroni C, Guérin P, Marcellino M. Using low frequency information for predicting high frequency variables[J]. International Journal of Forecasting, 2018, 34(4): 774-787.

[31] 刘金全, 刘汉, 印重. 中国宏观经济混频数据模型应用——基于 MIDAS 模型的实证研究[J]. 经

中国知网 https://www.cnki.net

济科学, 2010, (5): 23-34.

[32] 王维国, 于扬. 基于混频回归类模型对中国季度 GDP 的预报方法研究[J]. 数量经济技术经济研究, 2016, 33(4): 108-125.

[33] 许启发, 卓杏轩, 蒋翠侠. 反向有约束混频数据模型的市场化利率预测[J]. 管理科学学报, 2019, 22(10): 55-71.

[34] 耿鹏, 齐红倩. 我国季度 GDP 实时数据预测与评价[J]. 统计研究, 2012, 29(1): 8-14.

[35] Gao B, Yang C. Forecasting stock index futures returns with mixed-frequency sentiment[J]. International Review of Economics and Finance, 2017, 49: 69-83.

[36] 秦晔玲, 朱建平. 基于自适应 Lasso 变量选择方法的指数跟踪[J]. 统计与决策, 2018, 34(16): 141-145.

[37] 王爽. Lasso 及改进的 Lasso 方法在几类模型变量选择中的应用[D]. 桂林: 广西师范学院, 2018.

[38] 杨青龙, 田晓春, 胡佩媛. 基于 LASSO 方法的企业财务困境预测[J]. 统计与决策, 2016, (23): 170-173.

[39] 牛勇, 赵攀. 基于 Adaptive Lasso 方法的合肥市商品房价格影响因素实证分析[J]. 皖西学院学报, 2019, 35(04): 49-56.

[40] 齐文雪. 基于 Adaptive Lasso 方法的信用评分模型研究[D]. 大连: 大连理工大学, 2019.

[41] Tibshirani R. Regression shrinkage and selection via the Lasso[J]. Journal of the Royal Statistical Society Series B-Methodological, 1996, 58(1): 267-288.

[42] Katayama S, Imori S. Lasso penalized model selection criteria for high- dimensional multivariate linear regression analysis [J]. Journal of Multivariate Analysis, 2014, 132: 138-150.

[43] Zou H. The Adaptive Lasso and its oracle properties[J]. Journal of the American Statistical Association, 2006, 101(476): 1418-1429.

[44] Morelli D. The relationship between conditional stock market volatility and conditional macroe conomic volatility: Empirical evidence based on UK data[J]. International Review of Financial Analysis, 2002, 11(1):100-110.

[45] 郑挺国, 尚玉皇. 基于宏观基本面的股市波动度量与预测[J]. 世界经济, 2014, 37(12): 118-139.

[46] Asgharian H, Hou A J, Javed F. The importance of the macroeconomic variables in forecasting stock return variance: A GARCH-MIDAS Approach[J]. Journal of Forecasting, 2013, 32(7): 600-612.

中国知网 https://www.cnki.net

[47] Stock J H, Watson M W. Forecasting using principal components from a large number of predictors[J]. Journal of the AmericanStatistical Association, 2012, 97: 1167-1179.

[48] Stock J H, Watson M W. Macroeconomic forecasting using diffusion indexes[J]. Journal of Business and Economic Statistics, 2012, 20: 147-162.

[49] Fang L B, Yu H H, Wen X. Forecasting gold futures market volatility using macroeconomic variables in the united states[J]. Economic Modelling, 2018, 72: 249-259.

[50] Engle R F, Rangel J G. The Spline-GARCH model for low-frequency volatility and its global macroeconomic causes[J]. Review of Financial Studies, 2008, 21(3): 1187-1222.

中国知网 https://www.cnki.net

附录

部分核心 R 代码

1.Adaptive-lasso 模型指标筛选。

```
library(mice)
library(glmnet)
da <- read.csv("E：\\文件夹\\论文论文\\论文数据\\北方日度数据.csv")
da1=da[，2：10]
da3=da[，11：17]
da2=da[，-1]
# da2=scale(da1)
# da4=scale(da3)
x<- as.matrix(da2[，-1])
y<- as.matrix(da2[，1])
x_cont=x[1：2170，]
y_cont=y[1：2170，]
x_out=x[-c(1：2170)，]
y_out=y[-c(1：2170)，]
x_cont=x
y_cont=y
## Perform ridge regression(岭回归)
ridge1 = glmnet(x = x_cont，  y = y_cont，alpha=0)
plot(ridge1，xvar = "lambda"，label = F)
## Perform ridge regression with 10-fold CV
ridge1_cv <- cv.glmnet(x = x_cont，  y = y_cont，type.measure = "mse"，nfold = 10，alpha = 0)
ridge1_cv$lambda.min
coef(ridge1_cv，  s = ridge1_cv$lambda.min)
```


中国知网 https://www.cnki.net

```
best_ridge_coef <- as.numeric(coef(ridge1_cv， s = ridge1_cv$lambda.min))[-1]
## Perform adaptive LASSO
alasso1 <- glmnet(x = x_cont， y = y_cont，alpha = 1，penalty.factor = 1 / abs(best_ridge_coef))
plot(alasso1， xvar = "lambda")
## Perform adaptive LASSO with 10-fold CV
alasso1_cv <- cv.glmnet(x = x_cont， y = y_cont，type.measure = "mse"， nfold = 10，alpha = 1，penalty.factor = 1 / abs(best_ridge_coef)， keep = TRUE)
plot(alasso1_cv)
alasso1_cv$lambda.min
best_alasso_coef1 <- coef(alasso1_cv， s = alasso1_cv$lambda.min)
best_alasso_coef1
best_alasso_coef2<- as.numeric(best_alasso_coef1)[-1]
best_alasso_coef2
```

2.Adaptive-lasso 模型指标筛选及因子分析降维。

```
library(mice)
library(glmnet)
library(tseries)
a <- read.csv("E：\\文件夹\\论文论文\\论文数据\\宏观稀土全 37.csv")
aa=a[，-1]
da1=scale(aa)
da1<-as.data.frame(lapply(da[，-1]，f1))#归一化
x<- as.matrix(da1[，-1])
y<- as.matrix(da1[，1])
x_cont=x[1：110，]
y_cont=y[1：110，]
x_out=x[-c(1：110)，]
y_out=y[-c(1：110)，]
```


中国知网 https://www.cnki.net

```
## Perform ridge regression(岭回归)
ridge1 = glmnet(x = x_cont，  y = y_cont，alpha=0)
plot(ridge1，xvar = "lambda"，label = F)
## Perform ridge regression with 10-fold CV
ridge1_cv <- cv.glmnet(x = x_cont，  y = y_cont，type.measure = "mse"，nfold = 10，alpha = 0)
ridge1_cv$lambda.min
coef(ridge1_cv，  s = ridge1_cv$lambda.min)
best_ridge_coef <- as.numeric(coef(ridge1_cv，  s = ridge1_cv$lambda.min))[-1]
## Perform adaptive LASSO
alasso1 <- glmnet(x = x_cont，  y = y_cont，alpha = 1，penalty.factor = 1 / abs(best_ridge_coef))
plot(alasso1，  xvar = "lambda")
## Perform adaptive LASSO with 10-fold CV
alasso1_cv <- cv.glmnet(x = x_cont，  y = y_cont，type.measure = "mse"，  nfold = 10，alpha = 1，penalty.factor = 1 / abs(best_ridge_coef)，  keep = TRUE)
plot(alasso1_cv)
alasso1_cv$lambda.min
best_alasso_coef1 <- coef(alasso1_cv，  s = alasso1_cv$lambda.min)
best_alasso_coef1
best_alasso_coef2<- as.numeric(best_alasso_coef1)[-1]
#best_alasso_coef2
##predict
aa=predict(alasso1_cv，s=alasso1_cv$lambda.min，newx=x_out)
sqrt(mean(y_out-aa)^2)
##训练集的 R-Squared
y_predicted <- predict(alasso1_cv，s=alasso1_cv$lambda.min，newx=x_cont)
#find SST and SSE
```


中国知网 https://www.cnki.net

```
sst <- sum((y_cont - mean(y_cont))^2)
sse <- sum((y_predicted - y_cont)^2)
#find R-Squared
rsq <- 1 - sse/sst
rsq
##因子分析
library(psych)
da<- read.csv("E：\\文件夹\\代码\\指标\\ada 宏观 14.csv")
x<-da[，-1]
#KMO 检验和 Barlette 检验(kmo>0.7，p<0.05)
KMO(x)
bartlett.test(x)
rownames(x)<-da[，1]
da1<-scale(x)
#da1
dat<-cor(x)
#dat
#碎石图
par(mfrow=c(1，1))
screeplot(princomp(da1)，type="lines")
#极大似然法
fac<-factanal(da1，factors=5，rotation="varimax"，scores="regression")
fac
# #碎石图
# fa.parallel(dat，  n.obs = 112，  fa = "both"，  n.iter = 100)
# factor.plot(fac)
#因子得分
s=fac$scores
```


中国知网 https://www.cnki.net

S

3.PCA-RUMIDAS 模型

```
library(midasr)
library(lubridate)
library(Metrics)
library(forecast)
da1<- read.csv("E：\\文件夹\\代码\\指标\\22 周因子得分.csv")
da2<- read.csv("E：\\文件夹\\代码\\指标\\2214 因子得分.csv"，header=T，row.names=1)
#g2 <- ts(as.numeric(c(da2[，1]，da2[，2]，da2[，3]))， start=c(2010，1)， frequency = 12)
#月度
g21=ts(as.numeric(da2[，1])， start=c(2010，2)， frequency = 12)
g22=ts(as.numeric(da2[，2])， start=c(2010，2)， frequency = 12)
g23=ts(as.numeric(da2[，3])， start=c(2010，2)， frequency = 12)
g24=ts(as.numeric(da2[，4])， start=c(2010，2)， frequency = 12)
g25=ts(as.numeric(da2[，5])， start=c(2010，2)， frequency = 12)

#c(g21，g22，g23)
#周度
g11 <- ts(as.numeric(da1[，3])，start=c(2010，01，29)，frequency = 48)
g12 <- ts(as.numeric(da1[，4])，start=c(2010，01，29)，frequency = 48)
g10 <- ts(as.numeric(da1[，2])，start=c(2010，01，29)，frequency = 48)
open1 <- (g10-min(g10))/(max(g10)-min(g10))#归一化
#mlsd(带日期的 midas 滞后结构)
#m1<-midas_r(mls(open1，3，4)~mls(g11，36，4)+mls(g12，36，4)+mls(g21，3，1)+mls(g22，3，1)+mls(g23，3，1)+mls(g24，3，1)+mls(g25，3，1)，start = NULL)
# m1
```


中国知网 https://www.cnki.net

```
#m1<-midas_r(mls(open1，3，4)~mls(g11，4+0：23，4)+mls(g12，4+0：23，4)+mls(g21，1：6，1)+mls(g22，1：6，1)+mls(g23，1：6，1)+mls(g24，1：6，1)+mls(g25，1：6，1)，start = NULL)
# m1
m1<-midas_r(mls(open1，3，4)~mls(g11，4+0：11，4)+mls(g12，4+0：11，4)+mls(g21，1：3，1)+mls(g22，1：3，1)+mls(g23，1：3，1)+mls(g24，1：3，1)+mls(g25，1：3，1)，start = NULL)
m1
#让我们检查哪些时间序列构成了模型的一部分：
m1$model[nrow(m1$model)-(3：0)，  ]
#summary(m1)
# #让我们使用该模型进行预测。首先，让我们使用截至 2022 8 月的数据重新估计模型。
open1_h=open1[1：604]
g11_h=g11[1：604]
g12_h=g12[1：604]
#g13_h=g13[1：604]
g21_h=g21[1：151]
g22_h=g22[1：151]
g23_h=g23[1：151]
g24_h=g24[1：151]
g25_h=g25[1：151]
# tail(mls(g11_h，4+0：23，4))
# mls(g11，36，4)
m1h<-update(m1，data=list(open1=open1_h，g11=g11_h，g12=g12_h，g21=g21_h，g22=g22_h，g23=g23_h，g24=g24_h，g25=g25_h))
m1h$model[nrow(m1h$model)，1：6]
#预测 x 月第一周
```


中国知网 https://www.cnki.net

```
pr<-predict(m1h，newdata=list(open1=open1，g11=g11，g12=g12，g21=g21，g22=g22，g23=g23，g24=g24，g25=g25))
#检查历史数据的预测是否与模型的拟合值一致
cbind(pr[length(pr)-(5：1)]，m1h$fitted.values[length(m1h$fitted.values)-(4：0)])
#将模型预测与实际值进行比较
c(pr[length(pr)]， open1[length(open1)-(3)])
m1h_2 <- update(m1h， formula = mls(open1， 2， 4)~.)
m1h_3 <- update(m1h， formula = mls(open1， 1， 4)~.)
m1h_4 <- update(m1h， formula = mls(open1， 0， 4)~.)
m1h_2$model[nrow(m1h_2$model)，1：6]
m1h_3$model[nrow(m1h_3$model)，1：6]
m1h_4$model[nrow(m1h_4$model)，1：6]
#预测整个 2022 年 9 月度每一周（4 周）的值并与实际值进行比较。
pr2<-predict(m1h_2，newdata=list(open1=open1，g11=g11，g12=g12，g21=g21，g22=g22，g23=g23，g24=g24，g25=g25))
pr3<-predict(m1h_3，newdata=list(open1=open1，g11=g11，g12=g12，g21=g21，g22=g22，g23=g23，g24=g24，g25=g25))
pr4<-predict(m1h_4，newdata=list(open1=open1，g11=g11，g12=g12，g21=g21，g22=g22，g23=g23，g24=g24，g25=g25))
q2f <- c(tail(pr， n = 1)， tail(pr2， n = 1 )， tail(pr3， n = 1)，tail(pr4， n = 1))
aa=cbind(q2f， open1[length(open1)-(3：0)])
aa
aa1.2 <- open1[length(open1)-(3：0)]*(max(g10)-min(g10))+min(g10)
aa1.3 <- q2f*(max(g10)-min(g10))+min(g10)
#输出均方根误差
accuracy(q2f， open1[length(open1)-(3：0)])
accuracy(aa1.3，aa1.2)
#扩展 10 月度 4 个周具有 NA 的历史数据时间序列。
```


中国知网 https://www.cnki.net

```
library(xts)
nax<-xts(c(NA， NA， NA， NA)， order.by= ymd("2022-10-06"， "2022-10-13"，"2022-10-20"，"2022-10-27"))
nay <- xts(NA， order.by = ymd("2022-10-01"))
x_f1 <- c(open1，nax)
x_f2 <- c(g11，nax)
x_f3 <- c(g12，nax)
y_f1 <- c(g21，nay)
y_f2 <- c(g22，nay)
y_f3 <- c(g23，nay)
y_f4 <- c(g24，nay)
y_f5 <- c(g25，nay)
#用完整的历史数据更新规范，然后进行预测。
mrh_f2$model[nrow(mrh_f2$model)，1：6]
m1$model[nrow(m1$model)，1：6]
mrh_f2<-update(m1h_2，data=list(open1=open1，g11=g11，g12=g12，g21=g21，g22=g22，g23=g23，g24=g24，g25=g25))
mrh_f3<-update(m1h_3，data=list(open1=open1，g11=g11，g12=g12，g21=g21，g22=g22，g23=g23，g24=g24，g25=g25))
mrh_f4<-update(m1h_4，data=list(open1=open1，g11=g11，g12=g12，g21=g21，g22=g22，g23=g23，g24=g24，g25=g25))
pr_101<-predict(m1， newdata=list(open1=x_f1， g11=x_f2， g12=x_f3， g21=y_f1，g22=y_f2，g23=y_f3，g24=y_f4，g25=y_f5))
pr_102<-predict(mrh_f2，newdata=list(open1=x_f1，g11=x_f2，g12=x_f3，g21=y_f1，g22=y_f2，g23=y_f3，g24=y_f4，g25=y_f5))
pr_103<-predict(mrh_f3，newdata=list(open1=x_f1，g11=x_f2，g12=x_f3，g21=y_f1，g22=y_f2，g23=y_f3，g24=y_f4，g25=y_f5))
pr_104<-predict(mrh_f4，newdata=list(open1=x_f1，g11=x_f2，g12=x_f3，g21=y_f1，
```


中国知网 https://www.cnki.net

```
g22=y_f2，g23=y_f3，g24=y_f4，g25=y_f5))
pr_q3 <- c(tail(pr_101， n = 1)， tail(pr_102， n = 1)， tail(pr_103， n = 1)，tail(pr_104， n = 1))
xts(pr_q3， order.by = ymd(c("2022-10-06"， "2022-10-13"， "2022-10-20"， "2022-10-27")))
```

4.GARCH-MIDAS 模型

```
library(mfGARCH)
aa <- read.csv("E：\\文件夹\\代码\\指标\\微宏观 xlsx.csv")
str(aa)
date=as.Date(aa$date)
date2=as.Date(aa$month)
date3=as.Date(aa$quarter)
aaa2=data.frame(date)
aaa22=data.frame(date2)
aaa3=data.frame(date3)
#r1=aa$return*100
aa1=cbind(aaa2，aa[，2]*100，aaa22，aa[，4：6]，aaa3，aa[8：9])
aa2=data.frame(aa1)
colnames(aa2)=c("date"，"return"，"month"，"Factor11"，"Factor22"，"Factor32"，"quarter"，"factor1"，"factor2")
#ff=fit_mfgarch(aa2，y="return"，x="Factor1"，low.freq="month"，K=36，gamma=T)
ff2=fit_mfgarch(aa2，y="return"，x="Factor11"，low.freq="month"，K=36，x.two = "factor1"， K.two = 12， low.freq.two = "quarter")
ff2
ff2$bic
gt=ff2$g
as.data.frame(gt)
tau=ff2$tau
```


中国知网 https://www.cnki.net

```
as.data.frame(tau)
h=gt*tau
as.data.frame(h)
#write.csv(h，file="C：\\Users\\Lenovo\\Desktop\\11.csv")
plot(date，h，type="l"，ylim=c(2，50)，xlab="time"，ylab="volatility")
lines(date，gt，ylim=c(2，50)，type="l"，col="red")
```

5.GARCH-MIDAS-BP 模型

```
ibrary(AMORE)
library(forecast)
da<- read.csv("E：\\文件夹\\代码\\指标\\er 输入数据.csv")
aa=da[，2：8]
f1<-function(z){
  return((z-min(z)) / (max(z)-min(z)))                    #x-min(z)/max(z)-min(z)
  # return(z)
}
y_aa<-as.data.frame(lapply(aa，f1))#归一化
x_training1=y_aa[1：2350，2：7]#训练集输入数据（21 年 10 月至 22 年 9 月 243 个测试集）2127
y_training1=y_aa[1：2350，1] #训练集输出数据
x_testing1=y_aa[2351：2370，2：7]
y_testing1=aa[2351：2370，1]
set.seed(100)
#BP 寻最优隐藏层函数
pred_error_bp <- function(x){
  set.seed(100)
  net<-newff(n.neurons = c(6，x，1)，learning.rate.global = 0.15，momentum.global = 0.4，error.criterium = 'LMS'，Stao = NA，hidden.layer = "sigmoid"，output.layer = 'sigmoid'，method="ADAPTgdwm")
```


中国知网 https://www.cnki.net

```
    result<-train(net，x_training1，y_training1，show.step=10000，error.criterium="LMS"，
report=TRUE，n.shows=5)
      y_BP1<-as.ts(sim(result$net，x_testing1))
      y_BP1.2 <- y_BP1*(max(aa[，1])-min(aa[，1]))+min(aa[，1])
      acu=accuracy(y_BP1.2，y_testing1)
      return(acu) #显示预测精度
      #return(y_BP1.2) #显示预测结果
    }
    pred_error_bp(4)
    pred_error_bp(5)
    pred_error_bp(6)
    pred_error_bp(7)
    pred_error_bp(8)
    pred_error_bp(9)
    pred_error_bp(10)
    pred_error_bp(11)
    pred_error_bp(12)
    pred_error_bp(13)
    accuracy(ts(y_BP1.2)，y_testing1)          #SARIMA-Intervention-BP 预测结果
```


中国知网 https://www.cnki.net

河北经贸大学研究生学院监制

中国知网 https://www.cnki.net