基于神经网络模型的中国碳中和股票收盘价预测

胡智涛　郝立丽

摘要：随着国家“双碳”目标的提出，预测碳衍生的金融产品价格成为重要的发展议题。碳中和作为一项国家发展的基本战略，其衍生的金融产品价格波动会对国家的能源储备与投资管理有着深远的意义。但由于中国碳中和股票收盘价受到国际经济、政治、与自然等多种因素的影响，所以其收盘价的预测是一项较为困难的任务。针对其收盘价的非线性波动，使用 BP 神经网络结合粒子群算法（PSO）模拟价格的波动规律。通过粒子群算法对 BP 神经网络的重要参数进行优化，结果表明，PSO-BP 混合模型在碳中和收盘价预测精度的提升上具有良好的效果体现。

关键词：机器学习；BP 神经网络；粒子群算法；价格预测

DOI:10.19456/j.cnki.tjyzx.2023.05.004

一、引言

近年来，温室气体的排放造成全球变暖等诸多环境问题，控制碳排放成为改善环境，促进可持续发展的必由之路。随着有关节能减排的国家政策的逐步制定与实施，我国提出了 2060 年实现碳中和的战略目标，并建立了有关碳排放的数据核算与监测体系[1]。自从 2006 年国家权威组织发布多个行业标准，为各社会团体提供有关碳排放的指导准则以来，我国建立了多个全国性的碳排放权交易市场，促进了行业间碳排放权的交易效率，提高了环境治理效果。所以模拟碳中和的变化趋势对我国未来环境战略目标的发展规划具有一定的参考意义与价值。

由于我国碳中和情况变动的复杂性，所以准确把握其变化规律具有重要的学术价值。有不少学者提出了对于碳中和变化预测方法的创新研究，刘泽淼[2]综合运用了 WITCH 评估模型与 IBIS 植被动态模型在各种经济情景下的碳中和路径分析，并预测了碳中和所能达成的时间。李姝晓[3]利用灰色模型和马尔可夫链预测在不同情景和客源市场下的海南省旅游行业碳中和的实现。马新萍[4]采用了 PLUS 模型模拟了秦岭地区碳中和的空间分布，并运用气体扩散的相关定律计算得到了其山地碳中和对周边地区的影响效应。高峰[5]主要运用了 CASA 模型和灰色模型预测了青藏高原地区在不同情景下的碳中和发展状况。

本文基于碳中和所衍生的金融产品市场交易情况，选取了中国香港证券交易所的中国碳中和（01372）股票（2018 年 8 月 1 日—2023 年 8 月 1 日）的每日收盘价，将粒子群算法结合 BP 神经网络模型用于其股票市场价格的预测分析之中。

二、理论模型

（一）粒子群算法

粒子群算法是一种模拟自然界生物随机搜索觅食的行为算法，Eberhart 和 Kennedy 在 1995 年提出，现已广泛运用到各种学科领域的算法优化问题中。其基本思想是通过群体中每个个体之间信息共享以实现个体和群体的最优解。假如有一个鸟群在随机觅食，那么最佳的办法就是搜索距离食物最近的鸟所在的区域，每只鸟个体传递自己距离食物的信息，从而资源共享达到鸟群体觅食最优。

算法将群体中的每一个个体看作是在多维空间随机搜索的一个粒子，每个粒子代表一种可行解。而每一个粒子有三个特征信息，分别是位置、速度、适应

★基金项目：国家统计局统计科学研究项目（2014LY096），黑龙江省第四次全国经济普查项目 (2020022)。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

度。位置表示粒子的在空间中的方位，速度表示粒子移动的快慢程度，适应度表示评价粒子的优劣值，一般是设置为目标函数值。

首先算法会初始化一群随机的粒子，然后通过不断的迭代寻找到最优解。每一次迭代的方法是通过跟踪两个极值，一是粒子个体所寻找到的最优解称为个体极值，二是粒子群群体所寻找到的最优解称为全局极值，也可以用群体中的一部分粒子作为个体粒子的邻居称为局部极值[6]。

假设在一个 D 维空间中，有 N 个初始粒子构成一个粒子群群体，其中第 i 个粒子的位置是一个如下的 D 维向量：

$$X_i=(x_{i1},x_{i2},\ldots,x_{iD}),i=1,2,\ldots,N \quad (1)$$

第 i 个粒子的速度表示为：

$$V_i=(v_{i1},v_{i2},\ldots,v_{id}),i=1,2,\ldots,N \quad (2)$$

每一次迭代每个粒子体会有一个最优解 P_{best}，和整个粒子群群体的最优解 g_{best}。第 i 个粒子每一次迭代根据如下公式更新自己的位置和速度：

$$v_{id}=w\times v_{id-1}+c_1r_1(p_{id}-x_{id})+c_2r_2(p_{gd}-x_{id}) \quad (3)$$

$$x_{id+1}=x_{id}+v_{id} \quad (4)$$

其中在速度更新公式里，w 为惯性权重，代表粒子的反应速度即上一期的运动惯性，体现了继承之前速度的能力，一个较大的惯性权重有利于全局搜索，而一个较小的惯性权重有利于局部搜索。c_1、c_2 是学习因子，r_1、r_2 是在 [0,1] 范围内的随机数，分别代表了粒子向自己历史最佳位置逼近的趋势和向群体历史最佳位置逼近的趋势。在位置更新公式里，下一期的位置等于本期位置加上本期速度乘以时间，时间一般则取 1 个单位。

（二）BP 神经网络

作为初始的人工神经网络，具有计算简便处理效率高的优点，处理线性问题时具有良好的表现，但面对非线性问题时则较为捉襟见肘。BP 神经网络在初始的人工神经网络基础上增加了隐藏层，采用多层前馈网络，通过多维函数的映射能力，增强了网络的分类识别能力。

BP 神经网络包括输入层、隐藏层、输出层。一般输入层和输出层是固定的，输入一般是样本的变量个数，而输出一般是标签个数，但隐藏层节点个数则可以根据研究数据信息特征自行设定。BP 神经网络运行过程是有两部分组成，向前传播和反向计算。向前传播时，从输入层输入变量数据，经隐藏层逐层处理，再转到输出层得到标签结果，每一层神经元的状态都会受上一层神经元状态的影响并经过本层处理从而影响着下一层神经元的状态。BP 神经网络结构示意图如图 1 所示。

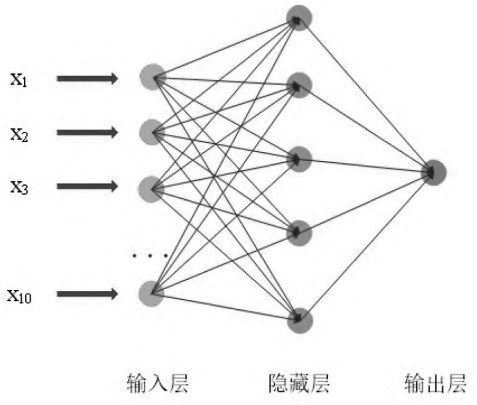

图 1　BP 神经网络模型

向前传播时设输入层有 m 个节点，隐藏层有 r 个节点，输出层有 n 个节点，输入层与隐藏层间的权重为 W，偏置项为 a，隐藏层与输出层的节点为 V，偏置项为 b，输入变量为 X，隐藏层为 Y 和输出层为 Z，则输出结果分别为：

$$Z_j^{'}=f_2\left(\sum_{k=1}^{r}V_{jk}Y_k+b_{jk}\right),j=1,\ldots,n \quad (5)$$

$$Y_k=f_1\left(\sum_{i=1}^{m}W_{ki}X_i+a_{ki}\right),k=1,\ldots, \quad (6)$$

设有 s 个输入变量，每个输入变量都存在一定误差，则建立误差函数为：

$$L_s=\frac{1}{2}\sum_{j=1}^{m}\left(z_{js}-z_{js}^{'}\right)^2 \quad (7)$$

然后根据误差调整神经元传输过程中的权重大小，会依照梯度下降法反向计算。参考上述公式关系，可以得出权重 W 和 V 的变化情况分别为：

$$\Delta V_{jk}=-\alpha\frac{\partial L_s}{\partial V_{jk}}=-\alpha\frac{\partial L_s}{\partial Z_{js}^{'}}\cdot\frac{\partial Z_{js}^{'}}{\partial\sum_{k=1}^{r}V_{jk}Y_k}\cdot\frac{\partial\sum_{k=1}^{r}V_{jk}Y_k}{\partial V_{jk}}$$
$$=-\alpha\left(-\sum_{j=1}^{m}\left(z_{js}-z_{js}^{'}\right)\right)\cdot f_2^{'}\left(\sum_{k=1}^{r}V_{jk}Y_k\right)\cdot Y_k \quad (8)$$

★通讯作者：郝立丽（1978-），女，黑龙江庆安人，副教授，硕士生导师，主要从事统计理论与方法。

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

$$\Delta W_{ki} = -\alpha \frac{\partial L_s}{\partial W_{ki}}$$

$$= -\alpha \frac{\partial L_s}{\partial Z'_{js}} \cdot \frac{\partial Z'_{js}}{\partial \sum_{k=1}^{r} V_{jk} Y_k} \cdot \frac{\partial \sum_{k=1}^{r} V_{jk} Y_k}{\partial Y_k} \cdot \frac{\partial Y_k}{\partial \sum_{i=1}^{m} W_{ki} X_i} \cdot \frac{\partial \sum_{i=1}^{m} W_{ki} X_i}{\partial W_{ki}} \quad (9)$$

$$= -\alpha \left(-\sum_{j=1}^{m} \left(z_{js} - z'_{js} \right) \right) \cdot f'_2 \left(\sum_{k=1}^{r} V_{jk} Y_k \right) \cdot V_{jk} \cdot f'_1 \left(\sum_{i=1}^{m} W_{ki} X_i \right) \cdot X_i$$

经过各层神经元反复的训练学习，按照上述公式所体现的权重变化，确定与最小误差相对应的权重信息，则神经网络训练停止，此时得出经过非线形转换的最小误差结果。

三、实证研究

（一）数据集信息

本文使用的数据集选取了中国香港证券交易所的中国碳中和（01372）股票（2018 年 8 月 1 日—2023 年 8 月 1 日）的每日收盘价，图 2 表示数据集的时间变化趋势。

图 2　中国碳中和股票（01372）收盘价
（2018 年 8 月 1 日—2023 年 8 月 1 日）

从这五年的长期趋势上看，近期中国碳中和股票收盘价相较于前一两年有较为明显的回落。在 2021 年中国碳中和股票收盘价开始有较为明显的攀升趋势之前，中国碳中和股票收盘价一直处于低位运行的变动规律，只在 2019 年前后有一个高峰期。这与各种能源的使用频率有关，一般在每年年尾处于冬季的时候，属于各种能源需求量的高涨期，收盘价也随之有一定幅度上升。

（二）对比模型与评估指标

为了验证所提出模型预测的准确性，本文还设置了四种基本模型作为对照组进行对比实验。分别是支持向量机（SVM）模型和随机森林（RF）模型。然后是基本的 BP 神经网络模型（BP），和经过遗传算法优化的 BP 神经网络模型（GA-BP）。使用以上模型分别对实验数据集进行对比预测。

为了评价模型的预测效果，本文采取四个指标来对模型的预测精度进行测算。这四个指标分别是拟合优度 R^2，平均绝对误差 MAE，均方根误差 RMSE，平均绝对百分比误差 MAPE，具体公式表示如下：

$$R^2 = 1 - \frac{\sum_{t=1}^{N} \left(T_t - P_t \right)^2}{\sum_{t=1}^{N} \left(T_t - \overline{T_t} \right)^2} \quad (10)$$

$$MAE = \frac{1}{N} \sum_{t=1}^{N} \left| T_t - P_t \right| \quad (11)$$

$$RMSE = \sqrt{\frac{1}{N} \sum_{t=1}^{N} \left(T_t - P_t \right)^2} \quad (12)$$

$$MAPE = \frac{1}{N} \sum_{t=1}^{N} \left| \frac{T_t - P_t}{T_t} \right| \times 100\% \quad (13)$$

式中 T_t 表示 t 时刻的真实值，P_t 表示 t 时刻的预测值，N 表示用于预测的样本量。R^2 表示预测值与真实值的接近程度，值越大代表两者越接近，预测效果越好。MAE 表示了预测值与真实值之间的绝对误差，值越小代表两者越吻合。RMSE 表达了一种回归效果，值越小表示效果越佳。MAPE 表示预测值与真实值之间的绝对误差占据真实值的比例大小，消除了量纲和数量级对误差可视化的影响，值越小表示精度越高。

（三）模型建立

步骤一：由于本文利用中国碳中和（01372）股票价格的历史信息，即采用滚动预测的方式，模拟时间序列数据的未来发展趋势。对中国碳中和（01372）股票的价格进行矩阵构造，本文采用前十个历史数据作为输入，第十一个数据作为输出，例如：第一组 $x_1, x_2 \cdots x_{10}$ 作为输入，x_{11} 作为输出；第二组 $x_2, x_3 \cdots x_{11}$ 作为输入，x_{12} 作为输出…一直到最后一组数据，延时步长为 10 的一步预测。

步骤二：对于构造好的数据集矩阵进行划分，前 80% 的数据集作为训练集，后 20% 的数据集作为测试集。对划分好的训练集和预测集分别进行归一化处理。在输入模型之前和训练完成之后会进行归一化与反归一化的操作。

步骤三：建立 BP 神经网络，按照训练集前十个输入模式设置输入层节点，按照训练集第十一个输出模式设置输出层节点，设置隐藏层节点数为 5。神经

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

元传输之间权重的迭代优化按照梯度下降法进行计算，训练次数为 1000，学习率为 0.01。

步骤四：建立粒子群算法优化 BP 神经网络初始权重，产生最佳的初始权重代入 BP 神经网络迭代优化。首先依照 BP 神经网络节点总数设置初始种群与速度，然后采取使得均方根误差最小的准则，进行个体与全局寻优，从而达到个体与全局最优化的结果。最后，从个体与全局最优化的结果中提取从输入层到隐藏层以及从隐藏层到输出层的权值与偏置项，提取出最优的权值与偏置项后代入 BP 神经网络中进行训练学习。

步骤五：训练完成后得到预测值与测试集的真实值计算相关的评估指标，如 R^2、MAE、RMSE、MAPE。

四、结果分析

（一）预测图像

按照上述的建模过程，将实验数据集代入模型之中训练学习可以得到以下的输出预测结果与测试集的对比图像，具体情况见图 3。

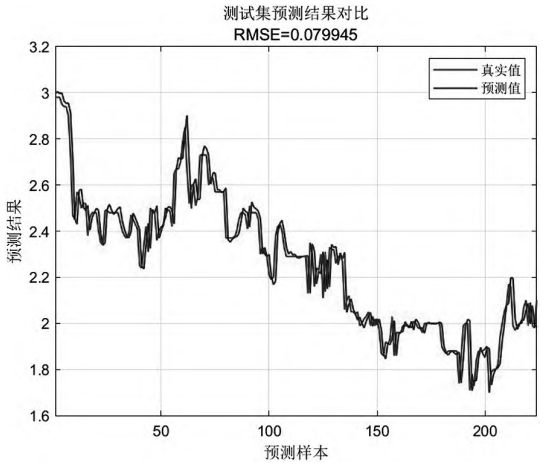

图 3　模型预测结果对比

图 3 表示本文所设计的 PSO-BP 神经网络模型测试集的预测值与真实值的对比情况，红线表示的真实值，而蓝线表示的预测值。从图中可以看出，两条趋势线非常接近，几乎重合，只有在价格波动较为剧烈的时候，预测值与真实值才有略微出入，整体预测精度较为良好。

（二）模型对比

本文设置了四种基础模型对未来价格趋势演变进行预测，并根据上述评估指标计算预测精度见表2。

表 1　模型预测结果对比

模型	R^2	MAE	RMSE	MAPE
SVM	0.165	0.854	1.820	12.384%
RF	0.727	0.518	1.040	8.078%
BP	0.848	0.096	0.113	4.360%
GA-BP	0.876	0.081	0.102	3.653%
PSO-BP	0.923	0.052	0.080	2.358%

从表 2 中可以看出，BP 神经网络模型相较于其他两种基础的机器学习算法支持向量机（SVM）和随机森林（RF）有着较为明显的预测精度的提高。这得益于模型反向迭代计算的运行机理对数据非线性特征的学习，从而可以对数据隐含规律挖掘的更为充分。

除了本文所设计的采取粒子群算法（PSO）优化 BP 神经网络的重要参数之外，还设置了使用遗传算法（GA）优化 BP 神经网络作为实验对照组。从两种优化算法对 BP 神经网络进行改进之后，可以看出，经过优化算法改进的 BP 神经网络模型明显预测效果又得到了进一步的提高。R^2 值都在 0.9 左右，而均方根误差也都降到了 0.1 左右。这主要是通过优化算法的改进，使得 BP 神经网络模型的一些重要参数设置的更为合理，更能够高效的学习到数据信息特征，从而最大化的提高预测精度。

在粒子群算法和遗传算法两种优化算法对 BP 神经网络模型改进的比较之中，可以看出，粒子群算法优化后的 BP 神经网络模型有着更为良好的预测表现，MAPE 值提升了有 1 个百分点。这说明粒子群算法的模拟迭代过程更能捕捉到 BP 神经网络模型重要参数的最优设置值。

参考文献：

[1] 王艳娟 . 基于大数据的空气质量对游客情绪变动影响研究 [J]. 统计与咨询 ,2022(05):4-9.

[2] 刘泽淼 , 黄贤金 , 卢学鹤等 . 共享社会经济路径下中国碳中和路径预测 [J]. 地理学报 ,2022,77(09):2189-2201.

[3] 李姝晓 , 童昀 , 何彪 . 多情景下海南省旅游业的碳达峰与碳中和预测 [J]. 经济地理 ,2023,43(06):230-240.

[4] 马新萍 , 李晶 , 余玉洋等 . 秦岭山地碳中和空间服务范围及其模拟预测 [J]. 生态学报 ,2022,42(23):9431-9441.

[5] 高峰 , 律可心 , 乔智等 . 青藏高原东缘生态过渡带碳中和评估与预测 [J]. 生态学报 ,2022,42(23):9442-9455.

[6] 邓宇轩 . 基于自适应 PSO-BP 神经网络的城轨造价预测研究 [J]. 建筑经济 ,2023,44(S1):92-96.

（作者单位：东北林业大学经济管理学院）

(C)1994-2023 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net