文章编号:2096-1472(2024)05-0007-07
DOI:10.19644/j.cnki.issn2096-1472.2024.005.002

基于深度学习的股票价格指数预测

高 源,黄 犀

(南京邮电大学经济学院,江苏 南京 210023)
✉ 2249139525@qq.com; wei.huang@njupt.edu.cn

摘 要:文章以2012—2022年上证50、沪深300、中证500三支股指交易数据为研究对象,利用深度学习预测股指,分别构建了卷积神经网络(CNN)模型、长短期记忆神经网络(LSTM)模型和CNN-LSTM组合神经网络模型,使用均方根误差(RMSE)、平均绝对误差(MAE)、平均百分比误差绝对值(MAPE)和决定系数(R^2)4个指标对模型进行评价。结果表明,组合模型兼有CNN模型的高维特征挖掘优势和LSTM模型的时序特征提取优势,在3支股指的预测中,组合模型的预测精度均高于CNN模型和LSTM模型单一模型,其RMSE指标分别提升了28.60百分点、52.56百分点和25.28百分点,证实了CNN-LSTM组合神经网络模型的有效性和准确性。

关键词:深度学习;股指预测;CNN模型;LSTM模型;CNN-LSTM组合神经网络模型

中图分类号:TP183 **文献标志码**:A

Stock Price Index Prediction Based on Deep Learning

GAO Yuan, HUANG Wei

(*School of Economics, Nanjing University of Posts and Telecommunications, Nanjing* 210023, *China*)
✉ 2249139525@qq.com; wei.huang@njupt.edu.cn

Abstract: Taking trading data of SSE50 (Shanghai Stock Exchange 50), CSI300 (China Securities Index 300), and CSI500 (China Securities Index 500) stock indexes from 2012 to 2022 as the research objects, this paper proposes to use Deep Learning to predict stock indexes. Convolutional Neural Network (CNN) model, Long Short-Term Memory Neural Network (LSTM) model, and CNN-LSTM combined neural network models are constructed to predict stock indexes. The model is evaluated using four indicators: Root Mean Square Error (RMSE), Mean Absolute Error (MAE), Mean Absolute Percentage Error (MAPE), and Coefficient of Determination (R^2). The results show that the combined model has the advantages of high-dimensional feature mining of CNN model and temporal feature extraction of LSTM model. In the prediction of the three stock indexes, the prediction accuracy of the combined model is higher than that of the CNN and LSTM single models. Its RMSE indicators have increased by 28.60 percentage points, 52.56 percentage points, and 25.28 percentage points respectively, verifying the effectiveness and accuracy of the CNN-LSTM combined neural network model.

Key words: Deep Learning; stock index prediction; CNN model; LSTM model; CNN-LSTM combined neural network model

0 引言(Introduction)

随着金融数字化的快速发展,金融市场的数据量呈现指数级增长,传统统计模型在股票市场预测的线性、低维缺点日益明显,无法充分挖掘金融时序数据的信息和准确把握股票价格

收稿日期:2023-09-07

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

走向。与此同时,机器学习、深度学习等模型在多领域的应用不断深化,其强大的非线性、高维数据处理能力与金融数字化不断融合发展,在金融时间序列尤其是股指预测领域取得了不错的效果。

目前,在利用深度学习的股市预测任务中,普遍采用卷积神经网络(CNN)模型、循环神经网络(RNN)模型、长短期记忆神经网络(LSTM)模型等单一模型,但每一种模型都有不足之处,例如卷积神经网络模型未考虑时序信息,循环神经网络模型存在梯度爆炸[1],以及长短期记忆神经网络模型无法精准把握高维信息等,在一定程度上影响了模型预测的准确性。为了解决上述问题,提高预测的准确性,本文在参考国内外文献的基础上,提出了 CNN-LSTM 组合神经网络模型,该模型在单一模型的基础上,结合了 CNN 高维特征挖掘能力与 LSTM 时序特征提取能力,提高了模型的预测精度,进一步优化深度学习模型在金融领域的应用。

1 相关研究(Related research)

从单一模型到优化模型再到组合模型,深度学习模型被不断深入应用于金融领域。从单一模型角度来看,彭燕等[2]结合 LSTM 的特性和股票市场的特点,搭建不同层数与相同层数下不同隐藏神经元个数的 LSTM 模型,预测准确率提高了 30 百分点。就优化模型的角度而言,裴大卫等[3]将多因子模型思想引入股价预测模型中,在单变量长短期记忆网络的基础上建立多变量长短期记忆网络股价预测模型,不仅提高了模型的预测准确率,并且具有更好的模型鲁棒性。宋刚等[4]提出的自适应粒子群优化的长短期记忆股价预测模型,对在沪交所(上海证券交易所)、深交所(深圳证券交易所)和港交所(香港交易及结算所有限公司)上市的股票数据进行比较分析,得到准确度高、具有普遍适用性的模型。

近年来,一些组合模型应用于股票价格预测取得较好的结果。王东等[5]针对股票数据变量较多、数据信息存量存在重叠等问题,提出首先利用主成分分析法降维,然后根据股票特性对模型进行调整后再开展预测,在大大减少运行时间的基础上降低预测平均误差。杨语蒙等[6]通过 GA(遗传算法)全局寻优模型寻找 LSTM 预测模型的最优参数,对沪深 300 股票收盘价进行预测,对比 LSTM 单一模型和 GA-LSTM 组合模型,得到 GA-LSTM 模型更优的结论。李辉等[7]为降低数据维度和后续模型的训练复杂度,利用随机森林对股票数据选择最优特征集,再通过长短期记忆神经网络模型对股票价格进行预测,对预测模型进行参数调优。张怡[8]在 LSTM 模型的基础上引入注意力机制,形成 AT-LSTM 模型,将 ARIMA(差分整合移动平均自回归模型)的预测残差引入 AT-LSTM,提高了模型的预测精度。许艺玮等[9]以 2017—2022 年的 4 支白酒股票作为研究对象,提出极限梯度提升机和长短期记忆神经网络模型组合的 XGB-LSTM 股票价格预测模型,结果表明组合模型预测损失最小,拟合度最高。

综上所述,深度学习应用于股票价格预测的研究较为丰富,使用不同的数据处理方法和组合算法模型对预测结果的精度有很大影响。本文沿用组合模型的方法,将卷积神经网络模型和长短期记忆神经网络模型进行组合,再将预测结果与上述两个模型分别进行对比,验证组合模型的有效性。

2 深度学习算法(Deep Learning algorithm)

2.1 卷积神经网络模型

卷积神经网络模型是深度学习中的一个经典算法,在计算机视觉领域具有出色的性能表现,它主要通过局部连接和权值共享降低神经元间连接的权重个数,从而避免了在网络中因参数过多而引起的过拟合等问题[10]。

卷积神经网络主要由输入层、卷积层、池化层、全连接层、输出层组成。

(1)卷积层

卷积层是 CNN 模型中关键的一层,通过卷积层可以有效地对输入数据进行特征提取,卷积层接收输入数据后,使用一个或多个较小的卷积核对数据进行卷积操作,卷积核的大小通常是 2 * 2 或者 5 * 5,本文选择与卷积核尺寸相同的滑动窗口,将卷积核内的元素和滑动窗口内的数据作为点乘,按一定的步长从左至右和从上至下依次移动窗口,卷积操作完成后生成与卷积核个数一样数量的特征图。卷积运算示意图如图 1 所示,卷积操作用的数学公式如下:

$$s(n)=(f*w)(n)=\begin{cases}\int_{-\infty}^{+\infty} f(x)\omega(n-x)\mathrm{d}x,\text{连续形式}\\ \sum_{-\infty}^{+\infty} f(x)\omega(n-x),\text{离散形式}\end{cases} \tag{1}$$

其中:函数 f 为输入,ω 为核函数,输出 s 为特征映射。

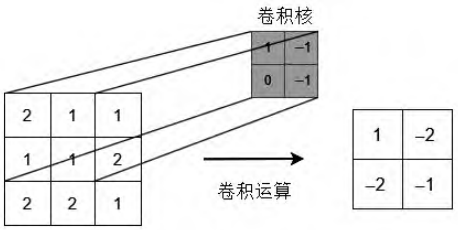

图 1 卷积运算示意图

Fig. 1 Convolution operation diagram

(2)池化层

卷积层之后通常连接池化层,二者是成对出现的,这是因为卷积层生成的特征图的信息量相比未进行卷积运算前的信息量呈指数级增长,池化层通过对特征图进行下采样处理减小特征图的尺寸,保留大部分特征信息的同时降低网络的复杂度,尽可能地避免过拟合现象,常用的池化方式有最大池化(保留滑动窗口内的最大值)、均池化(保留滑动窗口内的平均值)及全局均池化,最大池化示意图如图 2 所示。

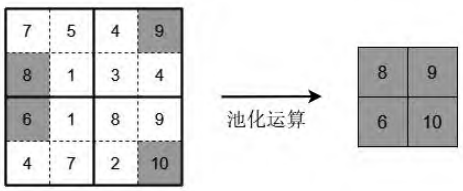

图 2 最大池化示意图

Fig. 2 Diagram of maximum pooling

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

(3)全连接层

全连接层是卷积神经网络模型中非常重要的一部分,该层的所有神经元与上一层的所有神经元互相连接,其作用是将之前卷积层提取的局部特征整合起来,赋予每个特征一个权重,并映射到输出空间给出预测结果。卷积神经网络模型通常有两层全连接层,池化层之后的第一个全连接层称为扁平化层,它的作用是将经历卷积层、池化层运算后输出的高维特征矩阵扁平化为一维向量,以便传入下一个全连接层,该向量保留了原始特征的非线性关系;第二个全连接层作为输出层,它的作用是获得最终的预测结果。

2.2 长短期记忆神经网络模型

长短期记忆神经网络模型是循环神经网络模型的一种优化算法[11],是一种具有记忆功能的神经网络模型,可以很好地处理时间序列数据中的长期依赖关系。作为RNN模型的改进模型,LSTM模型引入了门控机制和记忆单元,每一个模块都由遗忘门(FG)、输入门(IG)和输出门(OG)3个门控单元组成,依据门控机制控制信息流动及更新记忆单元。

LSTM模型内部结构图如图3所示。

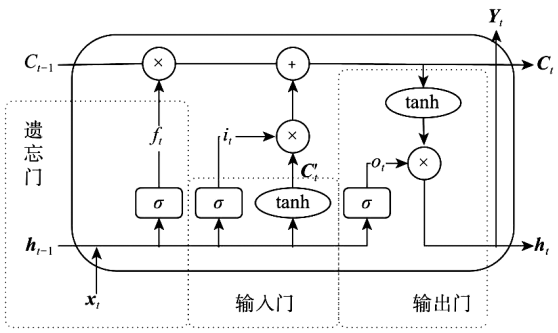

图3　LSTM模型内部结构图

Fig.3 LSTM model internal structure diagram

在LSTM模型结构中,遗忘门负责选择性地记忆和遗忘前一时间步的单元状态输入信息,通过在模型中新增单元状态 c_t 保留一定比例的信息,依据上一时刻的隐藏状态 h_{t-1} 和当前时刻的输入 x_t 计算保留信息的比例,公式如下:

$$f_t=\sigma(\omega_f\cdot[h_{t-1},x_t]+b_f) \tag{2}$$

其中:$\sigma(\cdot)$表示sigmoid函数,它负责输入信息映射到[0,1]的区间内,ω_f 和 b_f 分别为权重和偏置,f_t 是信息的保留比例。

输入门将当前时间步传递的输入信息进行过滤,选择部分新信息与遗忘门处理过的信息,结合后更新单元状态 c_t,计算公式如下:

$$i_t=\sigma(\omega_i\cdot[h_{t-1},x_t]+b_i) \tag{3}$$

$$\tilde{c}_t=\tanh(\omega_c\cdot[h_{t-1},x_t]+b_c) \tag{4}$$

$$c_t=i_t\tilde{c}_t+f_tc_{t-1} \tag{5}$$

输出门负责控制当前时刻的隐藏状态中输出信息的质量,并将本单元的信息与状态传入下一个单元,计算公式如下:

$$o_t=\sigma(\omega_o\cdot[h_{t-1},x_t]+b_o) \tag{6}$$

最终得到当前时间步的输出值:

$$y_t=h_t=o_t\tanh(c_t) \tag{7}$$

从以上LSTM模型更新记忆的过程可以看出,LSTM模型的特殊结构可以挖掘长时间序列数据间存在的依赖关系,避免了RNN模型中梯度爆炸和梯度消失的问题,弥补了RNN模型在处理长期信息时的局限性[12]。

3 数据来源与预处理(Data source and preprocessing)

3.1 数据来源

股票价格指数是度量和反映股票市场总体价格水平及其变动趋势的股价统计相对数,它是国家经济形势的综合反映,因而受到广大投资者的关注。为了更好地验证模型的有效性和泛化性,本文选取2012年1月1日至2022年12月31日的上证50、沪深300、中证500三支股指交易数据作为研究对象,包括收盘指数、开盘指数、最低指数、最高指数、日成交量和日成交金额6个特征,共2 673个交易日的数据。数据来源于国泰安数据库。

3.2 数据预处理

3.2.1 归一化

本文采用Min-max标准化也称为离差标准化,通过对原始数据进行线性变化使其映射在[0,1]的区间,其公式表示如下:

$$y_i=\frac{x_i-x_{\min}}{x_{\max}-x_{\min}} \tag{8}$$

其中:y_i 为经过标准化的量纲一数据,x_i 为原始数据,$x_{\min}$ 和 $x_{\max}$ 分别为原始数据的最小值和最大值。本文采用这一规范化方法,是为了消除量纲对收盘指数的影响。

3.2.2 训练集、测试集的划分

放入模型训练前,需将原数据集划分为训练集和测试集。训练集用于初次放入模型寻找数据间的关系;测试集用于评价数据相关关系的可靠性,并且不断地对模型给出反馈,以提高模型的稳定性和泛化性。本文将数据集按8∶2的比例划分训练集和测试集。在划分样本时,经过多次尝试,选取20个交易日为一个样本,用于预测第21日的股票价格。

4 实验及结果分析(Experiment and result analysis)

4.1 实验环境

本文构建深度学习模型所用的设备为Win10 64位系统,内存为8 GB,处理器是Intel(R) Core(TM) i5-7300HQ CPU@2.50GHz为2.50 GHz。本文模型的构建全部采用编程语言Python,IDE(集成开发环境)为Pycharm2020。Python在处理深度学习时具有独特的优势,其拥有众多成熟且强大功能的第三方库,大大提高了编程效率。第三方库介绍如表1所示。

表1　第三方库介绍

Tab.1 Introduction to third-party libraries

库名	版本	说明
Numpy	1.24.2	高效的多维数组操作和数学函数库
Pandas	1.5.3	高性能、易用的数据处理分析库
TA-Lib	0.4.24	专用于金融技术指标计算的函数库
Scikit-learn	1.2.1	众多机器学习算法和工具库
Tensorflow	2.11.0	支持神经网络算法开源深度学习库
Matplotlib	3.6.2	数据可视化库

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

4.2 评价指标

本文对 3 支股票指数进行预测，因此采用多个指标对预测结果进行评价，以便更全面且客观地体现不同模型的预测效果。本文选取 RMSE、MAE、MAPE 和 R^2 作为预测结果的评价标准。

RMSE 是预测值和真实值误差平方和的均值开方所得，该指标可以体现模型的拟合能力。

$$RMSE = \sqrt{\frac{1}{n}\sum_{i=1}^{n}(y_i - \hat{y}_i)^2} \tag{9}$$

MAE 是预测值和真实值误差绝对值的均值，其相对均方误差具有更好的鲁棒性，降低了异常值的影响，可以反映预测误差的实际情况。

$$MAE = \frac{1}{n}\sum_{i=1}^{n} | y_i - \hat{y}_i | \tag{10}$$

MAPE 是预测值与真实值绝对误差和真实值比值的均值。MAPE 用百分比衡量误差，避免了量纲的影响，用来评价模型的预测准确度。

$$MAPE = \frac{1}{n}\sum_{i=1}^{n}\left|\frac{\hat{y}_i - y_i}{y_i}\right| \tag{11}$$

R^2 反映了预测值与真实值之间的拟合程度。通常为 0～1 的数，其公式如下：

$$R^2 = 1 - \frac{\sum_{i}^{n}(\hat{y}_i - y_i)^2}{\sum_{i}^{n}(\hat{y}_i - \bar{y})^2} \tag{12}$$

其中：y_i 表示真实值，$\hat{y}_i$ 表示预测值，n 为测试集样本数。

以上 4 个指标均能体现模型的预测效果，只是反映误差的角度不同，故综合使用 4 个指标会使评价更准确更客观。其中，RMSE、MAE、MAPE 越小越好，也表示模型预测误差越小。R^2 越接近 1，表示模型的预测结果越准确，拟合效果也越好。

4.3 模型结构与超参数优化

4.3.1 CNN 模型结构

CNN 模型具有出色的数据特征提取能力，常用于计算机视觉、自然语言处理等任务。CNN 模型通常由输入层、隐藏层、全连接层构成，CNN 模型结构图如图 4 所示。

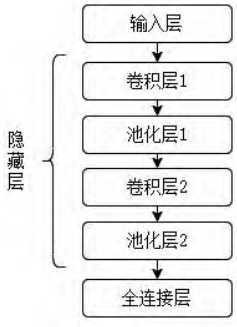

图 4 CNN 模型结构图

Fig. 4 CNN model structure diagram

CNN 模型的第一层为输入层，第二层为隐藏层，其中包含多个卷积层和池化层的组合。经过多次尝试，选取两组卷积层和池化层作为隐藏层，包含卷积核大小、卷积核个数，以及池化核大小等超参数。第三层为全连接层，它将数据最终输出为一维数据，经过反归一化后，得到股价数据。

4.3.2 LSTM 模型结构

LSTM 模型作为深度学习中的重要模型，不仅具有记忆历史数据信息的优点，同时可以针对历史信息的重要性选择性地给予权重，非常适用于时间序列预测，其架构分为 3 个部分：输入层、隐藏层及全连接层，LSTM 模型结构图如图 5 所示。

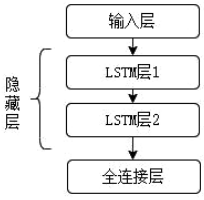

图 5 LSTM 模型结构图

Fig. 5 LSTM model structure diagram

LSTM 模型的第一层为输入层，第二层为隐藏层。经过多次尝试，选取两个 LSTM 层构成隐藏层。为了避免过拟合，每个 LSTM 层都设置了 dropout（神经元随机丢弃率）超参数。第三层为全连接层，也称为输出层。将隐藏层中最后一层的数据转换为一维数据，经反归一化后，得到股价预测数据。

4.3.3 CNN-LSTM 组合神经网络模型结构

为了充分利用 CNN 模型和 LSTM 模型的优点，CNN 模型具有较好的数据特征提取优势，可以提取 LSTM 模型无法提取的高维特征信息，挖掘出股价变化的规律；LSTM 模型对于时序数据具有独特的优势，可以把握不同时期的数据的重要性，并赋予不同的权重，避免早期数据在训练时逐渐消失，更准确地预测股价。本文构建了 CNN-LSTM 组合神经网络模型，包含输入层、隐藏层、全连接层（输出层）3 个模块，CNN-LSTM 组合神经网络模型结构图如图 6 所示。

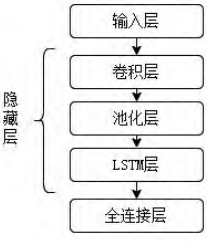

图 6 CNN-LSTM 组合神经网络模型结构图

Fig. 6 Structure diagram of CNN-LSTM combined neural network model

4.3.4 超参数优化

构建模型后，在开始训练前，需要设置一些初始超参数，具

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

体如下。

(1)卷积核的个数(Kernel Size)和大小(Number):考虑到本文数据的维度,最终设定卷积层1和卷积层2中的卷积核大小均为3*3,卷积核个数通常为32个、64个和128个。

(2)池化核大小:池化层1和池化层2中的池化核大小均为2*2。

(3)隐藏神经元个数(Units):对于两层LSTM层,通常第二层神经元的个数是第一层神经元个数的两倍。

(4)每批训练数据量大小(Batch_Size):该参数代表单次放入多少条数据进行训练。

(5)迭代次数(epoch):一个epoch代表所有训练集完整训练一次。因此,迭代次数不能设置过小,否则容易导致欠拟合,使模型训练不充分。同时,迭代次数设置太多,又会导致模型过拟合,随着epoch的增加,损失函数逐渐趋平。为了避免出现以上情况,本文加入早停策略,即损失函数在多个epoch后变动不大时,停止训练。

(6)神经元随机丢弃率(Dropout):为了避免模型过拟合,随机丢弃神经元,可以使模型得到更完全的训练,增加其泛化能力。

(7)优化器(Optimizer):优化是指训练过程中损失函数减少的过程,而优化器则是指优化方法,常用的优化器有SGD(随机梯度下降)和Adam(自适应矩阵估计)两种。SGD虽然能在短时间内得到较好的结果,但是容易陷入局部最优解。Adam优化了SGD的缺点,加入了更新的动量和自适应学习率,提高了优化的精度,虽然会延长训练时间,但是对本文数据集的影响不大,故本文选取Adam作为优化器。

为了使模型达到更好的预测效果,本文设置了网格调参,即为同一参数输入多个值,不断组合多个参数的不同值,选择最优组合。在CNN模型、LSTM模型和CNN-LSTM组合神经网络模型中,主要对CNN模型卷积层中卷积核的个数和LSTM模型层中神经元的个数进行了网格调参,同时将最优参数组合的模型进行保存。网格调参具体设置如表2所示。

表2　网格调参表

Tab.2 Network grid parameter table

参数	参数值
batch_size	32,64,128
number1	32,64
number2	64,128
units1	64,128
units2	128,256

4.4　实验结果分析

为了验证CNN-LSTM组合神经网络模型应用于股票价格指数预测的有效性和准确性,以及相较于CNN和LSTM单一模型的优越性。采用RMSE、MAE、MAPE、R^2四个指标,同时为了更直观地表现预测效果,本研究绘制了股价预测值和实际值的走势图,如图7至图15所示。不同模型在测试集中的预测效果评价表如表3所示。

表3　不同模型在测试集中的预测效果评价表

Tab.3 Evaluation table of predictive performance of different models on the test set

股指名称	模型	*RMSE*	*MAE*	*MAPE*/%	R^2/%
上证50	CNN	89.948 3	70.560 1	2.29	94.43
	LSTM	58.021 9	43.886 8	1.41	97.68
	CNN-LSTM	41.427 6	31.435 6	1.01	98.82
沪深300	CNN	150.110 6	115.594 2	2.51	92.10
	LSTM	124.294 0	96.490 4	2.04	94.59
	CNN-LSTM	58.967 9	45.445 1	0.99	98.78
中证500	CNN	213.177 9	164.584 9	2.54	78.56
	LSTM	116.828 6	90.866 5	1.41	93.56
	CNN-LSTM	87.298 7	65.779 0	1.02	96.40

结果表明:CNN-LSTM组合神经网络模型在上证50、沪深300、中证500三支股指中的预测效果优于CNN模型、LSTM模型的预测效果,RMSE分别达到了41.427 6、58.967 9、87.298 7,相较于两个单一模型的最优情况提升了28.60百分点、52.56百分点、25.28百分点,MAE、MAPE和R^2三项指标也优于两个单一模型,证明了CNN-LSTM组合神经网络模型的有效性。

不同深度学习模型应用于上证50、沪深300、中证500三支股指交易数据获得的预测股价与真实股价的对比如图7至图9所示。从图中可以看出,LSTM模型的预测性能优于CNN模型的预测性能,CNN-LSTM组合神经网络模型的预测性能优于单一模型的预测性能,其预测更精准和有效。

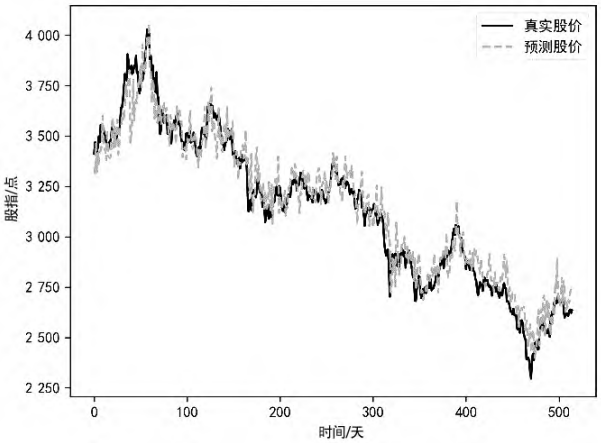

图7　上证50CNN模型测试集股指预测

Fig. 7 SSE50 CNN model test set stock index forecast

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net

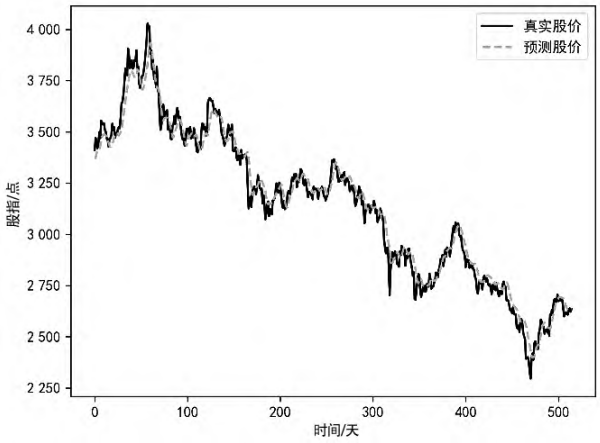

图 8 上证 50LSTM 模型测试集股指预测

Fig. 8 SSE50 LSTM model test set stock index forecast

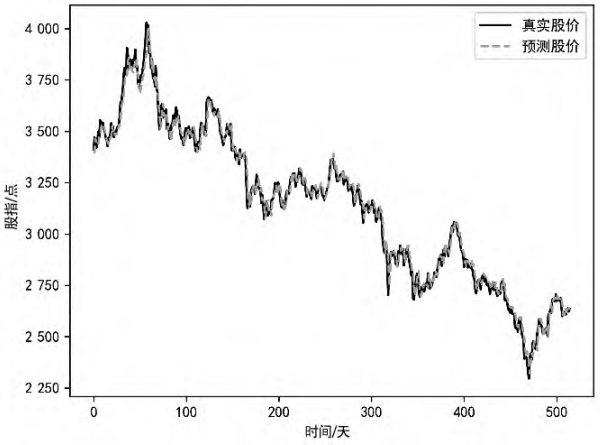

图 9 上证 50CNN-LSTM 模型测试集股指预测

Fig. 9 SSE50 CNN-LSTM model test set stock index forecast

由图 7 至图 9 可见，在 3 种模型中，上证 50CNN-LSTM 组合模型的测试集拟合度优于 CNN 模型的测试集拟合度和 LSTM 模型的测试集拟合度，而 LSTM 模型的测试集拟合度又优于 CNN 模型的测试集拟合度。与表 3 中的结果一致。

图 10 至图 12 清晰地展示了 3 种模型在沪深 300 测试集拟合度的排序，从高到低依次为 CNN-LSTM 模型、LSTM 模型、CNN 模型。

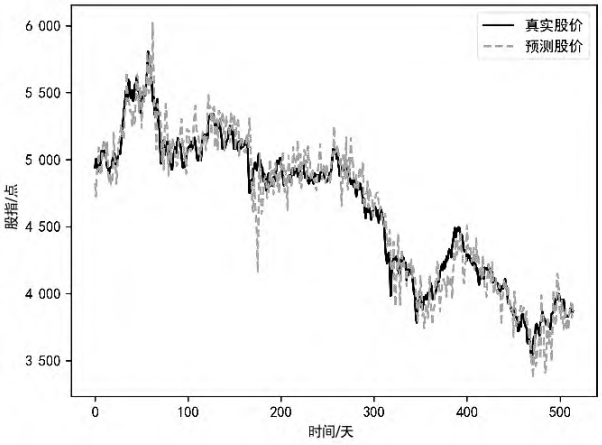

图 10 沪深 300CNN 模型测试集股指预测

Fig. 10 CSI300 CNN model test set stock index forecast

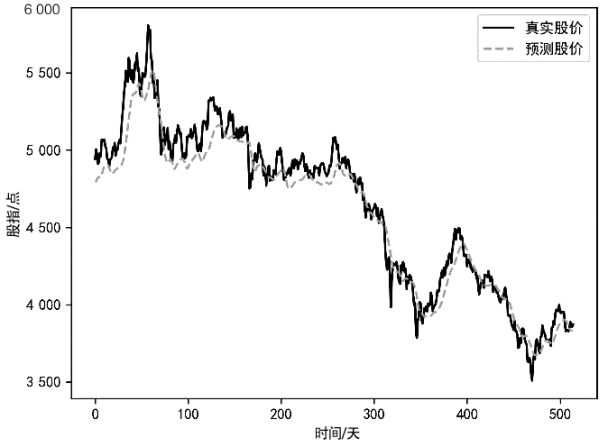

图 11 沪深 300LSTM 模型测试集股指预测

Fig. 11 CSI300 LSTM model test set stock index forecast

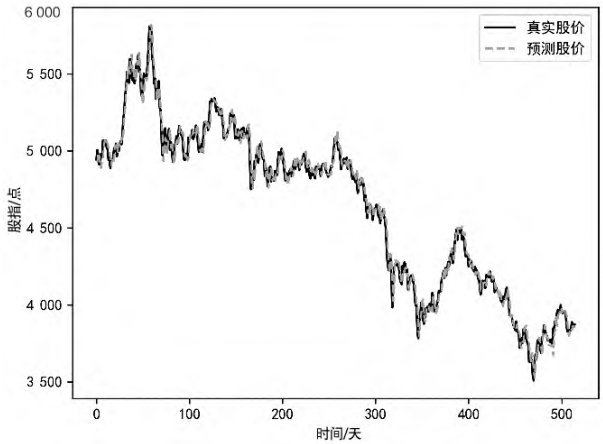

图 12 沪深 300CNN-LSTM 模型测试集股指预测

Fig. 12 CSI300 CNN-LSTM model test set stock index forecast

根据图 13 至图 15，中证 500CNN-LSTM 组合模型的测试集拟合度优于 CNN 模型和 LSTM 模型的测试集拟合度，LSTM 模型的测试集拟合度又优于 CNN 模型的测试集拟合度。

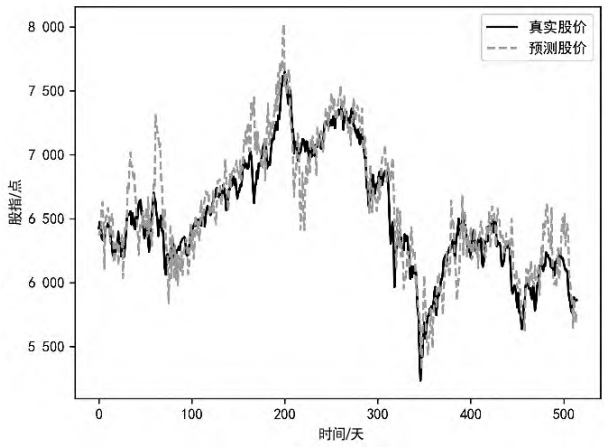

图 13 中证 500CNN 模型测试集股指预测

Fig. 13 CSI500 CNN model test set stock index forecast

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved. http://www.cnki.net

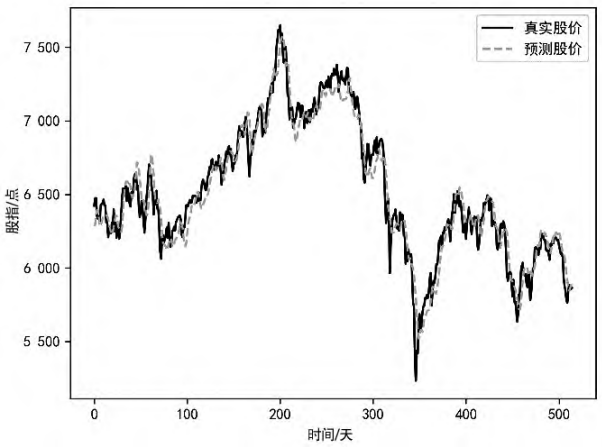

图 14　中证 500LSTM 模型测试集股指预测

Fig. 14 CSI500 LSTM model test set stock index forecast

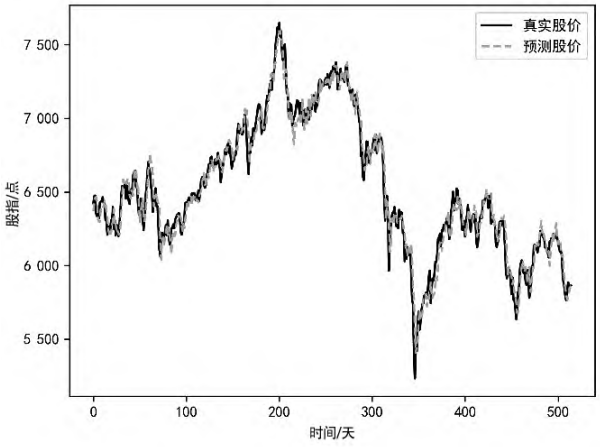

图 15　中证 500CNN-LSTM 模型测试集股指预测

Fig. 15 CSI500 CNN-LSTM model test set stock index forecast

5　结论(Conclusion)

本文基于 2012 年 1 月 1 日至 2022 年 12 月 31 日的上证 50、沪深 300、中证 500 三支股指日交易数据,分别构建了卷积神经网络模型、长短期记忆神经网络模型和 CNN-LSTM 组合神经网络模型,并采用多个指标对预测结果进行评价。主要的研究结论如下:第一,LSTM 模型优于 CNN 模型,CNN-LSTM 组合神经网络模型优于 LSTM 模型;第二,CNN-LSTM 组合神经网络模型的预测更精准、更有效,RMSE 指标分别提升了 28.60 百分点、52.56 百分点和 25.28 百分点。

参考文献(References)

[1] 陈聪,候磊,李乐乐,等. 基于 GRU 改进 RNN 神经网络的飞机燃油流量预测[J]. 科学技术与工程,2021,21(27):11663-11673.

[2] 彭燕,刘宇红,张荣芬. 基于 LSTM 的股票价格预测建模与分析[J]. 计算机工程与应用,2019,55(11):209-212.

[3] 裴大卫,朱明. 基于多因子与多变量长短期记忆网络的股票价格预测[J]. 计算机系统应用,2019,28(8):30-38.

[4] 宋刚,张云峰,包芳勋,等. 基于粒子群优化 LSTM 的股票预测模型[J]. 北京航空航天大学学报,2019,45(12):2533-2542.

[5] 王东,王霄鹏,杨川东. 一种基于主成分 LSTM 模型在股票预测中的研究[J]. 重庆理工大学学报(自然科学),2021,35(2):282-288.

[6] 杨语蒙,李兴东. 基于 GA-LSTM 组合模型的股票价格预测[J]. 现代计算机,2021,27(33):1-7.

[7] 李辉,化金金,邹波蓉. 基于 RF-LSTM 组合模型的股票价格预测[J]. 河南理工大学学报(自然科学版),2022,41(1):136-142.

[8] 张怡. 基于 ARIMA 和 AT-LSTM 组合模型的股票价格预测[J]. 电脑知识与技术,2022,18(11):118-121.

[9] 许艺玮,陆万荣. 基于 XGB-LSTM 组合模型的白酒股票价格预测研究[J]. 电子元器件与信息技术,2022,6(6):64-68.

[10] 郭迎,梁睿琳,王润民. 基于 CNN 图像增强的雾天跨域自适应目标检测[J]. 计算机工程与应用,2023,59(16):187-195.

[11] 王文姣,张娜. 基于 LSTM 变权组合模型的股价预测[J]. 商展经济,2023(7):95-97.

[12] UROLAGIN S,SHARMA N,DATTA T K. A combined architecture of multivariate LSTM with Mahalanobis and Z-Score transformations for oil price forecasting[J]. Energy,2021,231:120963.

作者简介:

高　源(2000-),男,硕士生。研究领域:金融数据分析。

黄　犟(1974-),女,硕士,副教授。研究领域:金融统计。

(C)1994-2024 China Academic Journal Electronic Publishing House. All rights reserved.　http://www.cnki.net